

Diplomado en Aprendizaje de Máquina y Modelos Generativos (DAMMG) – Aprendizaje supervisado

Las 8 demostraciones

Derivaciones completas (anexo para quien quiera la segunda capa)

Módulo VI

Facultad de Ciencias, Universidad Nacional Autónoma de México

Notación y colores según `docs/notacion.md`: $\vec{w}$ pesos, b sesgo, α tasa de aprendizaje, λ, C, γ hiperparámetros, error o residual, $\hat{y}$ predicción.

Octubre de 2026

Índice

Cómo leer este anexo **2**

1. La ecuación normal es una proyección ortogonal **2**

2. Ridge: encogimiento por dirección y prior gaussiano **4**

3. El MSE es el estimador de máxima verosimilitud gaussiano **6**

4. Log-loss = MLE de Bernoulli = entropía cruzada **8**

5. Ganancia de información y Gini **10**

6. SVM: el margen $2/\|\vec{w}\|$, margen suave y bisagra **11**

7. El truco del kernel, a mano **14**

8. Descenso de gradiente: regímenes de α y escalamiento **15**

Referencias **17**

Cómo leer este anexo

En clase cada demostración aparece "casi hecha": tres a cinco pasos visibles y un hueco que completa el grupo. Aquí está la versión completa. Cada sección sigue el mismo orden:

1. **Recuerden**: lo que ya vieron en módulos anteriores y que la derivación usa.
2. **Supuestos**: qué tiene que ser cierto para que el resultado valga.
3. **Derivación** paso a paso.
4. **Contraejemplo**: qué se rompe cuando un supuesto falla.
5. **¿Qué pasa si...?**: cómo se lee el resultado al trabajar con datos reales (MiBici).

Cada demostración tiene un notebook en `notebooks/demos/` donde la identidad se verifica con números y un control deslizante.

Convenciones. Ejemplos $x^{(i)} \in \mathbb{R}^n$, $i = 1, \dots, m$; matriz de diseño $X \in \mathbb{R}^{m \times n}$ con una fila por ejemplo; vector de etiquetas $\vec{y} \in \mathbb{R}^m$. Costo de Ng: $J(\vec{w}, b) = \frac{1}{2m} \sum_i (f_{\vec{w},b}(x^{(i)}) - y^{(i)})^2 + \frac{\lambda}{2m} \|\vec{w}\|^2$, sin regularizar b. Observen que $2m\, J = \|X\vec{w} + b\vec{1} - \vec{y}\|^2 + \lambda \|\vec{w}\|^2$: el mismo λ sirve en la escala de suma que usa `Ridge(alpha=λ)` de scikit-learn.

1. La ecuación normal es una proyección ortogonal

Recuerden (Mód I)

- El espacio columna $\text{col}(X) = \{X\vec{v} : \vec{v} \in \mathbb{R}^p\}$ es un subespacio de $\mathbb{R}^m$.
- $\vec{a} \perp \vec{b} \iff \vec{a}^\top \vec{b} = 0$. Si $\vec{a} \perp \vec{b}$, entonces $\|\vec{a} + \vec{b}\|^2 = \|\vec{a}\|^2 + \|\vec{b}\|^2$ (Pitágoras).
- Para todo X: $\text{col}(X^\top X) = \text{col}(X^\top)$ y $\ker(X^\top X) = \ker(X)$.
- Descomposición en valores singulares (SVD): $X = UDV^\top$, con U, V de columnas ortonormales y D diagonal con $d_1 \geq d_2 \geq \cdots \geq 0$.

Supuestos

- Para no cargar con b, en esta sección la primera columna de X es de unos y b es la primera entrada de $\vec{w}$. Así $X \in \mathbb{R}^{m \times p}$ con $p = n + 1$ y el modelo es $\hat{\vec{y}} = X\vec{w}$.
- Costo sin regularizar: $J(\vec{w}) = \frac{1}{2m} \|X\vec{w} - \vec{y}\|^2$.
- Para que $\hat{\vec{w}}$ sea único hace falta $\text{rango}(X) = p$ (columnas linealmente independientes). La proyección $\hat{\vec{y}}$ es única siempre.

Derivación

Paso 1: minimizar J es buscar el punto de $\text{col}(X)$ más cercano a $\vec{y}$. Cuando $\vec{w}$ recorre $\mathbb{R}^p$, el vector $X\vec{w}$ recorre exactamente $\text{col}(X)$. Entonces

$$\min_{\vec{w}} \|X\vec{w} - \vec{y}\|^2 = \min_{\vec{v} \in \text{col}(X)} \|\vec{v} - \vec{y}\|^2.$$

Paso 2: la condición de primer orden. Expandiendo, $2m\,J(\vec{w}) = \vec{w}^\top X^\top X\vec{w} - 2\vec{w}^\top X^\top \vec{y} + \vec{y}^\top \vec{y}$, así que

$$\nabla J(\vec{w}) = \frac{1}{m} X^\top (X\vec{w} - \vec{y}), \qquad \nabla^2 J(\vec{w}) = \frac{1}{m} X^\top X.$$

La hessiana es semidefinida positiva ($\vec{v}^\top X^\top X\vec{v} = \|X\vec{v}\|^2 \geq 0$), así que J es convexa y todo punto con gradiente cero es un mínimo global. Igualando el gradiente a cero obtenemos las **ecuaciones normales**:

$$\boxed{X^\top X\,\hat{\vec{w}} = X^\top \vec{y}}$$

Siempre tienen solución, porque $X^\top \vec{y} \in \mathrm{col}(X^\top) = \mathrm{col}(X^\top X)$.

Paso 3: leer las ecuaciones normales como ortogonalidad. Definan el residual $\vec{r} = \vec{y} - X\hat{\vec{w}}$. Las ecuaciones normales dicen

$$X^\top \vec{r} = \vec{0} \quad \Longleftrightarrow \quad \vec{x}_{:,j}^\top \vec{r} = 0 \ \text{ para cada columna } j.$$

El residual es perpendicular a *cada* columna de X, y por lo tanto a todo $\mathrm{col}(X)$. De ahí el nombre: las ecuaciones son "normales" porque el residual es normal (perpendicular) al subespacio.

Paso 4: Pitágoras prueba que es el más cercano. Sea $\hat{\vec{y}} = X\hat{\vec{w}}$ y sea $\vec{v} \in \mathrm{col}(X)$ cualquiera. Como $\hat{\vec{y}} - \vec{v} \in \mathrm{col}(X)$ y $\vec{r} \perp \mathrm{col}(X)$,

$$\|\vec{y} - \vec{v}\|^2 = \|\vec{r} + (\hat{\vec{y}} - \vec{v})\|^2 = \|\vec{r}\|^2 + \|\hat{\vec{y}} - \vec{v}\|^2 \ \geq \ \|\vec{r}\|^2,$$

con igualdad si y solo si $\vec{v} = \hat{\vec{y}}$. Así que $\hat{\vec{y}}$ es el único punto de $\mathrm{col}(X)$ más cercano a $\vec{y}$: la **proyección ortogonal** de $\vec{y}$ sobre $\mathrm{col}(X)$.

Paso 5: la matriz de proyección. Si $\mathrm{rango}(X) = p$, entonces $\ker(X^\top X) = \ker(X) = \{\vec{0}\}$, la matriz $X^\top X$ es invertible y

$$\hat{\vec{w}} = (X^\top X)^{-1} X^\top \vec{y}, \qquad \hat{\vec{y}} = H\vec{y}, \quad H = X(X^\top X)^{-1} X^\top.$$

H es simétrica ($H^\top = H$) e idempotente ($H^2 = X(X^\top X)^{-1}X^\top X(X^\top X)^{-1}X^\top = H$): proyectar dos veces es lo mismo que proyectar una. Además $\vec{r} = (I - H)\vec{y}$ y $\mathrm{tr}\, H = \mathrm{tr}\left((X^\top X)^{-1} X^\top X\right) = p$.

Paso 6: una consecuencia práctica. Como la primera columna de X es $\vec{1}$, el paso 3 da $\vec{1}^\top \vec{r} = \sum_i r_i = 0$: con intercepto, los residuales de mínimos cuadrados suman cero.

Cuando $X^\top X$ está casi singular

Con la SVD delgada $X = UDV^\top$ ($U \in \mathbb{R}^{m\times p}$, $D = \mathrm{diag}(d_1, \ldots, d_p)$, $V \in \mathbb{R}^{p\times p}$ ortogonal) y todos los $d_j > 0$:

$$\hat{\vec{w}} = \sum_{j=1}^{p} \frac{\vec{u}_j^\top \vec{y}}{d_j}\, \vec{v}_j, \qquad \hat{\vec{y}} = \sum_{j=1}^{p} \vec{u}_j\, (\vec{u}_j^\top \vec{y}).$$

Las predicciones *no dependen* de los d_j (solo de las direcciones $\vec{u}_j$). Los coeficientes sí: si dos columnas son casi colineales, algún d_p es diminuto y una perturbación $\varepsilon\,\vec{u}_p$ en $\vec{y}$ mueve $\hat{\vec{w}}$ en $(\varepsilon/d_p)\,\vec{v}_p$. Además $X^\top X = VD^2V^\top$, así que su número de condición es $\kappa(X^\top X) = (d_1/d_p)^2 = \kappa(X)^2$. Resolver las ecuaciones normales eleva al cuadrado la condición; por eso las bibliotecas usan QR o SVD (`np.linalg.lstsq`) en lugar de invertir $X^\top X$.

Contraejemplo: cuando un supuesto falla

Si una columna es combinación lineal de otras (por ejemplo, temperatura en °C y en °F, o $x_2 = 2x_1$), entonces $\text{rango}(X) < p$ y $X^\top X$ es singular. Las ecuaciones normales tienen *infinitas* soluciones: si $\hat{\vec{w}}$ es una, también lo es $\hat{\vec{w}} + t\,\vec{n}$ para cualquier $\vec{n} \in \ker(X)$, porque $X(\hat{\vec{w}} + t\vec{n}) = X\hat{\vec{w}}$. La proyección $\hat{\vec{y}}$ sigue siendo única (paso 4 no usó el rango). La pseudo-inversa elige la solución de norma mínima, $\hat{\vec{w}}^+ = X^+\vec{y}$, que es la única perpendicular a $\ker(X)$.

¿Qué pasa si...?

...dos variables de MiBici están casi duplicadas (por ejemplo, la hora y una variable "turno" derivada de ella)? Las predicciones casi no cambian, pero los coeficientes se vuelven enormes, con signos opuestos y muy sensibles a quitar unos cuantos días de datos. Si el objetivo es predecir, esto molesta poco; si el objetivo es interpretar "cuánto sube la demanda por grado de temperatura", es grave. En el notebook D1 el control mueve la correlación entre dos columnas hacia 1: el residual sigue perpendicular a las columnas (producto punto del orden de 10^{-12}) mientras $\kappa(X^\top X)$ explota. La demostración 2 (Ridge) es el remedio.

2. Ridge: encogimiento por dirección y prior gaussiano

Recuerden (Mód I y Mód V)

- (Mód I) SVD $X = UDV^\top$; si V es ortogonal, $VV^\top = V^\top V = I$, y $(VMV^\top)^{-1} = VM^{-1}V^\top$ para M invertible.
- (Mód V) Regla de Bayes: $p(\vec{w} \mid \text{datos}) \propto p(\text{datos} \mid \vec{w})\, p(\vec{w})$. El estimador MAP maximiza la posterior.
- (Mód V) Densidad de $\mathcal{N}(\vec{0}, \tau^2 I_n)$: $p(\vec{w}) = (2\pi\tau^2)^{-n/2} \exp\big(-\|\vec{w}\|^2/(2\tau^2)\big)$.

Supuestos

- $X \in \mathbb{R}^{m\times n}$ y $\vec{y}$ están **centrados** (media cero por columna). Entonces el intercepto óptimo es $\hat{b} = \bar{y} - \bar{\vec{x}}^\top \hat{\vec{w}}$ y se puede quitar del problema; así no se regulariza b.
- Las columnas están **estandarizadas** (o al menos en unidades comparables): la penalización $\|\vec{w}\|^2$ trata a todas las entradas por igual.
- $\lambda > 0$ en la escala de suma: minimizamos $\|\vec{y} - X\vec{w}\|^2 + \lambda\|\vec{w}\|^2$, que es $2m$ veces el costo de Ng.
- Para la lectura MAP: $y^{(i)} = \vec{w} \cdot x^{(i)} + \varepsilon^{(i)}$ con $\varepsilon^{(i)} \sim \mathcal{N}(0, \sigma^2)$ i.i.d. y prior $\vec{w} \sim \mathcal{N}(\vec{0}, \tau^2 I)$ independiente del ruido.

Derivación (a): la solución cerrada

El gradiente de $\|\vec{y} - X\vec{w}\|^2 + \lambda\|\vec{w}\|^2$ es $2X^\top(X\vec{w} - \vec{y}) + 2\lambda\vec{w}$. Igualando a cero:

$$(X^\top X + \lambda I)\,\hat{\vec{w}}_\lambda = X^\top \vec{y}.$$

Para $\lambda > 0$ la matriz $X^\top X + \lambda I$ es definida positiva, porque $\vec{v}^\top (X^\top X + \lambda I)\vec{v} = \|X\vec{v}\|^2 + \lambda\|\vec{v}\|^2 > 0$ si $\vec{v} \neq \vec{0}$. Por eso es invertible *aunque* X *tenga rango deficiente*, y la solución es única.

Derivación (b): el encogimiento vía SVD

Supongan $m \geq n$ y tomen la SVD delgada $X = UDV^\top$ con $U \in \mathbb{R}^{m\times n}$ ($U^\top U = I$), $D = \operatorname{diag}(d_1, \ldots, d_n)$, $d_j \geq 0$, y $V \in \mathbb{R}^{n\times n}$ ortogonal. Entonces

$$\begin{aligned} X^\top X + \lambda I &= VDU^\top UDV^\top + \lambda VV^\top = V(D^2 + \lambda I)V^\top, \\ (X^\top X + \lambda I)^{-1} &= V(D^2 + \lambda I)^{-1}V^\top, \\ \hat{\vec{w}}_\lambda &= V(D^2 + \lambda I)^{-1}V^\top\, VDU^\top \vec{y} = V\ \operatorname{diag}\Big(\frac{d_j}{d_j^2 + \lambda}\Big)U^\top \vec{y}. \end{aligned}$$

Y las predicciones:

$$\hat{\vec{y}}_\lambda = X\hat{\vec{w}}_\lambda = UDV^\top V\ \operatorname{diag}\Big(\frac{d_j}{d_j^2 + \lambda}\Big)U^\top \vec{y} = \sum_{j=1}^{n} \vec{u}_j\ \underbrace{\frac{d_j^2}{d_j^2 + \lambda}}_{s_j(\lambda)}\ \vec{u}_j^\top \vec{y}.$$

Comparen con mínimos cuadrados (sección 1): $\hat{\vec{y}}_{\text{OLS}} = \sum_j \vec{u}_j\, \vec{u}_j^\top \vec{y}$. Ridge toma la componente de $\vec{y}$ en cada dirección principal $\vec{u}_j$ y la multiplica por

$$\boxed{s_j(\lambda) = \frac{d_j^2}{d_j^2 + \lambda} \in [0, 1)}$$

Lo mismo pasa con los coeficientes en la base $\{\vec{v}_j\}$: la coordenada j de $\hat{\vec{w}}_\lambda$ es $\frac{d_j}{d_j^2+\lambda}\vec{u}_j^\top \vec{y} = s_j(\lambda) \cdot \frac{\vec{u}_j^\top \vec{y}}{d_j}$, es decir, s_j veces la de OLS (si $d_j > 0$).

Lectura: d_j^2/m es la varianza de los datos (centrados) en la dirección $\vec{v}_j$. Las direcciones con mucha varianza ($d_j^2 \gg \lambda$) casi no se tocan ($s_j \approx 1$); las de poca varianza ($d_j^2 \ll \lambda$), que son justo las que hacen inestable a OLS, se apagan ($s_j \approx 0$). La suma $\operatorname{df}(\lambda) = \sum_j s_j(\lambda) = \operatorname{tr} H_\lambda$ son los *grados de libertad efectivos*: vale $\operatorname{rango}(X)$ en $\lambda = 0$ y tiende a 0 cuando $\lambda \to \infty$.

Si $m < n$, se usa la SVD delgada con $r = \operatorname{rango}(X)$ componentes y la misma fórmula; la parte de $\hat{\vec{w}}_\lambda$ en $\ker(X)$ es cero. En el límite $\lambda \to 0^+$ se obtiene $\hat{\vec{w}}^+ = X^+\vec{y}$, la solución de norma mínima.

Derivación (c): Ridge es el MAP con prior gaussiano

Con los supuestos de ruido gaussiano (sección 3) y prior $\mathcal{N}(\vec{0}, \tau^2 I)$:

$$\begin{aligned} \log p(\vec{w} \mid X, \vec{y}) &= \log p(\vec{y} \mid X, \vec{w}) + \log p(\vec{w}) - \log p(\vec{y} \mid X) \\ &= -\frac{1}{2\sigma^2}\|\vec{y} - X\vec{w}\|^2 - \frac{1}{2\tau^2}\|\vec{w}\|^2 + \text{const.} \end{aligned}$$

donde "const." no depende de $\vec{w}$. Multiplicando por $-2\sigma^2 < 0$ (cambia máximo por mínimo):

$$\hat{\vec{w}}_{\text{MAP}} = \arg\min_{\vec{w}}\ \|\vec{y} - X\vec{w}\|^2 + \frac{\sigma^2}{\tau^2}\|\vec{w}\|^2.$$

Es Ridge con $\lambda = \sigma^2/\tau^2$, es decir,

$$\boxed{\vec{w} \sim \mathcal{N}\Big(\vec{0},\ \frac{\sigma^2}{\lambda} I\Big)}$$

Un λ grande es un prior angosto: "antes de ver datos, creo con firmeza que los pesos son chicos". Como la posterior es gaussiana, su moda (MAP) coincide con su media. No regularizar b equivale a ponerle un prior plano.

Contraejemplo: cuando un supuesto falla

- **Otro prior, otra penalización.** Con prior de Laplace $p(w_j) \propto e^{-|w_j|/\beta}$ el mismo cálculo da $\|\vec{y} - X\vec{w}\|^2 + 2\sigma^2/\beta \sum_j |w_j|$: Lasso, que sí produce coeficientes exactamente cero. Ridge nunca anula un coeficiente para λ finito (porque $s_j > 0$ si $d_j > 0$).
- **Sin estandarizar.** Si una columna se mide en metros y la cambian a kilómetros (se divide entre 1000), OLS multiplica su coeficiente por 1000 y las predicciones no cambian. Ridge no: ese coeficiente grande ahora cuesta mucho y se encoge más, y las predicciones sí cambian. El prior isotrópico $\mathcal{N}(\vec{0}, \tau^2 I)$ solo tiene sentido si las variables están en escalas comparables.

¿Qué pasa si...?

...subo λ? Primero se apagan las direcciones de poca varianza (las combinaciones casi colineales de la demostración 1), luego las demás; $\hat{\vec{w}}_\lambda \to \vec{0}$ y el modelo predice $\bar{y}$. **...lo bajo a cero?** Regresan los coeficientes inestables. En MiBici, λ se elige en validación temporal; el notebook D2 muestra los s_j en barras y cómo la norma de $\hat{\vec{w}}_\lambda$ baja con λ. En scikit-learn: `Ridge(alpha=λ)` usa esta misma escala de suma.

3. El MSE es el estimador de máxima verosimilitud gaussiano

Recuerden (Mód V)

- Verosimilitud: $L(\theta) = p(\text{datos} \mid \theta)$ vista como función de θ. Con observaciones independientes, es un producto.
- log es estrictamente creciente: $\arg\max L = \arg\max \log L$.
- Densidad normal: $\mathcal{N}(\mu, \sigma^2)$ tiene $p(t) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\big(-\frac{(t-\mu)^2}{2\sigma^2}\big)$.

Supuestos

- Modelo: $y^{(i)} = f_{\vec{w},b}(x^{(i)}) + \varepsilon^{(i)}$, con los $x^{(i)}$ tratados como fijos.
- Ruido **gaussiano**: $\varepsilon^{(i)} \sim \mathcal{N}(0, \sigma^2)$.
- **Independiente e idénticamente distribuido** (i.i.d.) entre ejemplos.
- **Varianza constante** σ^2: no depende de i ni de $x^{(i)}$ (homocedasticidad).

Derivación

Paso 1: la densidad de una observación. Con los supuestos, $y^{(i)} \mid x^{(i)} \sim \mathcal{N}\big(f_{\vec{w},b}(x^{(i)}), \sigma^2\big)$:

$$p\big(y^{(i)} \mid x^{(i)}; \vec{w}, b\big) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\Big(- \frac{(f_{\vec{w},b}(x^{(i)}) - y^{(i)})^2}{2\sigma^2} \Big).$$

Paso 2: la verosimilitud es un producto (independencia).

$$L(\vec{w}, b) = \prod_{i=1}^{m} p\big(y^{(i)} \mid x^{(i)}; \vec{w}, b\big).$$

Paso 3: tomar logaritmo.

$$\ell(\vec{w}, b) = \log L = -\frac{m}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^{m} (f_{\vec{w},b}(x^{(i)}) - y^{(i)})^2.$$

Paso 4: reconocer el costo. Con $J(\vec{w}, b) = \frac{1}{2m} \sum_i (f_{\vec{w},b}(x^{(i)}) - y^{(i)})^2$,

$$-\ell(\vec{w}, b) = \frac{m}{\sigma^2} J(\vec{w}, b) + \frac{m}{2} \log(2\pi\sigma^2).$$

Como $m/\sigma^2 > 0$ y el segundo término no depende de $(\vec{w}, b)$,

$$\boxed{\arg\max_{\vec{w},b} \ \ell(\vec{w}, b) = \arg\min_{\vec{w},b} \ J(\vec{w}, b)}$$

El valor de σ^2 no cambia el minimizador. Esto vale para cualquier f (lineal, polinomial, red neuronal); para f lineal, el minimizador es el de la sección 1.

Paso 5 (extra): estimar σ^2. Sea $S = \sum_i (f_{\hat{\vec{w}},\hat{b}}(x^{(i)}) - y^{(i)})^2$. Derivando ℓ respecto a σ^2: $-\frac{m}{2\sigma^2} + \frac{S}{2\sigma^4} = 0$, de donde $\hat{\sigma}^2 = S/m = 2J(\hat{\vec{w}}, \hat{b})$. (Este estimador está sesgado; el insesgado divide entre $m - p$.)

Contraejemplo: cuando un supuesto falla

Ruido de Laplace. Si $\varepsilon^{(i)}$ tiene densidad $\frac{1}{2\beta} e^{-|\varepsilon|/\beta}$, el mismo procedimiento da

$$-\ell(\vec{w}, b) = m \log(2\beta) + \frac{1}{\beta} \sum_{i=1}^{m} \big| f_{\vec{w},b}(x^{(i)}) - y^{(i)} \big|,$$

y el MLE minimiza el **error absoluto medio** (MAE), no el MSE. Ejemplo con un modelo constante $f = c$ y datos $\{1, 2, 3, 4, 100\}$: el MSE se minimiza en la media, $c = 22$; el MAE, en la mediana, $c = 3$. El valor atípico arrastra al MSE porque el ruido gaussiano casi nunca produce desviaciones así, y el modelo "se mueve" para explicarlo.

Varianza no constante. Si $\varepsilon^{(i)} \sim \mathcal{N}(0, \sigma_i^2)$, el MLE minimiza $\sum_i (f(x^{(i)}) - y^{(i)})^2 / \sigma_i^2$: mínimos cuadrados *ponderados*. El MSE sin pesos ya no es el MLE.

¿Qué pasa si...?

...el ruido de mis datos no es gaussiano? El MSE sigue siendo un costo razonable, pero deja de ser "el" estimador natural. En MiBici, los viajes por hora son conteos: en horas pico la varianza es mucho mayor que de madrugada, así que el MSE le da más peso a las horas pico. Opciones: modelar $\log(1+y)$, usar MAE o Huber si hay atípicos, o regresión de Poisson. El notebook D3 grafica $\ell(w)$ y muestra que su máximo cae en el $\hat{w}$ de mínimos cuadrados; con ruido de Laplace y un atípico, el MLE se separa del MSE.

4. Log-loss = MLE de Bernoulli = entropía cruzada

Recuerden (Mód II)

- Entropía cruzada entre distribuciones q (la verdadera) y p (la del modelo): $H(q,p) = -\sum_k q_k \log p_k$.
- $H(q,p) = H(q) + D_{\mathrm{KL}}(q \,\|\, p)$ y $D_{\mathrm{KL}} \geq 0$, con igualdad si y solo si $p = q$.
- Cambiar la base del logaritmo (bits contra nats) multiplica todo por una constante positiva y no cambia el minimizador.

Supuestos

- Etiquetas $y^{(i)} \in \{0,1\}$, condicionalmente independientes dado $x^{(i)}$.
- Modelo: $P(y=1 \mid x) = \hat{p} = \sigma(z)$, con $z = \vec{w} \cdot x + b$ y $\sigma(z) = 1/(1+e^{-z})$.
- Logaritmo natural. En código se recorta $\hat{p} \in [10^{-12}, 1-10^{-12}]$ para evitar $\log 0$.

Derivación (a): de Bernoulli al log-loss

Una variable de Bernoulli con parámetro $\hat{p}$ cumple $P(y) = \hat{p}^{\,y}(1-\hat{p})^{1-y}$ para $y \in \{0,1\}$ (verifiquen: $y=1$ da $\hat{p}$ y $y=0$ da $1-\hat{p}$). Con independencia,

$$L(\vec{w}, b) = \prod_{i=1}^{m} \left(\hat{p}^{(i)}\right)^{y^{(i)}} \left(1-\hat{p}^{(i)}\right)^{1-y^{(i)}}, \qquad \ell = \sum_{i=1}^{m} \left[y^{(i)} \log \hat{p}^{(i)} + (1-y^{(i)}) \log(1-\hat{p}^{(i)}) \right].$$

Entonces $-\ell/m$ es exactamente el costo logístico:

$$\boxed{J(\vec{w}, b) = -\frac{1}{m} \sum_{i=1}^{m} \left[y^{(i)} \log \hat{p}^{(i)} + (1-y^{(i)}) \log(1-\hat{p}^{(i)}) \right] = -\frac{\ell}{m}}$$

Derivación (b): es una entropía cruzada

Para el ejemplo i, la distribución "verdadera" de la etiqueta es la empírica $q^{(i)} = (y^{(i)},\, 1-y^{(i)})$ (toda la masa en la clase observada) y la del modelo es $p^{(i)} = (\hat{p}^{(i)},\, 1-\hat{p}^{(i)})$. Entonces

$$H\left(q^{(i)}, p^{(i)}\right) = -y^{(i)} \log \hat{p}^{(i)} - (1-y^{(i)}) \log(1-\hat{p}^{(i)}),$$

que es el término i del log-loss. Como $q^{(i)}$ es degenerada, $H(q^{(i)}) = 0$ y la entropía cruzada coincide con $D_{\mathrm{KL}}(q^{(i)} \| p^{(i)})$: el log-loss mide cuánta información "sobra" al describir la etiqueta real con las probabilidades del modelo.

Derivación (c): el gradiente tiene la forma del de la regresión lineal

Para un ejemplo, $\mathcal{L} = -[y \log p + (1-y)\log(1-p)]$ con $p = \sigma(z)$. Usamos tres derivadas:

$$\frac{\partial \mathcal{L}}{\partial p} = -\frac{y}{p} + \frac{1-y}{1-p} = \frac{p-y}{p(1-p)}, \qquad \sigma'(z) = \sigma(z)\big(1-\sigma(z)\big), \qquad \frac{\partial z}{\partial w_j} = x_j.$$

(La segunda sale de $\sigma'(z) = \frac{e^{-z}}{(1+e^{-z})^2} = \frac{1}{1+e^{-z}} \cdot \frac{e^{-z}}{1+e^{-z}}$.) Por la regla de la cadena, el factor $p(1-p)$ se cancela:

$$\frac{\partial \mathcal{L}}{\partial z} = p - y, \qquad \frac{\partial \mathcal{L}}{\partial w_j} = (p-y)\, x_j, \qquad \frac{\partial \mathcal{L}}{\partial b} = (p-y).$$

Promediando y agregando la regularización:

$$\frac{\partial J}{\partial w_j} = \frac{1}{m}\sum_{i=1}^{m} \big(\hat{p}^{(i)} - y^{(i)}\big)\, x_j^{(i)} + \frac{\lambda}{m} w_j, \qquad \frac{\partial J}{\partial b} = \frac{1}{m}\sum_{i=1}^{m} \big(\hat{p}^{(i)} - y^{(i)}\big).$$

Es *la misma expresión* que en regresión lineal, con $f_{\vec{w},b}(x) = \sigma(\vec{w} \cdot x + b)$ en lugar de $\vec{w} \cdot x + b$. El código de descenso de gradiente es casi idéntico; el modelo no lo es.

Derivación (d): por qué no usar MSE con la sigmoide

El log-loss es convexo. $\frac{\partial^2 \mathcal{L}}{\partial z^2} = \sigma'(z) = p(1-p) \geq 0$, y z es lineal en $(\vec{w}, b)$; la composición de una función convexa con una afín es convexa. La hessiana de J es $\frac{1}{m}\sum_i \hat{p}^{(i)}(1-\hat{p}^{(i)})\tilde{x}^{(i)}\tilde{x}^{(i)\top} \succeq 0$, con $\tilde{x} = (x, 1)$.

El MSE con sigmoide no lo es. Para un ejemplo con $y = 1$, sea $g(z) = (\sigma(z) - 1)^2$ y $s = \sigma(z)$. Entonces

$$g'(z) = 2(s-1)\, s(1-s) = -2s(1-s)^2, \qquad g''(z) = -2\big[s'(1-s)^2 - 2s(1-s)s'\big] = -2s(1-s)^2(1-3s).$$

Así $g''(z) < 0$ cuando $s < 1/3$, es decir, cuando $z < -\ln 2$: hay una región cóncava y el costo total puede tener mesetas y mínimos locales. Peor aún, si el modelo se equivoca con mucha confianza ($z \to -\infty$), $g'(z) \to 0$ y el gradiente casi no empuja, mientras que el del log-loss vale $p - 1 \to -1$.

Contraejemplo: cuando un supuesto falla

Datos linealmente separables. Si existe $(\vec{w}, b)$ que clasifica todo bien con margen estricto (ningún punto sobre la frontera), entonces con $(t\vec{w}, tb)$ y $t \to \infty$ cada $\hat{p}^{(i)}$ tiende a $y^{(i)}$ y $J \to 0$, pero ningún parámetro finito alcanza $J = 0$. El MLE no existe y el descenso de gradiente hace crecer $\|\vec{w}\|$ sin parar. La regularización ($\lambda > 0$, o un prior gaussiano como en la sección 2) devuelve un mínimo finito y único.

¿Qué pasa si...?

...el modelo dice $\hat{p} = 0.001$ y la etiqueta real es 1? El log-loss cobra $-\ln 0.001 \approx 6.9$; el error cuadrático cobraría como máximo 1. El log-loss castiga la sobreconfianza, y por eso empuja a probabilidades calibradas. En el Lab 2 ("¿flujo neto extremo en la próxima hora?") esas probabilidades son las que después se cortan con un umbral elegido en validación. El notebook D4 compara las dos curvas de costo y verifica numéricamente que el gradiente analítico coincide con el de diferencias finitas.

5. Ganancia de información y Gini

Recuerden (Mód II)

- Entropía en bits: $H(Y) = -\sum_k p_k \log_2 p_k$, con $0 \log 0 = 0$.
- Entropía condicional: $H(Y \mid S) = \sum_s P(S = s)\, H(Y \mid S = s)$.
- Información mutua: $I(Y; S) = H(Y) - H(Y \mid S) \geq 0$.
- Una función ϕ es cóncava si $\phi\big(\sum_h \pi_h p_h\big) \geq \sum_h \pi_h \phi(p_h)$ para pesos $\pi_h \geq 0$ que suman 1 (Jensen).

Supuestos

- Las probabilidades de cada nodo se estiman con las frecuencias de las clases en ese nodo.
- Cortes binarios: un nodo padre con N ejemplos se divide en dos hijos con $N_{\text{izq}} + N_{\text{der}} = N$ (uso N para no confundirlo con n, el número de variables).
- El árbol se construye de manera *voraz*: en cada nodo se elige el mejor corte local.

Derivación

Paso 1: la ganancia es información mutua. Sea $S \in \{\text{izq}, \text{der}\}$ el hijo al que cae un ejemplo. Con frecuencias, $P(S = h) = N_h/N$ y $H(Y \mid S = h) = H(\text{hijo } h)$. Entonces

$$IG = H(\text{padre}) - \sum_h \frac{N_h}{N} H(\text{hijo } h) = H(Y) - H(Y \mid S) = I(Y; S).$$

Paso 2: la ganancia nunca es negativa. La distribución de clases del padre es la mezcla de las de los hijos: $p_{\text{padre}} = \sum_h \frac{N_h}{N} p_h$. En el caso binario $H(p) = -p \log_2 p - (1-p) \log_2 (1-p)$ y

$$H''(p) = -\frac{1}{p(1-p)\ln 2} < 0 \quad (0 < p < 1),$$

así que H es cóncava y, por Jensen, $H(p_{\text{padre}}) \geq \sum_h \frac{N_h}{N} H(p_h)$, es decir $IG \geq 0$. Como la concavidad es estricta, $IG = 0$ si y solo si los dos hijos tienen la misma proporción de clases que el padre: el corte no separó nada.

Paso 3: Gini se comporta igual. $G(p) = 1 - \sum_k p_k^2 = \sum_k p_k (1 - p_k)$. En el caso binario $G(p) = 2p(1-p)$ y $G'' = -4 < 0$; con el mismo argumento, la reducción de Gini es ≥ 0.

Paso 4: Gini es la aproximación de primer orden de la entropía. Como $\ln t \le t - 1$ para $t > 0$, se tiene $-\ln p_k \ge 1 - p_k$, y por lo tanto

$$H_{\text{nats}}(p) = -\sum_k p_k \ln p_k \;\ge\; \sum_k p_k(1 - p_k) = G(p),$$

y Gini se obtiene de la entropía al cambiar $-\ln p_k$ por su aproximación lineal alrededor de $p_k = 1$, que es $1 - p_k$. Las dos valen cero en nodos puros, son máximas en la distribución uniforme ($H = 1$ bit y $G = 1/2$ con dos clases) y son simétricas. Gini no usa logaritmos, por eso es un poco más barata y es el criterio por omisión de scikit-learn.

Ejemplo resuelto. Padre con 10 positivos y 10 negativos: $H = 1$, $G = 0.5$.

Corte	Hijos	IG (bits)	Reducción de Gini
A	$[8, 2]$ y $[2, 8]$	$1 - 0.722 = 0.278$	$0.5 - 0.320 = 0.180$
B	$[10, 4]$ y $[0, 6]$	$1 - \frac{14}{20}(0.863) = 0.396$	$0.5 - \frac{14}{20}(0.408) = 0.214$

Los dos criterios prefieren B, que produce un hijo puro. En la práctica casi siempre coinciden; Raileanu y Stoffel (2004) reportan desacuerdo en alrededor de 2 % de los casos que estudiaron.

Contraejemplo: cuando un supuesto falla

- **La voracidad no ve interacciones (XOR).** Cuatro puntos $(0,0) \mapsto 0$, $(1,1) \mapsto 0$, $(0,1) \mapsto 1$, $(1,0) \mapsto 1$. Cortar por x_1 deja hijos $[1,1]$ y $[1,1]$: $IG = 0$. Lo mismo con x_2. Sin embargo, dos cortes seguidos clasifican todo perfecto. El criterio local dice "no hay nada que ganar" justo donde hay estructura.
- **Variables con muchos valores.** Un identificador único (por ejemplo, el ID del viaje) deja hijos puros de un ejemplo cada uno: $IG = H(\text{padre})$, la máxima posible, y el corte no generaliza nada. Por eso existen correcciones como la razón de ganancia (C4.5) y, en la práctica, límites de profundidad y de tamaño de hoja.

¿Qué pasa si...?

...cambio `criterion="gini"` por `"entropy"`? Casi siempre obtienen el mismo árbol o uno muy parecido; la decisión que importa más es `max_depth` y `min_samples_leaf`. **...muevo el umbral del corte?** En el notebook D5 el control mueve el umbral sobre una variable de MiBici y la gráfica muestra IG y la reducción de Gini: las dos curvas tienen el máximo casi en el mismo lugar.

6. SVM: el margen $2/\|\vec{w}\|$, margen suave y bisagra

Recuerden (Mód I y Mód III)

- (Mód I) El hiperplano $\{x : \vec{w} \cdot x + b = 0\}$ tiene vector normal $\vec{w}$. La distancia de un punto x_0 a él es $|\vec{w} \cdot x_0 + b|/\|\vec{w}\|$.
- (Mód III) Multiplicadores de Lagrange y condiciones de Karush-Kuhn-Tucker (KKT) para problemas con restricciones de desigualdad: estacionariedad, factibilidad primal y dual, y holgura complementaria.

Supuestos

- Etiquetas $y^{(i)} \in \{-1, +1\}$ y clasificador signo$(\vec{w} \cdot x + b)$.
- **Margen duro**: los datos son linealmente separables.
- **Margen suave**: no hace falta separabilidad; $C > 0$ es el peso de los errores (el `C` de `SVC`).
- Las variables están en escalas comparables (el margen se mide con distancia euclidiana).

Derivación (a): distancia de un punto al hiperplano

Sea x_p la proyección de x_0 sobre el hiperplano. Como $\vec{w}$ es normal, $x_p = x_0 - t\,\frac{\vec{w}}{\|\vec{w}\|}$ para algún $t \in \mathbb{R}$, y $|t|$ es la distancia. Imponiendo $\vec{w} \cdot x_p + b = 0$:

$$\vec{w} \cdot x_0 + b - t\,\frac{\vec{w} \cdot \vec{w}}{\|\vec{w}\|} = 0 \implies t = \frac{\vec{w} \cdot x_0 + b}{\|\vec{w}\|}.$$

Derivación (b): por qué el margen es $2/\|\vec{w}\|$

Los pares $(\vec{w}, b)$ y $(c\vec{w}, cb)$ con $c > 0$ definen el mismo hiperplano. Fijamos la escala (*escala canónica*) pidiendo

$$\min_i \; y^{(i)}(\vec{w} \cdot x^{(i)} + b) = 1.$$

Entonces los puntos más cercanos cumplen $\vec{w} \cdot x + b = \pm 1$: están sobre los **planos canónicos**. Tomen x_+ en el plano $+1$ y x_- en el plano -1. Restando, $\vec{w} \cdot (x_+ - x_-) = 2$. La distancia entre los planos paralelos es la componente de $x_+ - x_-$ en la dirección normal unitaria:

$$\left(x_+ - x_-\right) \cdot \frac{\vec{w}}{\|\vec{w}\|} = \frac{2}{\|\vec{w}\|}.$$

Así, $2/\|\vec{w}\|$ es la distancia entre los planos canónicos, y cada uno está a $1/\|\vec{w}\|$ de la frontera. Maximizar $2/\|\vec{w}\|$ es lo mismo que minimizar $\frac{1}{2}\|\vec{w}\|^2$ (más cómodo: diferenciable y convexo):

$$\min_{\vec{w}, b} \; \tfrac{1}{2}\|\vec{w}\|^2 \quad \text{s.a.} \quad y^{(i)}(\vec{w} \cdot x^{(i)} + b) \geq 1, \quad i = 1, \ldots, m.$$

Derivación (c): el dual y los vectores de soporte (margen duro)

Lagrangiano con $\alpha_i \geq 0$: $\mathcal{L} = \frac{1}{2}\|\vec{w}\|^2 - \sum_i \alpha_i \left[y^{(i)}(\vec{w} \cdot x^{(i)} + b) - 1\right]$. Estacionariedad:

$$\frac{\partial \mathcal{L}}{\partial \vec{w}} = 0 \Rightarrow \vec{w} = \sum_i \alpha_i y^{(i)} x^{(i)}, \qquad \frac{\partial \mathcal{L}}{\partial b} = 0 \Rightarrow \sum_i \alpha_i y^{(i)} = 0.$$

Holgura complementaria: $\alpha_i \left[y^{(i)}(\vec{w} \cdot x^{(i)} + b) - 1\right] = 0$. Si un punto no está sobre un plano canónico, su α_i es cero. Solo los puntos sobre los planos (los **vectores de soporte**) entran en $\vec{w}$. Sustituyendo $\vec{w}$ en $\mathcal{L}$ queda el dual

$$\max_{\alpha} \; \sum_i \alpha_i - \tfrac{1}{2} \sum_{i,k} \alpha_i \alpha_k \, y^{(i)} y^{(k)} \left(x^{(i)} \cdot x^{(k)}\right) \quad \text{s.a.} \quad \alpha_i \geq 0, \quad \sum_i \alpha_i y^{(i)} = 0,$$

que depende de los datos *solo a través de productos punto*. Esa es la puerta al truco del kernel (sección 7).

Derivación (d): margen suave y la pérdida bisagra

Con datos no separables se permiten holguras $\xi_i \geq 0$:

$$\min_{\vec{w},b,\xi} \ \tfrac{1}{2}\|\vec{w}\|^2 + C\sum_i \xi_i \quad \text{s.a.} \quad y^{(i)}(\vec{w}\cdot x^{(i)} + b) \geq 1 - \xi_i, \quad \xi_i \geq 0.$$

Para $(\vec{w}, b)$ fijos, cada ξ_i se hace lo más chico posible respetando $\xi_i \geq 0$ y $\xi_i \geq 1 - y^{(i)} f(x^{(i)})$, con $f(x) = \vec{w}\cdot x + b$. Entonces $\xi_i = \max\big(0,\, 1 - y^{(i)} f(x^{(i)})\big)$ y el problema es

$$\boxed{\min_{\vec{w},b} \ \tfrac{1}{2}\|\vec{w}\|^2 + C\sum_{i=1}^{m} \max\big(0,\, 1 - y^{(i)}(\vec{w}\cdot x^{(i)} + b)\big)}$$

La **bisagra** vale cero si el punto está bien clasificado y fuera del margen ($yf \geq 1$) y crece linealmente si no. Dividiendo entre mC se ve como "pérdida promedio $+\frac{\lambda}{2}\|\vec{w}\|^2$" con $\lambda = 1/(mC)$: un C grande es poca regularización.

Derivación (e): los dos tipos de vectores de soporte

Agregando multiplicadores $\mu_i \geq 0$ para $\xi_i \geq 0$, la estacionariedad en ξ_i da $C - \alpha_i - \mu_i = 0$, es decir $0 \leq \alpha_i \leq C$. La holgura complementaria da $\mu_i \xi_i = 0$ y $\alpha_i\big[y^{(i)} f(x^{(i)}) - 1 + \xi_i\big] = 0$. Tres casos:

- $\alpha_i = 0$: entonces $\mu_i = C > 0$, así que $\xi_i = 0$ y $y^{(i)} f(x^{(i)}) \geq 1$. El punto está bien clasificado, sobre o fuera del margen, y no influye en $\vec{w}$.
- $0 < \alpha_i < C$: entonces $\mu_i > 0$, así que $\xi_i = 0$; y como $\alpha_i > 0$, $y^{(i)} f(x^{(i)}) = 1$. El punto está **exactamente sobre un plano canónico**. De estos se despeja $b = y^{(i)} - \vec{w}\cdot x^{(i)}$.
- $\alpha_i = C$: entonces $\mu_i = 0$ y $\xi_i \geq 0$ queda libre, con $y^{(i)} f(x^{(i)}) = 1 - \xi_i \leq 1$. El punto **puede** estar dentro del margen pero bien clasificado ($0 < \xi_i < 1$), sobre la frontera ($\xi_i = 1$) o mal clasificado ($\xi_i > 1$). El caso degenerado $\xi_i = 0$ también es posible.

En el margen suave, $2/\|\vec{w}\|$ sigue siendo la distancia entre los planos canónicos; la diferencia es que ahora hay puntos que los cruzan.

Contraejemplo: cuando un supuesto falla

Margen duro sin separabilidad. Si un solo punto de la clase $+1$ cae en medio de la clase -1 y no hay hiperplano que separe, el conjunto factible del problema duro es vacío: no hay solución. Si el punto sí permite separar, pero muy pegado, el margen duro se vuelve angosto solo por ese punto. El margen suave con C moderado sacrifica ese punto (queda con $\alpha_i = C$) a cambio de un margen más ancho. Cuando los datos son separables y $C \to \infty$, la solución suave se acerca a la dura.

¿Qué pasa si...?

...bajo C? Errores baratos: margen ancho, muchos vectores de soporte, más sesgo. **...subo C?** Errores caros: margen angosto que persigue cada punto, menos vectores de soporte, más varianza. Ojo con las convenciones: `SVC` no regulariza b; `LinearSVC` usa `squared_hinge` por omisión y sí regulariza b (en el curso fijamos `loss="hinge"`). El notebook D6 verifica que $2/\|\vec{w}\|$ coincide con la distancia medida entre los planos y que los $\alpha_i < C$ caen sobre ellos ($|y^{(i)} f(x^{(i)}) - 1| < 10^{-3}$).

7. El truco del kernel, a mano

Recuerden (Mód I y demostración 6)

- Producto punto y su expansión: $(a+b+c)^2 = a^2+b^2+c^2+2ab+2ac+2bc$.
- Un mapeo de características $\phi : \mathbb{R}^n \to \mathbb{R}^N$ lleva cada punto a otro espacio.
- El dual del SVM solo usa productos punto $x^{(i)} \cdot x^{(k)}$, y la predicción es $f(x) = \sum_i \alpha_i y^{(i)} (x^{(i)} \cdot x) + b$.

Supuestos

- El algoritmo usa los datos solo a través de productos punto (SVM dual, regresión ridge en forma dual, PCA de kernel).
- $K(x,z)$ es un kernel válido: simétrico y con matriz de Gram $K_{ik} = K(x^{(i)}, x^{(k)})$ semidefinida positiva para cualquier conjunto de puntos (condición de Mercer). Esto garantiza que existe ϕ con $K(x,z) = \phi(x) \cdot \phi(z)$.

Derivación (a): el kernel polinomial de grado 2 en $\mathbb{R}^2$

Sean $x = (x_1, x_2)$ y $z = (z_1, z_2)$. Expandiendo,

$$\begin{aligned}(x \cdot z + 1)^2 &= (x_1 z_1 + x_2 z_2 + 1)^2 \\ &= x_1^2 z_1^2 + x_2^2 z_2^2 + 1 + 2x_1 z_1 x_2 z_2 + 2x_1 z_1 + 2x_2 z_2 \\ &= \underbrace{(x_1^2,\ x_2^2,\ \sqrt{2}x_1 x_2,\ \sqrt{2}x_1,\ \sqrt{2}x_2,\ 1)}_{\phi(x)} \cdot \underbrace{(z_1^2,\ z_2^2,\ \sqrt{2}z_1 z_2,\ \sqrt{2}z_1,\ \sqrt{2}z_2,\ 1)}_{\phi(z)}.\end{aligned}$$

Entonces $K(x,z) = (x \cdot z + 1)^2 = \phi(x) \cdot \phi(z)$ con $\phi : \mathbb{R}^2 \to \mathbb{R}^6$. El $\sqrt{2}$ hace falta para que los términos cruzados salgan con coeficiente 2.

Con números. $x = (1,2)$, $z = (3,-1)$. Por la izquierda: $x \cdot z = 3 - 2 = 1$ y $K = (1+1)^2 = 4$. Por la derecha: $\phi(x) = (1, 4, 2\sqrt{2}, \sqrt{2}, 2\sqrt{2}, 1)$, $\phi(z) = (9, 1, -3\sqrt{2}, 3\sqrt{2}, -\sqrt{2}, 1)$ y $\phi(x) \cdot \phi(z) = 9 + 4 - 12 + 6 - 4 + 1 = 4$. ✓

El ahorro. Calcular K cuesta un producto punto en $\mathbb{R}^n$ más una potencia. Construir ϕ explícitamente para grado d requiere $\binom{n+d}{d}$ coordenadas: con $n = 100$ y $d = 3$ son 176 851. El truco es reemplazar cada $x^{(i)} \cdot x^{(k)}$ del dual por $K(x^{(i)}, x^{(k)})$ sin construir ϕ nunca.

Derivación (b): elevar para separar

En una dimensión, la clase $+1$ en $|x| < 1$ y la -1 en $|x| > 1$ no se separan con un umbral. Con $\phi(x) = (x, x^2)$ los puntos viven sobre la parábola $x_2 = x_1^2$ y la recta horizontal $x_2 = 1$ los separa. En el espacio original, esa recta es la frontera $\{x : x^2 = 1\} = \{-1, 1\}$: lineal arriba, no lineal abajo.

Derivación (c): el kernel RBF y la intuición de γ

$K(x, z) = \exp(-\gamma\|x - z\|^2)$ con $\gamma > 0$. En una dimensión,

$$e^{-\gamma(x-z)^2} = e^{-\gamma x^2} e^{-\gamma z^2} e^{2\gamma xz} = \sum_{k=0}^{\infty} \left(e^{-\gamma x^2} \sqrt{\tfrac{(2\gamma)^k}{k!}}\, x^k\right)\left(e^{-\gamma z^2} \sqrt{\tfrac{(2\gamma)^k}{k!}}\, z^k\right),$$

usando la serie $e^u = \sum_k u^k/k!$ con $u = 2\gamma xz$. El mapeo ϕ tiene *infinitas* coordenadas, $\phi_k(x) = e^{-\gamma x^2}\sqrt{(2\gamma)^k/k!}\, x^k$, y aun así K se calcula en una línea.

Qué controla γ. $K(x, z)$ es una similitud: vale 1 si $x = z$ y decae con la distancia; a distancia $1/\sqrt{\gamma}$ ya vale $e^{-1} \approx 0.37$. La predicción $f(x) = \sum_i \alpha_i y^{(i)} K(x^{(i)}, x) + b$ es una suma de "campanas" centradas en los vectores de soporte, de radio aproximado $1/\sqrt{\gamma}$.

- γ **grande**: campanas angostas. Cada punto influye solo en su vecindad, la frontera rodea puntos individuales (sobreajuste). En el límite $\gamma \to \infty$ la matriz de Gram tiende a la identidad (para puntos distintos) y cualquier etiquetado se puede separar.
- γ **chico**: campanas anchas. Como $K \approx 1 - \gamma\|x - z\|^2$ cuando $\gamma\|x - z\|^2 \ll 1$, todo se parece a todo y la frontera es muy suave (subajuste).

Relación con el ancho de una gaussiana: $\gamma = 1/(2s^2)$. En scikit-learn, `gamma="scale"` usa $\gamma = 1/(n \cdot \mathrm{Var}(X))$.

Contraejemplo: cuando un supuesto falla

No cualquier fórmula es un kernel. Tomen $K(x, z) = x \cdot z - 1$. Para $x = z = \vec{0}$ da $K(\vec{0}, \vec{0}) = -1$. Si existiera ϕ con $K = \phi \cdot \phi$, tendríamos $\|\phi(\vec{0})\|^2 = -1 < 0$, imposible. Con un "kernel" así la matriz de Gram puede tener eigenvalores negativos, el dual deja de ser convexo y el optimizador puede no converger o dar resultados sin sentido.

¿Qué pasa si...?

...subo γ en el Lab 4? La exactitud de entrenamiento sube hasta casi 100 % y la de validación cae: sobreajuste. γ y C interactúan (los dos controlan complejidad), así que se buscan juntos en una rejilla logarítmica. Como RBF usa distancias, estandarizar las variables es obligatorio: una variable en metros y otra en kilómetros dejarían a la segunda sin voz. El notebook D7 verifica $(x \cdot z + 1)^2 = \phi(x) \cdot \phi(z)$ en 1000 pares aleatorios y mueve γ para ver la frontera.

8. Descenso de gradiente: regímenes de α y escalamiento

Recuerden (Mód III y Mód IV)

- (Mód III) Gradiente, hessiana y aproximación de Taylor de segundo orden: $J(\theta + \vec{h}) \approx J(\theta) + \nabla J^\top \vec{h} + \frac{1}{2}\vec{h}^\top \nabla^2 J\, \vec{h}$.
- (Mód III) Una matriz simétrica se diagonaliza con una base ortonormal: $H = Q\Lambda Q^\top$.
- (Mód IV) Estandarizar: $x' = (x - \bar{x})/s$, con s la desviación estándar.

Supuestos

- Costo **cuadrático**: $J(\theta) = J^* + \frac{1}{2}(\theta - \theta^*)^\top H(\theta - \theta^*)$ con H simétrica definida positiva. La regresión lineal con $J = \frac{1}{2m}\|\tilde{X}\theta - \vec{y}\|^2$ es de esta forma con $H = \frac{1}{m}\tilde{X}^\top\tilde{X}$, si $\tilde{X} = [X\ \vec{1}]$ tiene rango completo.
- Tasa de aprendizaje $\alpha > 0$ constante y gradiente exacto (lote completo).
- Eigenvalores de H: $0 < \lambda_{\text{mín}} \leq \cdots \leq \lambda_{\text{máx}}$. (Estos λ son eigenvalores, no el hiperparámetro de regularización.)

Derivación

Paso 1: la iteración del error. $\nabla J(\theta) = H(\theta - \theta^*)$. Con $\theta_{k+1} = \theta_k - \alpha\nabla J(\theta_k)$ y el error $e_k = \theta_k - \theta^*$:

$$e_{k+1} = e_k - \alpha H e_k = (I - \alpha H)\, e_k \quad \Longrightarrow \quad e_k = (I - \alpha H)^k e_0.$$

Paso 2: separar por direcciones. Con $H = Q\Lambda Q^\top$ y $c_k = Q^\top e_k$ (el error en la base de eigenvectores), $I - \alpha H = Q(I - \alpha\Lambda)Q^\top$, de modo que cada coordenada evoluciona sola:

$$c_{k+1,j} = (1 - \alpha\lambda_j)\, c_{k,j} \quad \Longrightarrow \quad c_{k,j} = (1 - \alpha\lambda_j)^k c_{0,j}.$$

Cada dirección es una parábola de una dimensión con curvatura λ_j.

Paso 3: los regímenes. Para una dirección con curvatura λ, el factor es $\rho = 1 - \alpha\lambda$:

$\alpha\lambda$	factor ρ	comportamiento
$0 < \alpha\lambda < 1$	$0 < \rho < 1$	converge sin cambiar de lado (monótono)
$\alpha\lambda = 1$	$\rho = 0$	llega en un paso
$1 < \alpha\lambda < 2$	$-1 < \rho < 0$	converge **oscilando** (salta de un lado al otro)
$\alpha\lambda = 2$	$\rho = -1$	oscila para siempre con la misma amplitud
$\alpha\lambda > 2$	$\rho < -1$	**diverge** oscilando

GD converge desde cualquier θ_0 si y solo si $|1 - \alpha\lambda_j| < 1$ para toda j, es decir,

$$\boxed{0 < \alpha < \frac{2}{\lambda_{\text{máx}}}}$$

La dirección más curva pone el límite.

Paso 4: la mejor tasa y el número de condición. La rapidez la marca $\max_j |1 - \alpha\lambda_j| = \max\left(|1 - \alpha\lambda_{\text{mín}}|, |1 - \alpha\lambda_{\text{máx}}|\right)$. Se minimiza cuando $1 - \alpha\lambda_{\text{mín}} = \alpha\lambda_{\text{máx}} - 1$, es decir, en $\alpha^* = 2/(\lambda_{\text{mín}} + \lambda_{\text{máx}})$, y ahí

$$\rho^* = \frac{\lambda_{\text{máx}} - \lambda_{\text{mín}}}{\lambda_{\text{máx}} + \lambda_{\text{mín}}} = \frac{\kappa - 1}{\kappa + 1}, \qquad \kappa = \frac{\lambda_{\text{máx}}}{\lambda_{\text{mín}}}.$$

Si κ es enorme, $\rho^* \approx 1$ y GD avanza a paso de tortuga en la dirección plana, porque α está limitado por la dirección empinada.

Paso 5: el escalamiento cambia la forma del tazón. Para regresión lineal con una variable, $\theta = (w, b)$ y

$$H = \frac{1}{m}\sum_i \begin{pmatrix} (x^{(i)})^2 & x^{(i)} \\ x^{(i)} & 1 \end{pmatrix} = \begin{pmatrix} \overline{x^2} & \bar{x} \\ \bar{x} & 1 \end{pmatrix}.$$

Con tamaños de casa en pies cuadrados ($\bar{x} \approx 2000$, $\overline{x^2} \approx 4.2 \times 10^6$), $\lambda_{\text{máx}} \approx 4.2 \times 10^6$ y $\lambda_{\text{mín}}$ es pequeñísimo: el tazón es una trinchera alargada, α tiene que ser menor que $\sim 5 \times 10^{-7}$ y b casi no se mueve. Tras estandarizar con la desviación estándar poblacional, $\bar{x}' = 0$ y $\overline{x'^2} = 1$, así que $H = I$: $\kappa = 1$, curvas de nivel circulares, y con $\alpha = 1$ GD llega en un paso.

Paso 6: fuera de lo cuadrático. Si J no es cuadrática pero su gradiente es L-Lipschitz (la curvatura nunca pasa de L), se cumple $J(\theta - \alpha\nabla J) \leq J(\theta) - \alpha\big(1 - \frac{\alpha L}{2}\big)\|\nabla J(\theta)\|^2$, así que cada paso baja el costo si $0 < \alpha < 2/L$. Cerca de un mínimo, $L \approx \lambda_{\text{máx}}$ de la hessiana local, y se recupera la cota del paso 3.

Contraejemplo: cuando un supuesto falla

Curvatura sin cota. Con $J(w) = w^4$ la hessiana es $12w^2$, que crece sin límite. La iteración es $w_{k+1} = w_k(1 - 4\alpha w_k^2)$. Si $4\alpha w_0^2 > 2$, entonces $|1 - 4\alpha w_0^2| > 1$, $|w_1| > |w_0|$, la curvatura crece más y la sucesión diverge. Para cualquier $\alpha > 0$ fijo hay puntos de inicio desde donde GD explota; no existe un α "seguro" global. En redes neuronales esto se ve como pérdidas que de pronto valen `NaN`.

¿Qué pasa si...?

...en el Lab 1 el costo sube y luego da `NaN`? Probablemente $\alpha > 2/\lambda_{\text{máx}}$. Antes de bajar α, revisen si las variables están escaladas: la hora del día (0 a 23) junto a la temperatura (10 a 35) y un conteo de viajes de la hora anterior (0 a 300) dan un κ grande. **...agrego regularización?** Ridge suma λ/m a todos los eigenvalores de la hessiana, lo que baja κ y mejora la convergencia. El notebook D8 muestra los tres regímenes en una parábola, compara α con $2/\lambda_{\text{máx}}$ calculado con `np.linalg.eigvalsh`, y dibuja las trayectorias antes y después de estandarizar.

Referencias

- Boyd, S., y Vandenberghe, L. (2004). *Convex Optimization*. Cambridge University Press. (Cap. 5: dualidad y KKT; cap. 9: descenso de gradiente.)
- Hastie, T., Tibshirani, R., y Friedman, J. (2009). *The Elements of Statistical Learning* (2.ª ed.). Springer. (Sec. 3.4.1: Ridge y SVD; cap. 12: SVM.)
- Mitchell, T. (1997). *Machine Learning*. McGraw-Hill. (Cap. 3: árboles y ganancia de información.)
- Ng, A. *CS229 Lecture Notes*. Stanford University. (Notas 1: mínimos cuadrados, MLE y logística; notas 3: SVM y kernels.)
- Raileanu, L. E., y Stoffel, K. (2004). Theoretical comparison between the Gini index and information gain criteria. *Annals of Mathematics and Artificial Intelligence*, 41, 77–93.
- Strang, G. (2016). *Introduction to Linear Algebra* (5.ª ed.). Wellesley-Cambridge Press. (Cap. 4: proyecciones y mínimos cuadrados.)