DAMMG | FACULTAD DE CIENCIAS, UNAM | 1ª EMISIÓN

Facultad de Ciencias UNAM

SECRETARÍA DE EDUCACIÓN ABIERTA Y CONTINUA
FACULTAD DE CIENCIAS

DIPLOMADO EN APRENDIZAJE DE MÁQUINA Y MODELOS GENERATIVOS

APRENDIZAJE SUPERVISADO

DAMMG Módulo VI: Aprendizaje supervisado | Sesión 1, VI.1 y VI.2 | vie 30 oct 2026, 16:00 a 21:00

Mtro. Hesus García Cobos

QUIÉN SOY



Hesus García Cobos

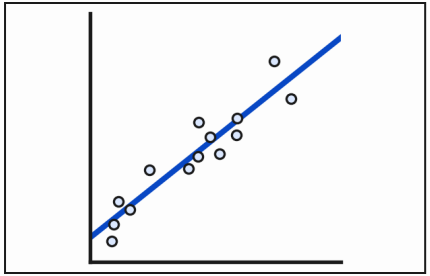
- Diseño cursos de IA y aprendizaje de máquina. Hoy en DeepLearning.AI, el equipo de Andrew Ng; antes di clases en el Tec de Monterrey.
- No soy la persona más técnica del cuarto. Lo mío es entender cómo funcionan las cosas y luego explicarlas para que otros también las entiendan.
- Dato inútil: soy el único Hesus que conoces, y probablemente el único que conocerás.

GitHub: github.com/HesusG. LinkedIn: linkedin.com/in/hgcobos

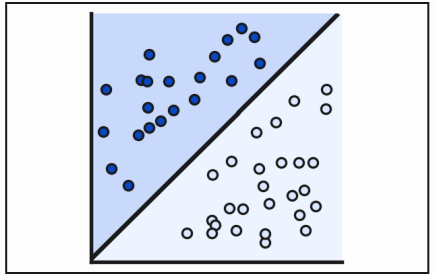
QUÉ VAMOS A VER

Sesión	Cuándo	Temas
S1	vie 30 oct, 16 a 21 h	VI.1 Aprendizaje inductivo y deductivo. VI.2 Regresión lineal y polinomial, y sus métricas
S2	sáb 31 oct, 9 a 14 h	VI.2 Características derivadas, sobreajuste y Ridge. VI.3 Regresión logística
S3	vie 6 nov, 16 a 21 h	VI.3 Evaluar clasificadores. VI.4 Árboles de decisión y ensambles
S4	sáb 7 nov, 9 a 14 h	VI.5 Máquinas de soporte vectorial. Integración y proyecto

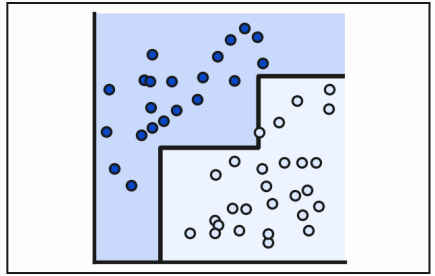
Cada modelo dibuja una forma distinta. Elegir modelo es elegir la forma que mejor le queda a los datos.



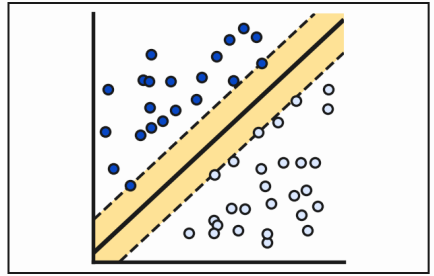
S1 Regresión lineal: una recta que pasa entre los puntos



S2 Regresión logística: una línea recta que separa dos grupos



S3 Árbol de decisión: escalones, preguntas de sí o no



S4 SVM: la línea que deja más espacio libre a los dos lados (la franja amarilla)

CÓMO VAMOS A TRABAJAR EN ZOOM

Las señales

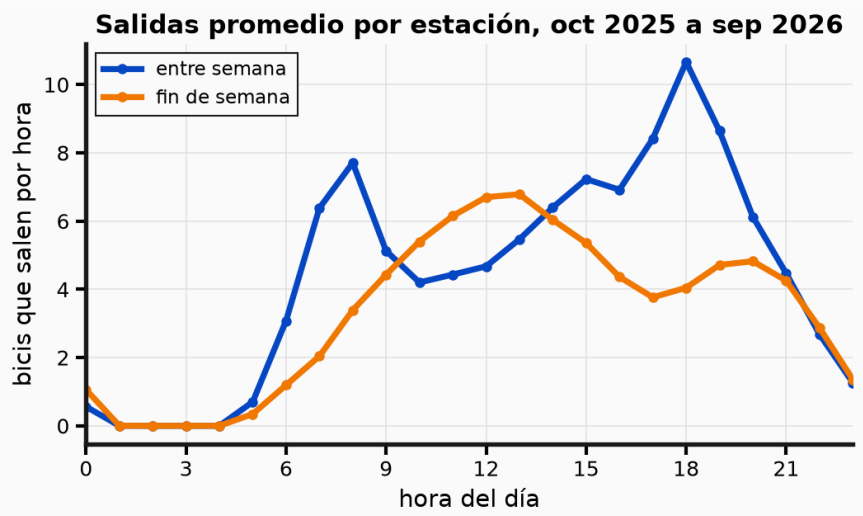
- ✅ reacción: **terminé** o **voy bien**
- ✋ levantar la mano: **tengo una pregunta** o **necesito ayuda**
- **Chat waterfall**: escribe tu respuesta y **no la envíes** hasta que diga "¡ya!"
- **Mentimeter**: entra a menti.com con el código **6445 2630**

Cada bloque

1. Un problema real (MiBici, Guadalajara)
2. Recordamos lo que ya vieron en otros módulos
3. Construimos la idea paso a paso: fórmula, palabras y código
4. Ustedes predicen antes de ver el resultado
5. Lo programamos en Colab

Probemos: manden un ✅ y escriban en el chat de dónde se conectan. No lo envíen hasta que diga "¡ya!".

LOS DATOS DE TODO EL MÓDULO: MIBICI



Estación	Cuándo	Salieron	Hace una semana
51	lun 26 ene, 7 a.m.	28	19
51	lun 26 ene, 8 a.m.	34	40

- **MiBici**: las bicis públicas de Guadalajara. Usamos las **40 estaciones** más activas durante **un año**, de octubre de 2025 a septiembre de 2026.
- Cada fila es **una estación en una hora**: cuántas bicis salieron y llegaron, qué día era y cuántas salieron hace un día y hace una semana.
- Ya viene **limpio** y **partido** por fechas: de octubre a junio para entrenar, julio para validar, agosto y septiembre para la prueba final. Cómo se limpió, en una lectura corta: los datos de MiBici, en corto.
- No hay que bajar nada: la primera celda de cada notebook lo descarga sola.

CÓMO SE EVALÚA

Qué	Peso	Cómo	Vence
Labs L1 a L4	30 %	Se hacen **en clase, todos al mismo ritmo**: yo corro, ustedes corren, y en cada *Ahora tú* todos tenemos los mismos minutos. Lo que falte, en casa	L1 y L2: dom 8 nov. L3 y L4: dom 15 nov
Tareas T1 y T2	40 %	**Individuales, a tu ritmo**, unas 2 h cada una: escoger, interpretar y a veces una función chica. Si sobra tiempo en clase, la empiezas ahí	T1: dom 8 nov. T2: dom 15 nov
Proyecto final	30 %	**En equipos de 2 a 3**, con MiBici: son analistas y responden preguntas de negocio. Notebook y reporte de 2 páginas	dom 22 nov

Las pruebas las corro yo: escribe los nombres de variables y funciones, y las fórmulas que se piden, **exactamente** como dice el notebook. Todo se entrega en Moodle a las 23:59, con **tolerancia sin penalización hasta el miércoles siguiente**. Asistencia mínima: 80 %. Las sesiones no se graban.

EL PROYECTO: ANALISTAS DE MIBICI

En equipos de 2 o 3, son el equipo de datos de MiBici. Responden **preguntas de negocio** con los modelos del módulo.

1. **Mover bicis de noche.** ¿Cuántas saldrán mañana a las 8 a.m. en cada estación, y con qué error?
2. **Alertas con presupuesto.** Con N viajes de camión al día, ¿a qué estaciones mandan alerta?
3. **¿Dónde falla el modelo?** ¿En qué estaciones, horas o días se equivoca más?
4. **¿Qué modelo ponemos en producción?** Comparen al menos tres y recomienden uno.
5. **¿Sigue sirviendo después de vacaciones?** ¿El modelo de junio funciona en agosto y septiembre?

Teoría

T1. Si predicen siempre la misma constante c, demuestren que $\frac{1}{m}\sum_i (c - y^{(i)})^2$ es mínimo cuando $c = \bar{y}$.

Pista: repasen la derivada del Módulo III y el costo J de hoy (bloque B).

T2. Con un presupuesto fijo de k alertas, muestren que $\text{precision} = \frac{TP}{k}$ y que $\text{recall} = \frac{\text{precision} \cdot k}{P}$, con P los desbalances reales. ¿Qué quiere decir para el negocio?

Pista: repasen la matriz de confusión de la sesión 2; las k alertas son TP + FP.

Entregan un notebook y un reporte de 2 páginas, el **dom 22 nov**. Hoy no tienen que hacer nada: cada sesión les da una herramienta para una de estas preguntas.

TODO YA ESTÁ ABIERTO

En el sitio del curso ya está **todo** el material del módulo, con sus fechas:

- Slides y PDF de las 4 sesiones
- Labs L1 a L4, en Colab
- Tareas T1 y T2
- Proyecto final
- Demos para ver a su ritmo

hesusg.github.io/dammg-supervisado

Pueden adelantar lo que quieran: leer la T1, armar su equipo para el proyecto o asomarse a las slides de mañana.

En Moodle se entrega todo. Las actividades de S1 y S2 ya están abiertas; las de S3 y S4 se abren antes de su sesión.

ANTES DE EMPEZAR: ¿QUIÉN ESTÁ AQUÍ? (6 MIN)

¿QUÉ PASA SI…?

menti.com, código 6445 2630

1. ¿De qué carrera vienes y en qué trabajas? (nube de palabras)

¿QUÉ PASA SI…?

menti.com, código 6445 2630

2. ¿Qué tanto te suena cada cosa? Del 1 (nada) al 5 (lo uso en el trabajo)

A. Python
B. NumPy (arreglos, np.mean)
C. Colab o Jupyter
D. scikit-learn: fit y predict
E. Descenso de gradiente
F. Mínimos cuadrados
G. Máxima verosimilitud

BLOQUE A | VI.1 Aprendizaje inductivo y deductivo

DEDUCIR E INDUCIR

APRENDIZAJE DEDUCTIVO E INDUCTIVO

En machine learning hay dos maneras de llegar a una respuesta.

Deductivo

Conocemos la regla y deducimos la respuesta.

"El kilo cuesta 25 pesos", así que 7 kilos cuestan 175. Es segura si la regla es cierta.

Aplicar la regla es *inferencia* deductiva. *Aprendizaje* deductivo es cuando un sistema reorganiza reglas que ya tiene para usarlas mejor, como un sistema experto que junta dos reglas en una.

Inductivo

Solo tenemos ejemplos con su respuesta y proponemos la regla.

Con tickets de compras pasadas, estimamos cuánto cuesta el kilo. Puede fallar.

El aprendizaje supervisado es inductivo: entrenar con ejemplos, predecir y evaluar. Hoy veremos por qué casi todo se aprende así, cómo medimos si aprendió y cuándo podemos confiar.

DOS MANERAS DE SABER ALGO



Deducir

Tienes la receta. Sigues los pasos y sabes cómo va a salir el pastel, sin probarlo.



Inducir

No tienes la receta. Probaste muchos pasteles y adivinas qué llevan.

Deducir: de la regla a los casos. Inducir: de los casos a la regla.

EL EJEMPLO DE TODO EL BLOQUE

¿CUÁNTO PAGARÍAS POR 7 KILOS?

La tortillería no tiene letrero. Solo tienes tres tickets: 1 kilo por 25 pesos, 2 kilos por 51 y 3 kilos por 74.

CON LETRERO: APLICAR UNA REGLA

EN MATEMÁTICAS	EN PALABRAS
$A \Rightarrow B$	Una regla: si pasa A, entonces pasa B. La flecha doble se lee "implica".
A	Me dicen que pasó A.
$A \Rightarrow B,\ \ A \ \vdash \ B$	Entonces se sigue B. $\vdash$ se lee "se deduce": separa lo que sabes de lo que concluyes. ⇒ va dentro de la regla.
$y = 25x,\ \ x = 3 \ \vdash \ y = 75$	El letrero dice 25 pesos el kilo; llevas 3 kilos; pagas 75.

La conclusión es segura si el letrero aplica a tu compra. Y no dice nada que no estuviera ya en el letrero.

SIN LETRERO: PROPONER UNA REGLA

EN MATEMÁTICAS	EN PALABRAS
$(1, 25),\ (2, 51),\ (3, 74)$	Tres tickets: kilos y lo que se pagó.
$h(x) = 25x$	Propongo una regla: 25 pesos por kilo.
$h(1), h(2), h(3) = 25,\ 50,\ 75$	No reproduce los tickets exacto: se equivoca por 0, 1 y 1 peso. Se **aproxima**.
$h(7) = 25 \cdot 7 = 175$	La uso para un caso que no he visto: 7 kilos.

Nadie me dio la regla: la propuse con los tickets. Puede fallar. Eso es inducir.

¿QUÉ PASA SI…?

menti.com, código 6445 2630

3. Del 1 al 5, ¿qué tan seguro estás de que mañana sale el sol? ¿Por qué no 5?

ACTIVIDAD EN SALAS: ¿DEDUCIR O INDUCIR?

SALAS DE ZOOM salas de 3 o 4 TIEMPO **10:00**

1. Abran la hoja de trabajo (enlace en el chat).
2. Repártanse: quien lee, quien duda, quien escribe.
3. En cada caso decidan: ¿es deducir o inducir?
4. Fíjense hacia dónde va la flecha: de la regla al caso o del caso a la regla.

La hoja:

https://hesusg.github.io/dammg-supervisado/s1/handouts/vi1-deducir-inducir.html

Al volver, quien escribe manda una sola línea al chat cuando diga "¡ya!":

```
5a: __ 5b: __ 6a: __ 6b: __
```

LO QUE SALIÓ EN LAS SALAS

- **La inducción matemática es deducción.** Demuestra que vale para toda n; no puede fallar. El nombre engaña.
- **Deducir es seguro si la regla es cierta.** La receta y la fórmula del libro también salieron, alguna vez, de casos medidos.
- **En el filtro de spam pasan las dos.** Entrenar es inducir; ya entrenado, marcar un correo es aplicar la regla. Lo que se aprende está en la primera parte, y por eso sus respuestas no son seguras: la regla salió de ejemplos.

Aprendizaje supervisado es inducir una regla con ejemplos. Ya aprendida, usarla es aplicar la regla.

LOS SISTEMAS EXPERTOS: IA CON REGLAS ESCRITAS



En las tortillas pudimos escribir una regla. En los años 70 y 80, buena parte de la IA hacía eso: un experto dictaba sus reglas y alguien las programaba. Había **pocos datos** y las computadoras eran **lentas**.

MYCIN (1976) diagnosticaba infecciones con unas 600 reglas "SI... ENTONCES":

> SI la infección es en la sangre Y la bacteria es gramnegativa, ENTONCES sospecha de tal bacteria.

La computadora no aprendía nada: aplicaba lo que el experto ya sabía.

POR QUÉ NO ALCANZÓ



- **No se pueden escribir todas las reglas.** ¿Qué regla dice si un correo es spam o si una foto tiene un gato?
- **El mundo cambia.** Cada regla nueva hay que escribirla y mantenerla a mano.
- **Llegaron los datos y el cómputo.** Con millones de ejemplos, que la computadora proponga la regla se volvió práctico.

Hoy conviven: reglas escritas donde las tenemos, aprendizaje donde no.

LO QUE VAMOS A ESTUDIAR

APRENDIZAJE SUPERVISADO

Aprende de ejemplos que ya traen la respuesta, como un maestro que corrige cada tarea.

Inducir: con los ejemplos $\{(x^{(i)}, y^{(i)})\}_{i=1}^{m}$ escogemos una regla h.

Generalizar: que acierte en lo que nunca vio, $h(x_{\text{nuevo}}) \approx y_{\text{nuevo}}$.

En una frase: aproximar una función a partir de ejemplos. El problema de fondo es generalizar.

CUÁNDO CONVIENE APRENDER DE EJEMPLOS

Hay un patrón

Los precios no son al azar: más kilos, más pesos.

No tienes la regla

Nadie te dio el letrero, o es demasiado complicado escribirla.

Tienes datos

Los tickets. En MiBici, un año de viajes por hora.

Si tienes el letrero, no hace falta aprender: aplicas la regla.

¿QUÉ QUIERE DECIR QUE APRENDA?

Una definición clásica: un programa **aprende** si mejora en una **tarea**, gracias a la **experiencia**, según una **medida de desempeño**.

Tarea

Decir cuánto cuestan unos kilos de tortillas.

Experiencia

Los tickets que ya tenemos.

Desempeño

Por cuántos pesos se equivoca con compras nuevas.

Sin medida de desempeño no hay forma de decir si aprendió. Por eso hoy medimos el error en pesos.

ENTRADA, RESPUESTA Y PREDICCIÓN

$$D = \{(x^{(i)}, y^{(i)})\}_{i=1}^{m}$$

m ejemplos; cada uno con una **entrada** $x^{(i)}$ y su **respuesta observada** $y^{(i)}$. El (i) es el número de fila, no una potencia.

$$\hat{y} = h(x)$$

La regla h recibe una entrada y regresa una **predicción** $\hat{y}$ ("ye gorro"). h es la regla que guardas; $\hat{y}$ es lo que responde para una entrada.

i	x: kilos	y: pagado	$\hat{y} = 25x$	error $\hat{y} - y$
1	1	25	25	0
2	2	51	50	-1
3	3	74	75	1

Aquí $m = 3$. En MiBici, $m = 254{,}440$: 40 estaciones $\times$ 6,361 horas (del 8 de octubre al 30 de junio).

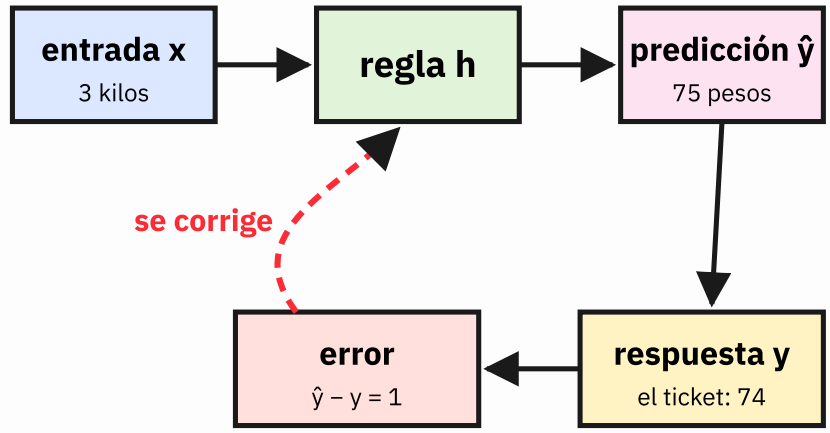
EL MAESTRO QUE CORRIGE

$$\hat{y} = h(x)$$

h recibe una entrada y regresa una **predicción** $\hat{y}$.

Aprender es **escoger** h para que $\hat{y}$ se parezca a y en los ejemplos.

Por eso se llama **supervisado**: la respuesta y es el maestro que dice cuánto se equivocó el modelo.



CÓMO MEDIMOS EL ERROR

$$E(h) = \frac{1}{m} \sum_{i=1}^{m} \left| \hat{y}^{(i)} - y^{(i)} \right|$$

EN MATEMÁTICAS	EN PALABRAS
$(25 - 25) + (50 - 51) + (75 - 74)$	Los tres errores de la regla $25x$: lo que predijo menos lo que se pagó, ticket por ticket.
$= 0 + (-1) + 1 = 0$	Si los sumamos con su signo, el −1 y el +1 se anulan y da 0, como si nunca se equivocara. Pero sí se equivocó en dos tickets: por eso hace falta quitarles el signo.
$\lvert 0 \rvert + \lvert -1 \rvert + \lvert 1 \rvert = 2$	Sin signo, pasarse o quedarse corto cuenta igual. Eso hacen las barras.
$\frac{1}{3}(0 + 1 + 1) \approx 0.67$	Dividimos entre los $m = 3$ tickets: en promedio se equivoca por 67 centavos. Es el **error absoluto promedio** (MAE).
$\frac{1}{3}(5 + 1 + 4) \approx 3.33$	La regla $20x + 10$: se equivoca por 3.33 pesos. Gana 25 por kilo, **pero lo medimos con tickets que ya vio.**

¿QUÉ PODEMOS AFIRMAR DE 7 KILOS?

¿QUÉ PASA SI…? menti.com, código 6445 2630

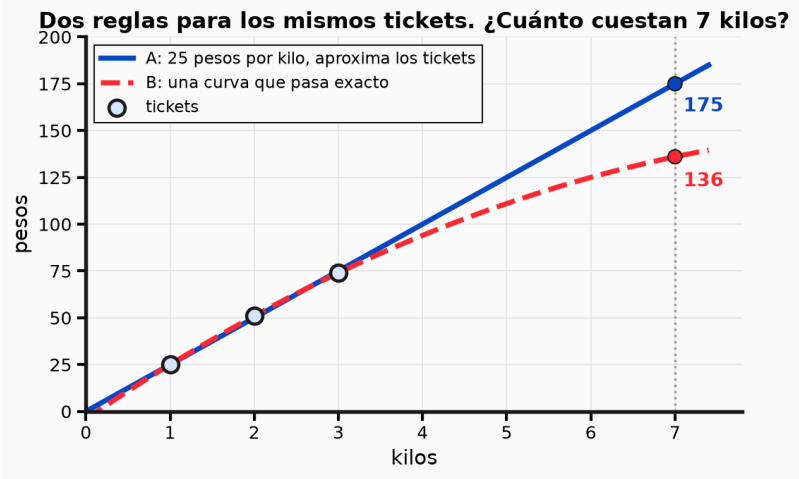
4. Con solo los tickets (1 kg, 25 pesos), (2 kg, 51) y (3 kg, 74), ¿qué podemos afirmar del precio de 7 kg?

A. Seguro es 175 pesos

B. Seguro es 136 pesos

C. Las dos cifras son seguras

D. Ninguna es segura: hace falta suponer algo o más datos



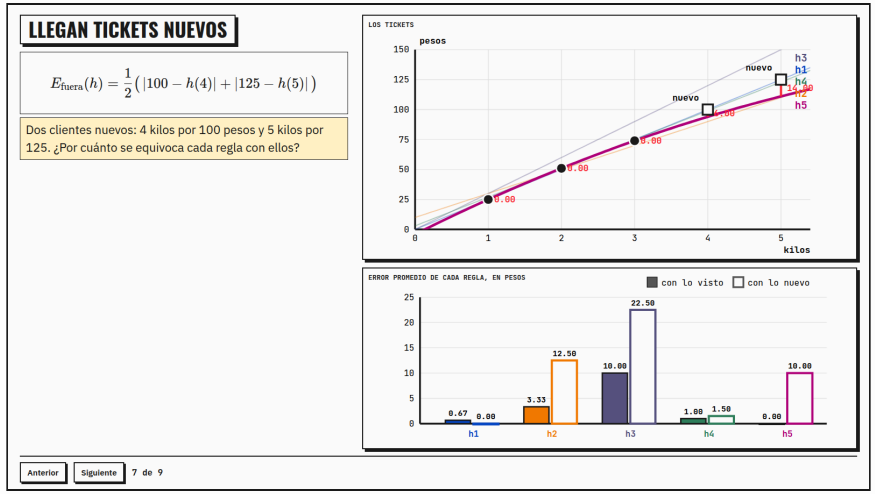
D. Las dos reglas encajan con los tres tickets y no dicen lo mismo de 7 kilos: 175 contra 136. Además, 7 kilos está lejos de lo que vimos (1 a 3): es **extrapolar**. Los tickets no deciden; hay que **suponer** algo.

DEMO: CINCO REGLAS CANDIDATAS

No hay letrero, solo tres tickets. Hay cinco reglas candidatas. ¿Cuál escogemos?

Escogemos la que menos se equivoca con lo visto, y luego llegan clientes nuevos.

Ábranlo y muévanlo ustedes:
hesusg.github.io/dammg-supervisado/widgets/tortillas-induccion.html



AJUSTAR BIEN NO BASTA

Regla	Error con los 3 tickets	Error con 2 clientes nuevos
$h_1(x) = 25x$	0.67	0.00
h_5: la curva exacta	**0.00**	10.00

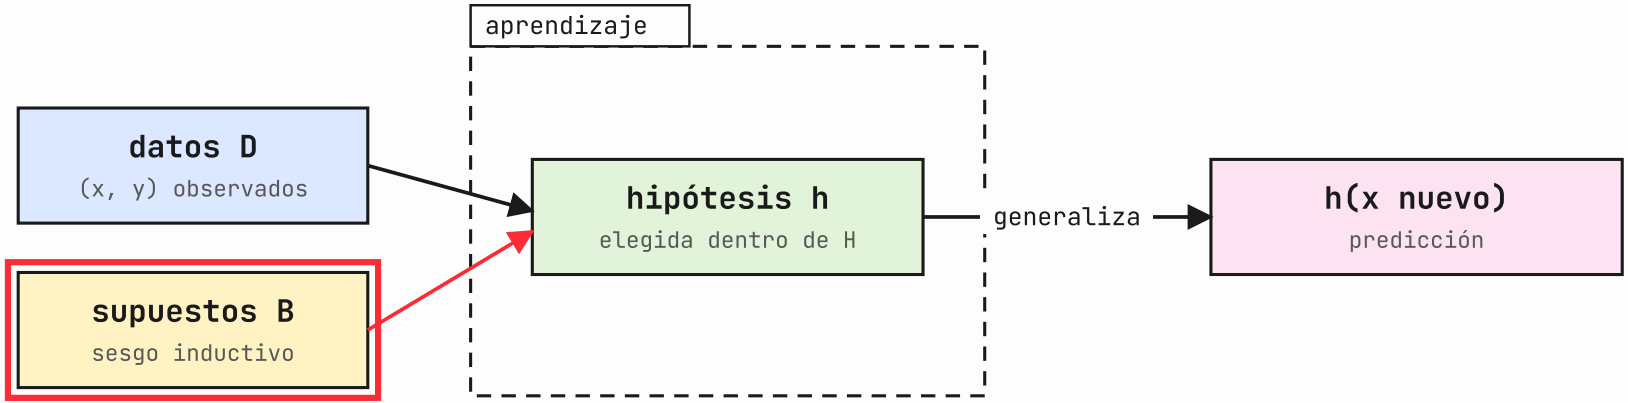
Error promedio en pesos. Clientes nuevos: 4 kilos por 100 y 5 kilos por 125.

h_5 reproduce **exacto** los tres tickets y aun así falla más que h_1 con lo nuevo: 10 pesos contra 0.

Caso extremo: un filtro de spam que solo se aprende de memoria los correos marcados acierta siempre con esos y no sabe qué hacer con uno nuevo.

Lo que importa es generalizar: acertar en lo que no vio. Con dos clientes no queda demostrado; es evidencia.

ESCOGER EXIGE SUPONER



En palabras: los datos solos no deciden. Para predecir un caso nuevo hay que suponer algo. Ese supuesto se llama **sesgo inductivo**. H es el menú de reglas posibles; h es la que escogemos al entrenar.

Tortillas: suponer que el precio es aproximadamente proporcional a los kilos (la regla 25 por kilo) o que hay descuento por volumen (la curva). Los tickets no deciden entre las dos.

DOS SABORES DE SESGO

Restricción

Qué reglas existen en H.

"Solo considero rectas".

Si la verdad no está en H, nunca la encuentras.

Preferencia

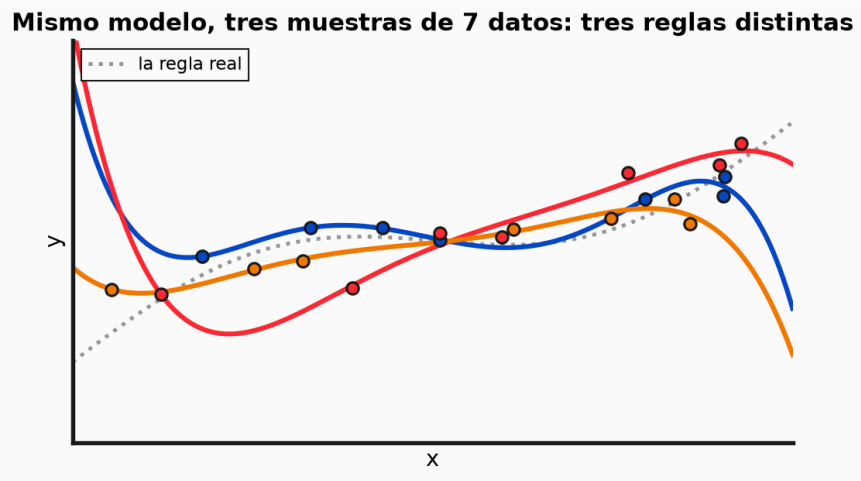
Con cuál me quedo entre las que ajustan.

"Entre todas, la de pesos más chicos" o "el árbol más corto".

La navaja de Ockham, con números.

No Free Lunch: no existe el mejor modelo en general. Promediando sobre todos los problemas posibles, ninguno le gana a otro. Un modelo gana cuando su sesgo **se parece al problema**, como un zapato que le queda a un pie y no a otro.

INDUCIR TIENE SU PRECIO



Con **pocos datos**, lo que aprende el modelo depende mucho de **qué datos le tocaron**.

Aquí, el mismo modelo con tres muestras de 7 datos dibuja tres reglas muy distintas. Ninguna se parece a la real fuera de los puntos.

A eso se le llama **varianza**: el modelo cambia mucho si cambias los datos. Mañana la medimos.

COMBINAR DATOS Y CONOCIMIENTO

Lo que dicen los datos **más** lo que preferimos de antemano:

$$\text{costo} = \underbrace{\text{error con los ejemplos}}_{\text{lo que dicen los datos}} + \lambda \cdot \underbrace{\text{qué tan grandes son los pesos}}_{\text{lo que preferimos}}$$

Primer término: que la regla se equivoque poco con los ejemplos.

Segundo término: una **preferencia** por reglas sencillas. Es la navaja de Ockham: si dos explicaciones funcionan igual de bien, quédate con la más sencilla.

λ decide cuánto pesa la preferencia: con pocos datos, conviene que pese más. Esto se llama **regularización**; la versión de arriba es **Ridge** (a veces "regresión de cresta"; scikit-learn le dice Ridge). La vemos mañana.

Los pesos son los números que ajusta el modelo; en las tortillas, el 25 por kilo. En inglés son *weights*: no son pesos de dinero. La fórmula exacta la vemos mañana.

ENTRENAR, ESCOGER Y EVALUAR

Entrenar

Ajustar la regla con ejemplos.

Tortillas: los 3 tickets.

MiBici: de octubre a junio.

Escoger

Comparar reglas con datos que no se usaron al entrenar.

MiBici: julio.

Evaluar

Una sola vez, al final, con datos que nadie tocó.

Tortillas: los 2 clientes nuevos.

MiBici: agosto y septiembre.

Es un solo año partido en tres por fecha: el futuro no se ve antes.

¿CUÁNDO PODEMOS CONFIAR?

El error con lo nuevo se parece al error con lo visto si se cumplen tres cosas.

`Lo nuevo viene del mismo lugar`

Tortillas: el cliente nuevo compra en la misma tortillería.

MiBici: predecimos las mismas 40 estaciones.

`Nada cambió`

Tortillas: si sube el precio de la masa, los tickets viejos ya no sirven.

MiBici: vacaciones, lluvia, una estación nueva al lado.

`Hay ejemplos suficientes para el menú`

Tortillas: con 3 tickets, escoger entre 5 reglas es razonable; entre todas las curvas no, porque siempre hay una que pasa exacto.

MiBici: 254 mil filas permiten un menú más grande.

Aun así no es seguro, solo muy probable. Por eso siempre guardamos datos para comprobar.

LO QUE HAY QUE FIJAR PARA HABLAR DE APRENDER

$$E_{\text{dentro}}(h)$$

$$E_{\text{fuera}}(h)$$

$$\left| E_{\text{fuera}}(h) - E_{\text{dentro}}(h) \right| \leq \varepsilon$$

$$P\left(\left| E_{\text{fuera}}(h) - E_{\text{dentro}}(h) \right| \leq \varepsilon \right) \geq 1 - \delta$$

Letra	Qué es	En las tortillas
E_{dentro}, E_{fuera}	error con lo que vio, error con lo nuevo	0.67 con los tickets; 0 con los 2 clientes
m	cuántos ejemplos	3 tickets
H	el menú de reglas	las 5 del widget
ε	cuánta diferencia tolero	1 peso
δ	probabilidad de que los datos me engañen	5 de cada 100

Más reglas en H o una ε más chica piden más ejemplos m.

DE LAS TORTILLAS A MIBICI

El mismo esquema, con los datos del módulo:

$$\{(x^{(i)}, y^{(i)})\}_{i=1}^{m}$$

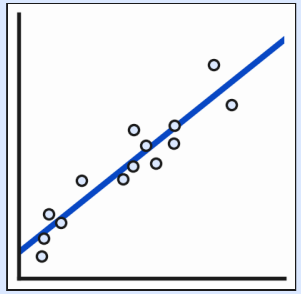
- $x^{(i)}$: la **entrada** del ejemplo número i (lo que sabemos); puede ser varias columnas a la vez
- $y^{(i)}$: su **respuesta correcta** (lo que queremos predecir)
- m: **cuántos** ejemplos tenemos

i	x: hora y día	x: hace una semana	y: salieron
1	lun 7 a.m.	19	28
2	lun 8 a.m.	40	34
3	mar 7 a.m.	28	28
4	mar 8 a.m.	29	34

Estación 51 de MiBici, 26 y 27 de enero de 2026. Aquí $m = 4$; en el lab, m ronda los 254 mil.

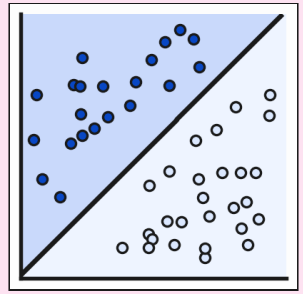
DOS TIPOS DE RESPUESTA

Regresión: y es un número



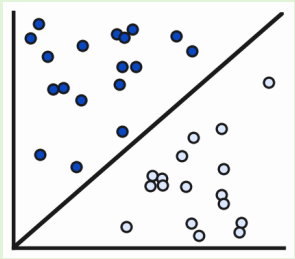
¿Cuántas bicis van a salir a las 8 a.m.? $y \in \mathbb{R}$

Clasificación: y es una clase



¿Habrá un desbalance fuerte entre salidas y llegadas? $y \in \{0, 1\}$

TRES MANERAS DE APRENDER

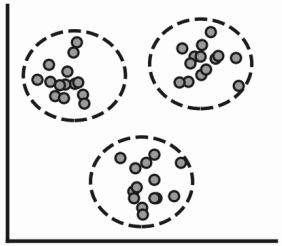


Supervisado

Los datos **traen la respuesta**.

MiBici: predecir cuántas bicis salen.

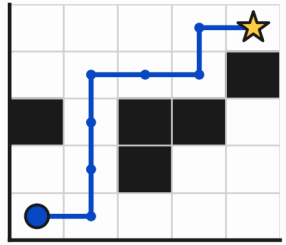
`este módulo`



No supervisado

Sin respuesta: busca grupos o patrones.

MiBici: juntar estaciones que se usan parecido.

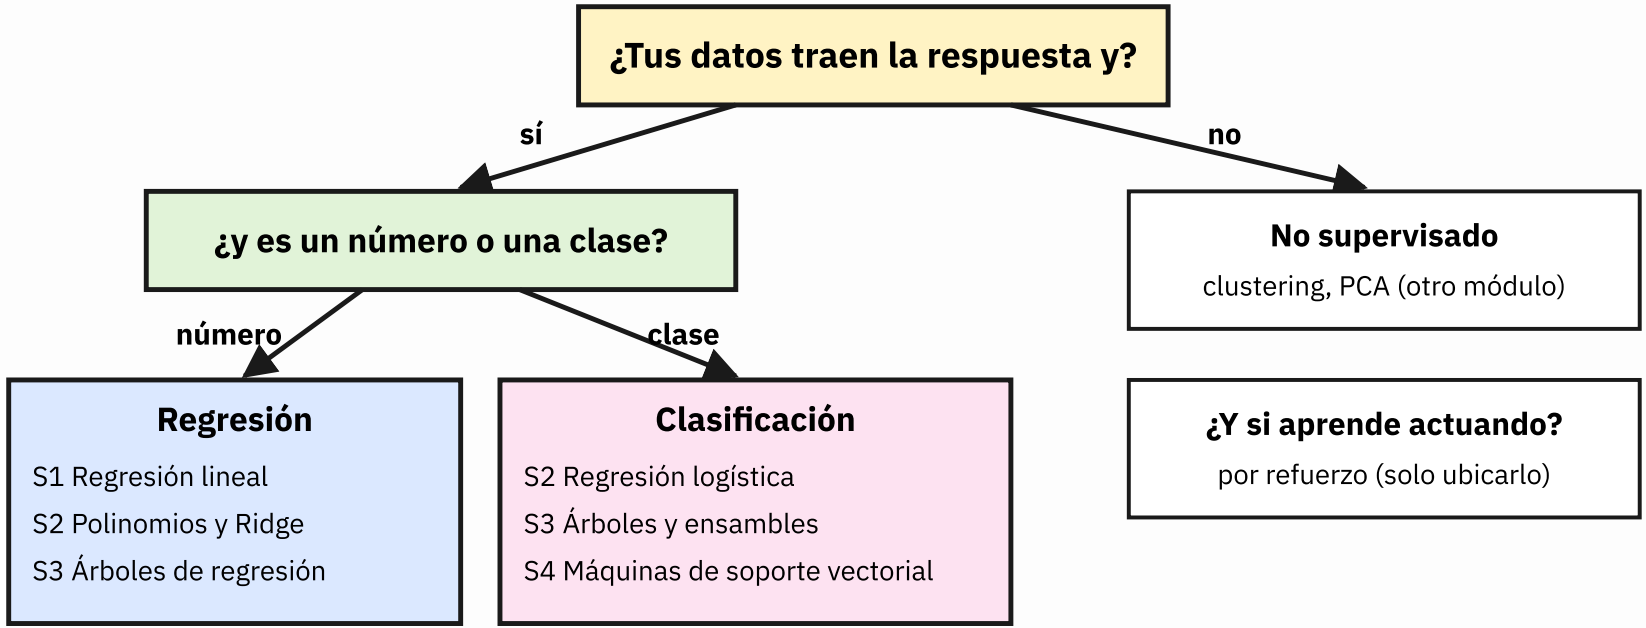


Por refuerzo

Aprende **probando**, con premios y castigos.

MiBici: decidir a dónde mover el camión que reacomoda bicis.

EL MAPA: ¿QUÉ MODELO USO?



CIERRE DEL BLOQUE A

Chat waterfall (2 min): completa la frase **sin enviar** hasta "¡ya!"

> "Lo que más me sorprendió de este bloque fue..."

REFERENCIAS DEL BLOQUE A

Abu-Mostafa, Y. S., Magdon-Ismail, M., & Lin, H.-T. (2012). *Learning from data: A short course*. AMLBook.

Buchanan, B. G., & Shortliffe, E. H. (Eds.). (1984). *Rule-based expert systems: The MYCIN experiments of the Stanford Heuristic Programming Project*. Addison-Wesley.

Daumé III, H. (2017). *A course in machine learning* (2a ed.). http://ciml.info

Geman, S., Bienenstock, E., & Doursat, R. (1992). Neural networks and the bias/variance dilemma. *Neural Computation, 4*(1), 1–58.

Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The elements of statistical learning: Data mining, inference, and prediction* (2a ed.). Springer.

Hoeffding, W. (1963). Probability inequalities for sums of bounded random variables. *Journal of the American Statistical Association, 58*(301), 13–30.

Isbell, C., & Littman, M. (s.f.-a). *Induction and deduction* [Video]. Georgia Institute of Technology; Udacity. https://www.youtube.com/watch?v=pqXASFHUfhs

Isbell, C., & Littman, M. (s.f.-b). *Defining inductive learning* [Video]. Georgia Institute of Technology; Udacity. https://youtu.be/WYYe93__FpI

MacKay, D. J. C. (2003). *Information theory, inference, and learning algorithms*. Cambridge University Press.

Mitchell, T. M. (1997). *Machine learning*. McGraw-Hill.

Samuel, A. L. (1959). Some studies in machine learning using the game of checkers. *IBM Journal of Research and Development, 3*(3), 210–229.

Shalev-Shwartz, S., & Ben-David, S. (2014). *Understanding machine learning: From theory to algorithms*. Cambridge University Press.

Valiant, L. G. (1984). A theory of the learnable. *Communications of the ACM, 27*(11), 1134–1142.

Wolpert, D. H. (1996). The lack of a priori distinctions between learning algorithms. *Neural Computation, 8*(7), 1341–1390.

PAUSA DE 5 MIN

Lejos de la pantalla. Agua, estírate, mira por la ventana.

REGRESAMOS EN **05:00**

LAB 1, PARTE 1: REGLAS PARA MIBICI

Lo mismo que con las tortillas, ahora con un año de datos reales.

LAB 1, PARTE 1: CÓMO VA A SER

1. **Miren cómo lo abro.** "Abrir en Colab", luego *Archivo*, *Guardar una copia en Drive*, y correr las dos primeras celdas hasta ver ✅. Lo hacen junto conmigo.
2. **Leemos juntos qué hace cada celda.**
3. **Ustedes cambian una cosa y miran qué sale.** Todos al mismo ritmo: les doy los mismos minutos.

El código ya está escrito, y una IA lo escribe en segundos. Lo que nos interesa es leer qué resultado da y decidir si tiene sentido.

Chat waterfall, mientras carga Colab: sin enviar hasta "¡ya!"

> "Si tuvieras que adivinar cuántas bicis salen mañana a las 8 a.m. de una estación, ¿qué dato mirarías primero?"

Lo de ayer, lo de la semana pasada, la hora, el clima...

EN VIVO: CARGAR LOS DATOS

```
df = pd.read_parquet(RUTA_DATOS)      # RUTA_DATOS la dejó lista la celda de preparación
train = df[df.particion == "train"]   # octubre a junio
julio = df[df.particion == "val"]     # julio
print(df.shape)                       # (342680, 19)
df[["station_id", "hour", "departures", "departures_lag_24h", "departures_lag_168h"]].head()
```

- Cada fila es **una estación en una hora**.
- La respuesta y es `departures`: cuántas bicis salieron.
- Las entradas x son lo que ya sabíamos a esa hora: la hora, el día, `departures_lag_24h` (ayer) y `departures_lag_168h` (hace una semana).
- `train` son los tickets que vemos; `julio`, los clientes nuevos.

EN VIVO: APLICAR UNA REGLA

```
# La regla nos la dan: "saldrán las mismas que hace una semana"
y_hat = train.departures_lag_168h
error = y_hat - train.departures      # predicción menos respuesta
mae = np.mean(np.abs(error))          # 2.20
```

Aplicar una regla dada es **deducir** la predicción. Todavía no aprendimos nada: la regla ya existía.

Medir su error sí usa los datos: es el mismo $E(h)$ de los tickets, ahora con m de 254 mil.

Se equivoca por 2.2 bicis por hora, en promedio.

EN VIVO: ESCOGER DEL MENÚ

```
menu = {
  "igual que hace una semana":
      "departures_lag_168h",
  "igual que ayer":
      "departures_lag_24h",
  "promedio de la última semana":
      "departures_mean_168h",
}
for nombre, col in menu.items():
    err = train[col] - train.departures
    print(nombre, np.mean(np.abs(err)))
```

Regla	MAE en train
igual que hace una semana	2.20
igual que ayer	2.39
promedio de la última semana	3.26

Esto es **inducir**: los datos escogen la regla. Gana "hace una semana".

¿Y con los clientes nuevos? En julio, la ganadora se equivoca por 2.30.

AHORA TÚ: MEZCLAR DOS REGLAS (7 MIN)

PREDICE Y MIDE tu Colab TIEMPO **07:00**

1. En el notebook, "Ahora tú: mezclar dos reglas": escoge dos reglas y mueve el peso.
2. Antes de mover nada: ¿alguna mezcla le gana a 2.30? Escríbelo.
3. Escoge el peso viendo **train**; julio solo lo usas para comprobar. El examen final es agosto y septiembre.
4. Pega en el chat tus dos reglas, tu peso y tu MAE **de julio**.

$$\hat{y} = \text{peso} \cdot A + (1 - \text{peso}) \cdot B$$

peso	queda
1	la regla A sola
0.5	el promedio de las dos
0	la regla B sola

¿Mezclar dos reglas le gana a la mejor regla sola? ¿Con qué peso?

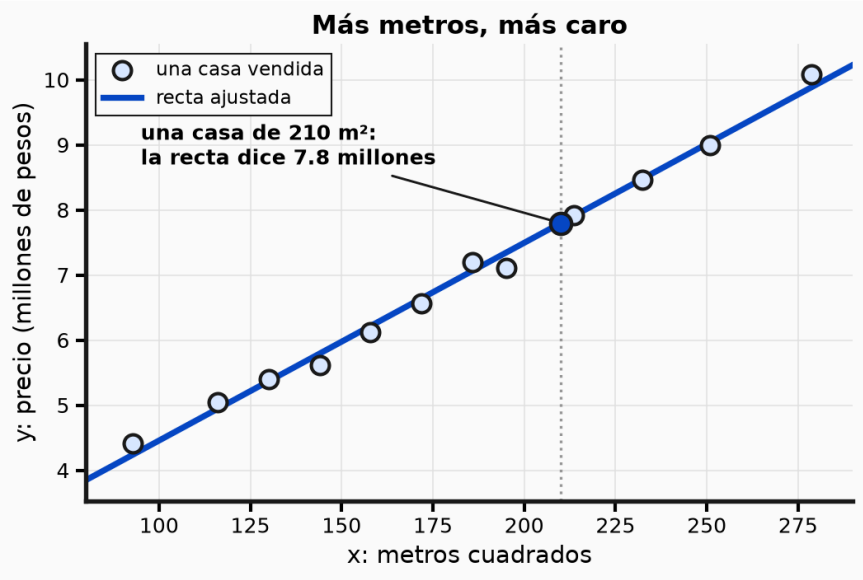
Lo que escojas es tu *Entregable 1*. Después corran la celda de la regla por estación y hora: la usamos al final.

BLOQUE B | VI.2 Regresión | ⏱ 88 a 137

REGRESIÓN LINEAL: LA APUESTA MÁS SIMPLE

Primero la recta, luego el costo, luego cómo bajar por él.

¿UNA CASA MÁS GRANDE CUESTA MÁS?



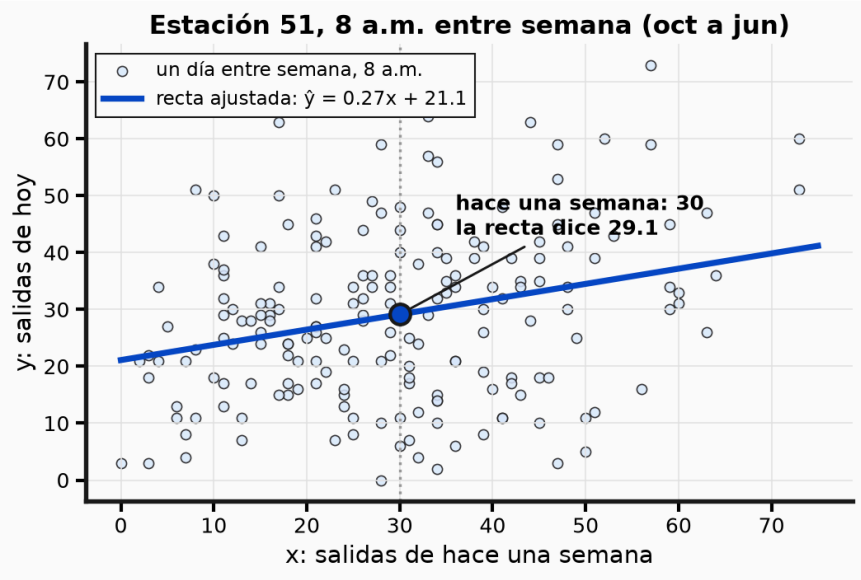
Seguro que sí: con más metros cuadrados, una casa cuesta más. Cada punto es una casa vendida.

Alguien ya trazó una recta. Una casa de **210 m²**: la recta dice **7.8 millones**. Se lee en la gráfica, sin fórmula.

Que más metros cuesten más **lo suponemos** (es nuestro sesgo). **Cuánto** más por metro lo **inducimos** de las casas vendidas. Y ya con la recta, el precio de una casa nueva se **deduce**: se aplica la regla.

¿Cómo se escoge esa recta y no otra? Eso es todo este bloque.

LO MISMO CON MIBICI



Como con las casas, pero con los datos del módulo: operas MiBici y cada noche decides cuántas bicis reacomodar. Otra vez hay que **predecir un número**.

Cada punto es un día entre semana a las 8 a.m. en la estación 51: cuántas salieron hace una semana (x) y cuántas salieron ese día (y).

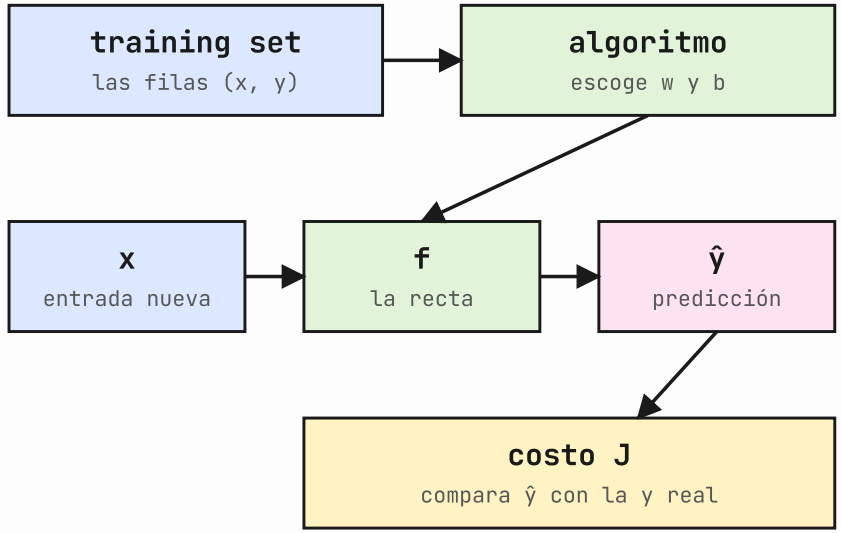
La recta se lee igual: hace una semana salieron 30; **la recta dice 29.1** para hoy. Pero la nube es mucho más ancha que la de las casas: lo de hace una semana explica solo una parte.

Las casas se ven fáciles; MiBici es el problema real del módulo.

DEL TRAINING SET A LA PREDICCIÓN

i	x: hace una semana	y: hoy
1	40	34
2	29	34
3	59	45
4	39	41
5	10	38

Estación 51, 8 a.m., del 26 al 30 de enero. Cada fila es un punto de la gráfica anterior. En train hay $m = 189$ de estos días.

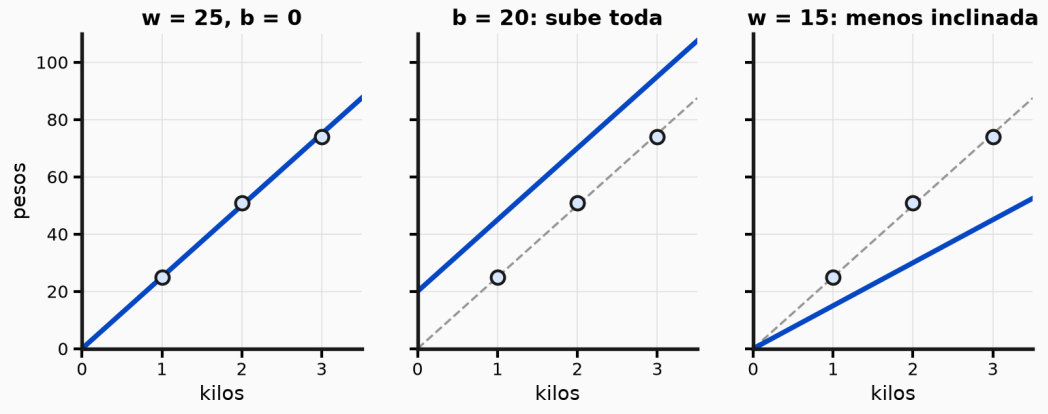


En el bloque A nosotros proponíamos la regla. Ahora el algoritmo busca w y b: entrenar es inducir; predecir es aplicar f, deducir $\hat{y}$. La y solo sirve para medir qué tan mal va.

EL MODELO

$$f_{w,b}(x) = w\,x + b$$

EN MATEMÁTICAS	EN PALABRAS
w	La pendiente: cuánto sube la predicción por cada unidad de x. En las tortillas, el precio por kilo.
b	La predicción cuando $x = 0$: dónde empieza la recta. En las tortillas, un cobro fijo por visita.



¿QUÉ DICE CADA NÚMERO?

¿QUÉ PASA SI…? menti.com, código 6445 2630

La recta de MiBici es ŷ = 0.27x + 21.1, con x las salidas de hace una semana. ¿Qué significa el 0.27?

A. Por cada bici que salió hace una semana, la predicción sube 0.27

B. Hoy sale el 27 % de las bicis

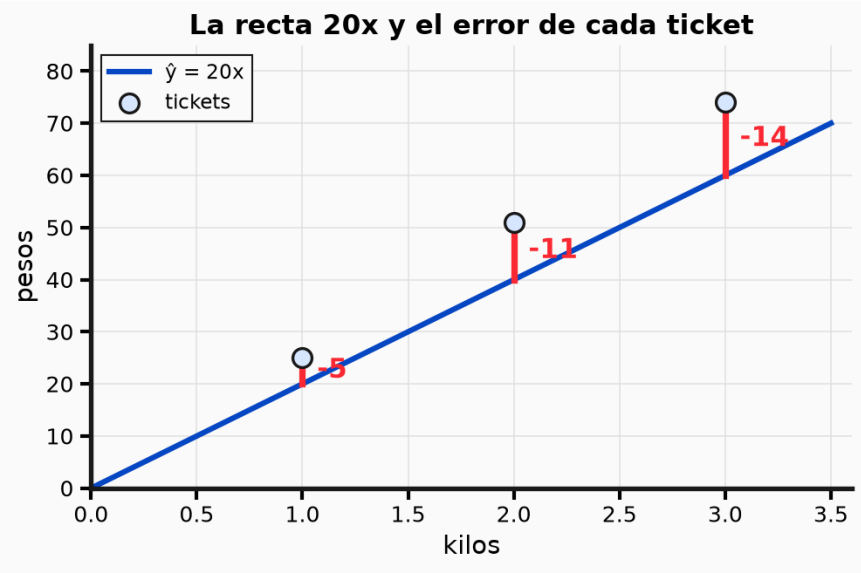
C. La recta acierta el 27 % de las veces

D. Hoy salen 0.27 bicis

A. Y el 21.1 es la base: aunque hace una semana no saliera ninguna, la recta predice 21. ¿Le creerías? Casi no hay días con x cerca de 0.

Por qué empezar con una recta: la regla de hace una semana ya es una recta, $\hat{y} = x$, con $w = 1$ y $b = 0$. Aprender es dejar que los datos escojan w y b para que se equivoque menos.

¿QUÉ TAN MALA ES UNA RECTA? EL ERROR DE CADA TICKET



EN MATEMÁTICAS	EN PALABRAS
$\hat{y}^{(i)} - y^{(i)}$	El error de un ticket: lo que predijo la recta menos lo que se pagó.
$20 - 25,\ 40 - 51,\ 60 - 74$	Con la recta $20x$: -5, -11 y -14. **Negativo = predijo menos de lo que se pagó.** Cobra 20 por kilo y el precio real anda en 25: se queda corta en los tres, y cada vez por más.
¿Por qué es un problema?	Una recta que siempre se queda corta comete un error **sistemático**: la tortillería pierde dinero en cada venta. En MiBici sería predecir

SUMAR NO BASTA: AL CUADRADO

EN MATEMÁTICAS	EN PALABRAS
$(-5) + (-11) + (-14) = -30$	Sumar con signo. Aquí da −30, pero con la recta $25x$ del bloque A daba 0: los errores de más y de menos se cancelan.
$25 + 121 + 196 = 342$	Al cuadrado, el signo se va. Y el cuadrado es una lupa: el error de 14 pesa 196; el de 5, solo 25.
$\lvert\hat{y} - y\rvert$ contra $(\hat{y} - y)^2$	En el bloque A quitamos el signo con el valor absoluto (el MAE). El cuadrado es otra forma, que castiga más los errores grandes.

CONCEPTEST 1. Voto individual (1 min) siguiente ▸

¿Por qué al cuadrado y no valor absoluto?

A. Porque es derivable en todas partes

B. Porque castiga más los errores grandes

C. Porque es lo natural si el ruido es gaussiano

D. Todas las anteriores

menti.com, código 6445 2630, o letra en el chat

EL COSTO J

$$J(w, b) = \frac{1}{2m} \sum_{i=1}^{m} \left(f_{w,b}(x^{(i)}) - y^{(i)} \right)^2$$

EN MATEMÁTICAS	EN PALABRAS
$J(20, 0) = \frac{342}{2 \cdot 3} = 57$	Los errores de la recta $20x$ al cuadrado, promediados. Un solo número: **qué tan mala es esa recta.**
`LinearRegression().fit(X, y)`	Eso hace scikit-learn por dentro: **busca la w y la b con el menor J.**

Entrenar es buscar la recta con el menor J. Para reportar usamos el MAE, que se lee en bicis.

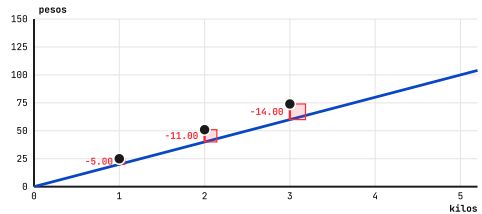
SI SOLO MOVEMOS W: EL COSTO DE CADA RECTA

Mueve w, el precio por kilo: cada w es una recta y su J es un punto de la U. **El fondo de la U es lo que encuentra** `LinearRegression().fit`**.** (abrir aparte)

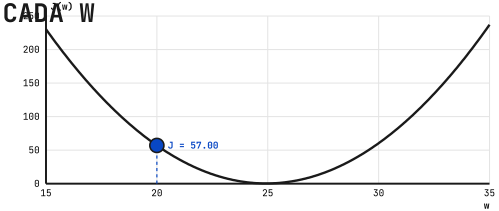
EL COSTO PARA CADA W

Cada **w** tiene su costo. Juntos dibujan una olla. Mueve el control y pasa por 20, 25 y 30.

LOS TICKETS



EL COSTO PARA CADA W



7 de 13

w, precio por kilo: **20.00** pesos

De 20, 25 y 30 gana 25. ¿Dónde está el fondo exacto? **Lo buscan ustedes en la sala.**

ACTIVIDAD EN SALAS: EL COSTO EN PYTHON

SALAS DE ZOOM salas de 3 o 4 TIEMPO **10:00**

1. Abran el notebook en Colab (enlace en el chat).
2. Papeles: quien lee, quien corre las celdas y comparte pantalla, quien duda, quien escribe.
3. Cambien w a 20 y a 30 y anoten J, como en el ejemplo de $J(25)$.
4. Antes de correr cada gráfica, escriban su predicción.

El notebook: Abrir en Colab. Si Colab no abre, la hoja trae lo mismo para hacerlo a mano.

Al volver, una sola línea al chat cuando diga "¡ya!":

`J(20): __ J(30): __ / fondo en w ≈ __ / con el ticket nuevo, fondo en w ≈ __ / cómo se escoge la recta: __`

LO QUE SALIÓ EN LAS SALAS: EL COSTO

- **El fondo no está en 25 sino en 24.93.** Los tickets no caen exacto en $25x$; la recta que menos se equivoca con ellos no es la del letrero.
- **Un ticket raro mueve todo.** Su error de 40 pesos, al cuadrado, pesa 1600; el fondo se va hasta 30.3. El cuadrado castiga mucho los errores grandes.
- **0.27 no es un porcentaje.** Es cuánto sube la predicción por cada bici de hace una semana; 21.1 es la base.

Entrenar es buscar los w y b del fondo del costo.

¿QUÉ PASA SI HAY UN OUTLIER?

¿QUÉ PASA SI…? menti.com, código 6445 2630

Agregas un día con un evento (concierto) en la orilla derecha de la nube: x grande y salidas 10 veces lo normal. ¿Qué le pasa a la recta de mínimos cuadrados?

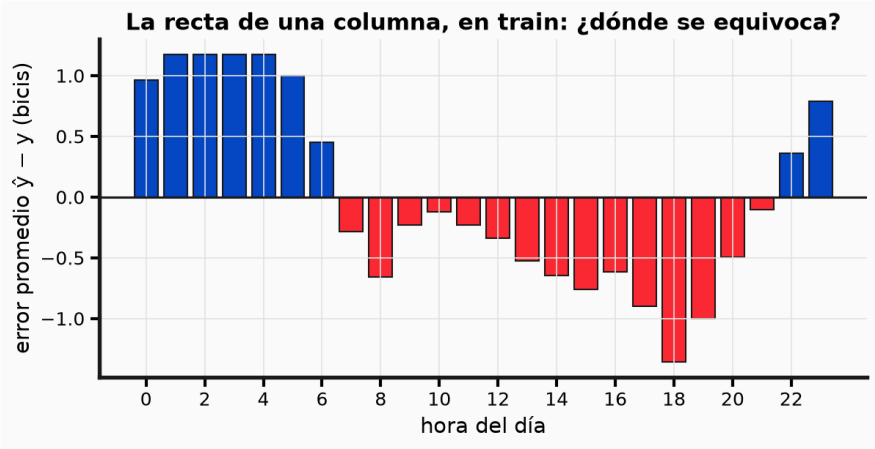
A. Casi nada
B. Se inclina notablemente hacia el outlier
C. Se vuelve horizontal
D. Depende de b

El error al cuadrado de ese punto domina la suma: **la recta se inclina**. Cuánto depende de dónde cae en x: un punto en un extremo gira la recta; uno en medio la sube o la baja.

Por qué jala tanto: un error de 10 al cuadrado pesa 100, lo mismo que cien errores de 1.

Aplicación: si tus datos tienen eventos raros, revisa los residuales o usa una pérdida robusta (MAE, Huber).

¿DÓNDE SE EQUIVOCA LA RECTA? MIRAR LOS ERRORES



- En la madrugada, la recta predice **1.2 bicis de más**; a las 18 h, **1.4 de menos**.
- Si los errores tienen forma, a la recta le falta algo. Aquí: la hora del día.

```
error = y_hat - train.departures
error.groupby(train.hour_of_day).mean()
```

Un número dice cuánto se equivoca; los errores por grupo dicen dónde. En el bloque C le damos la hora.

CIERRE DEL BLOQUE B

Entrenar es buscar el fondo del costo. Mirar los errores dice qué le falta al modelo.

Lo menos claro (1 min): en el chat, *¿qué fue lo menos claro de este bloque?* Una frase.

Leo las respuestas en el descanso y abro el bloque C con lo que más se repita.

REFERENCIAS DEL BLOQUE B

MiBici. (s.f.). *Datos abiertos* [Conjunto de datos]. Gobierno de Jalisco. https://www.mibici.net/es/datos-abiertos/

Ng, A. (2022). *Machine learning specialization* [Curso en línea]. DeepLearning.AI; Stanford Online. https://www.coursera.org/specializations/machine-learning-introduction

Ng, A., & Ma, T. (2023). *CS229 lecture notes*. Stanford University. https://cs229.stanford.edu/main_notes.pdf

PAUSA DE 25 MIN

Lejos de la pantalla. Agua, estírate, mira por la ventana.

REGRESAMOS EN **25:00**

BLOQUE C | VI.2 Regresión | ⏱ 162 a 222

LA RECTA DE MIBICI, CON SCIKIT-LEARN

Primero la usamos, luego la doblamos y al final la medimos como lo mide un negocio.

LAS 3 HERRAMIENTAS DEL LAB

Herramienta	Para qué
NumPy	Hacer cuentas con arreglos completos, sin escribir `for`
scikit-learn	Modelos listos: `fit` entrena, `predict` predice
Colab	Python en el navegador, sin instalar nada

```
import numpy as np
from sklearn.linear_model import LinearRegression

X = np.array([[10], [20], [30]])  # hace una semana
y = np.array([12, 19, 33])        # hoy

modelo = LinearRegression().fit(X, y)  # entrenar
modelo.predict([[25]])  # predecir un caso nuevo
```

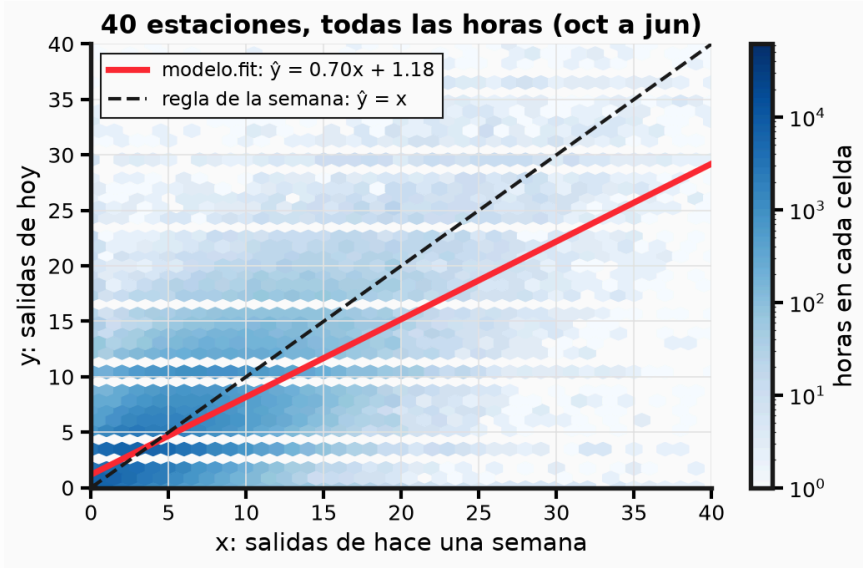
Primero **usamos** scikit-learn con MiBici; al final de la sesión medimos qué tan buena quedó, con tres varas. `X` va con doble corchete porque es una tabla: filas por columnas.

EN VIVO: LA RECTA EN TRES LÍNEAS

```
X = train[["departures_lag_168h"]]
y = train.departures
modelo = LinearRegression().fit(X, y)
modelo.coef_, modelo.intercept_   # 0.70, 1.18

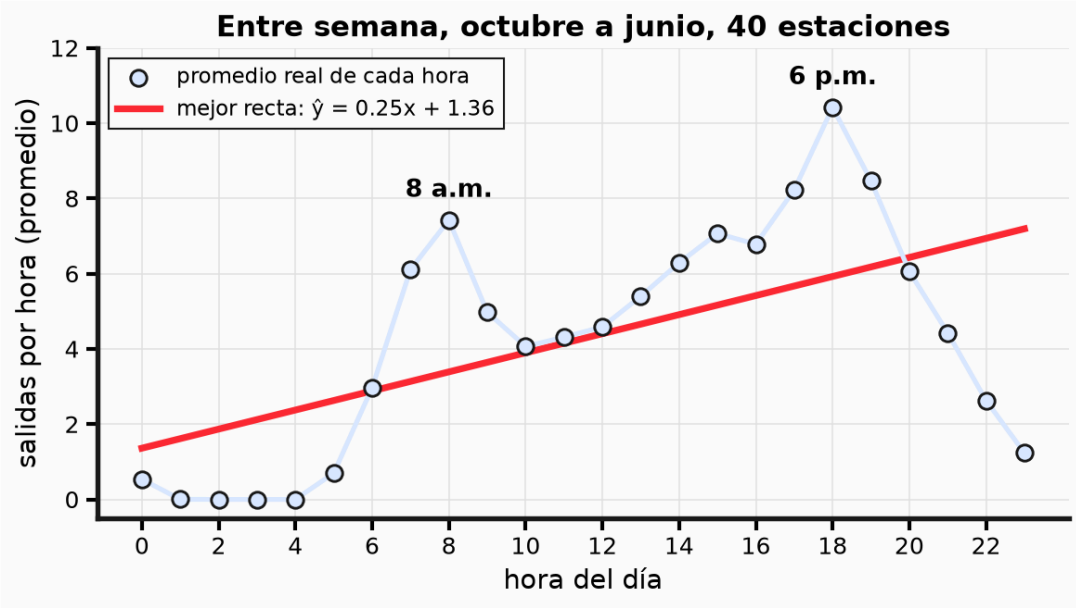
Xj = julio[["departures_lag_168h"]]
y_hat = modelo.predict(Xj)
np.mean(abs(y_hat - julio.departures))  # 2.35
```

En el bloque B	En scikit-learn
buscar el fondo de J	`fit`
w, b	`coef_`, `intercept_`
$wx + b$	`predict`



Por cada bici más hace una semana, la predicción sube 0.70. En la regla de la semana subía 1: la recta aprendió que no todo se repite.

LA RECTA SE QUEDA CORTA



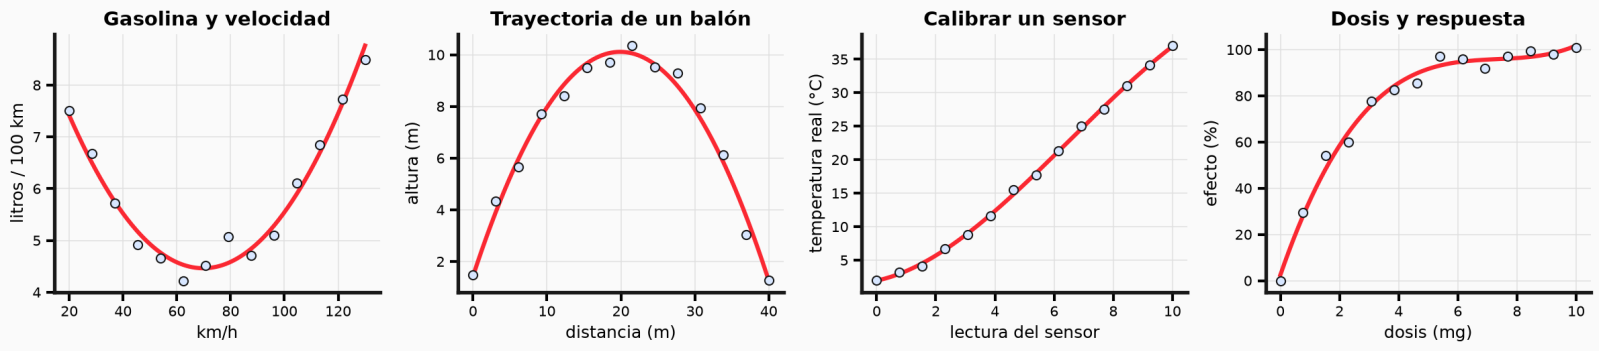
Dos picos y una noche en cero. Ninguna recta dobla.

¿A QUIÉN SE LE OCURRIÓ?

- **1805, Legendre** publica los mínimos cuadrados para calcular órbitas de cometas.
- **1809, Gauss** los publica también y dice que ya los usaba desde 1795.
- **1815, Gergonne** ajusta un **polinomio** con mínimos cuadrados y se pregunta qué grado usar.

El trabajo de Gergonne se olvidó por 150 años, hasta que Stigler (1974) lo rescató. Ya traía la pregunta que nos va a ocupar mañana: **¿cuánta curva es demasiada?**

¿DÓNDE SE USA?



- **Gasolina:** muy lento o muy rápido gasta más. Una U, grado 2.
- **Balón:** la física dice parábola. Grado 2, sin adivinar.
- **Sensor:** la lectura cruda se dobla un poco. Un grado 3 la corrige.
- **Dosis:** sube y se aplana. Un polinomio sirve dentro del rango medido.

EL TRUCO: INVENTAR COLUMNAS

EN MATEMÁTICAS	EN PALABRAS
$x = 2$	Una sola columna: la hora, los kilos, lo que sea.
<table><tr><th>x</th><th>x^2</th><th>x^3</th></tr><tr><td>2</td><td>4</td><td>8</td></tr></table>	Inventamos dos columnas más elevando x al cuadrado y al cubo. La fila ahora dice 2, 4, 8.
$\hat{y} = w_1 x + w_2 x^2 + w_3 x^3 + b$	El modelo es **la misma recta de hoy**, con tres columnas. Mismo costo J, mismo `fit`.

Mañana esta idea tiene nombre: características derivadas.

¿Y SI NO ES UNA RECTA? REGRESIÓN POLINOMIAL

EN MATEMÁTICAS	EN PALABRAS
$\hat{y} = w_1 x + w_2 x^2 + \cdots + w_d x^d + b$	La misma recta, con columnas nuevas: x^2, x^3... El **grado** d dice cuántas.
<table><tr><th>x</th><th>x^2</th><th>x^3</th></tr><tr><td>2</td><td>4</td><td>8</td></tr></table>	Para el modelo son columnas como cualquier otra: le busca un peso a cada una. Por eso se sigue llamando regresión lineal.

En scikit-learn:

`make_pipeline(PolynomialFeatures(degree=d), LinearRegression())`. `degree` es el grado.

¿QUÉ PASA SI…?

menti.com, código 6445 2630

Si subo el grado, el RMSE en train (con mínimos cuadrados)...

A. Siempre baja o se queda igual

B. Siempre sube

C. Baja y luego sube

D. No cambia

MUÉVELO: ¿DE QUÉ GRADO?

¿DE QUÉ GRADO?

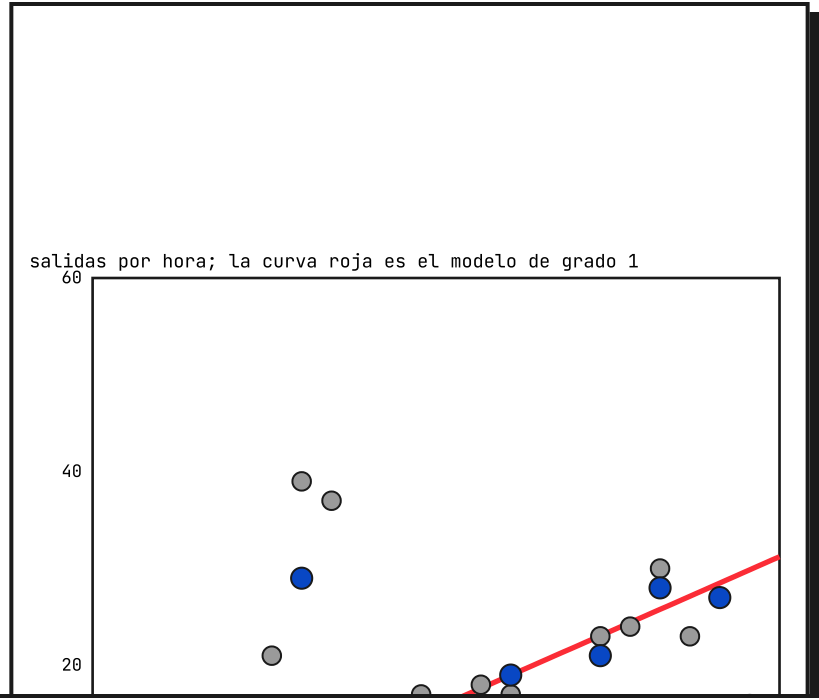
$$\hat{y} = w_1 x + w_2 x^2 + \cdots + w_d x^d + b$$

La misma recta con columnas nuevas: la hora, la hora², la hora³… El grado dice cuántas. Entrenamos con 12 horas de un lunes (**azul**) y validamos con el lunes siguiente (**gris**).

grado: 1

RMSE en train

RMSE en validación



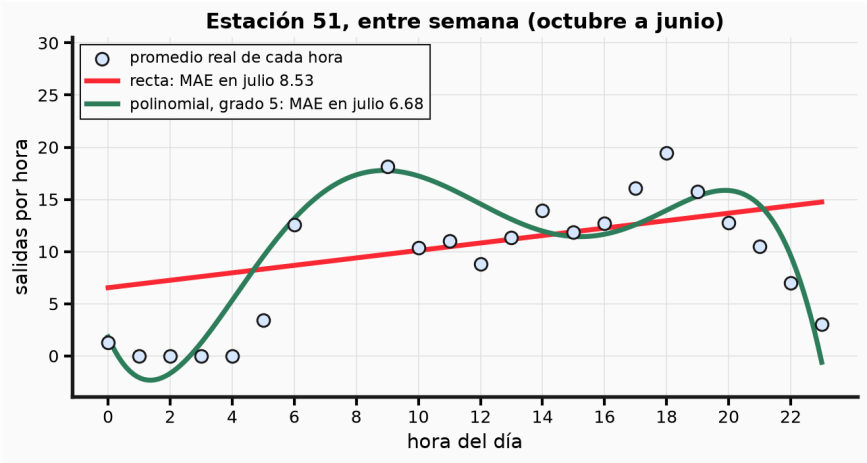
EN PYTHON: RECTA CONTRA POLINOMIAL

Ábranlo y corran conmigo:

https://colab.research.google.com/github/HesusG/dammg-supervisado/blob/main/notebooks/salas/S1_recta_vs_polinomial.ipynb

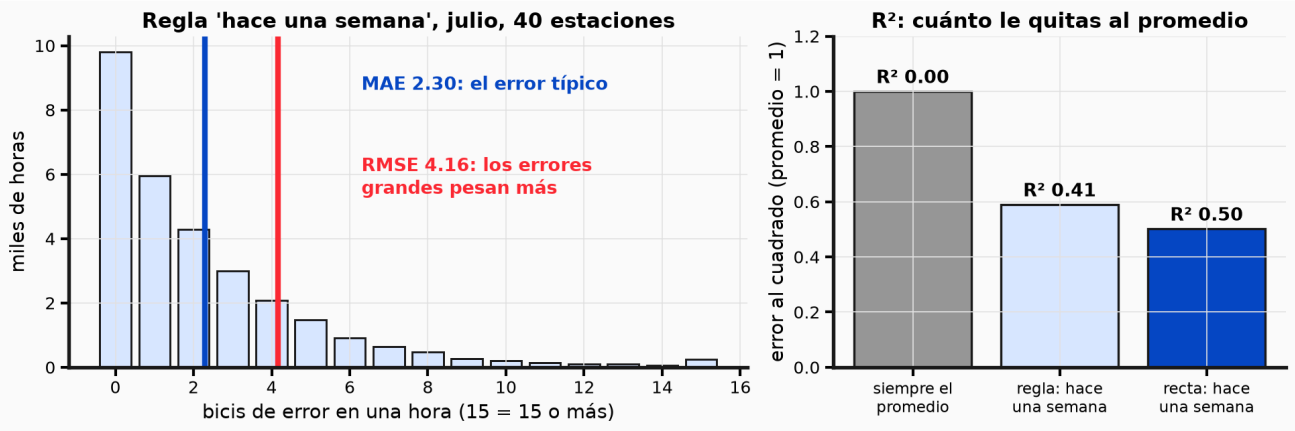
Qué van a ver:

1. La recta con scikit-learn y seaborn, en autos y MiBici.
2. Residuos con forma: a la recta le falta curva.
3. La polinomial, de grado 1 a 8.
4. Las tres varas por grado, en train y validación.
5. Anscombe: mismos números, datos distintos.



En la estación 51 la recta falla por 8.5 bicis por hora en julio; el grado 5, por 6.7.

TRES VARAS, TRES PREGUNTAS DE NEGOCIO



MAE: 2.30 bicis

¿Por cuántas bicis fallamos en una hora típica?

RMSE: 4.16 bicis

¿Qué tan feo nos va en las horas malas?

R²: 0.41

¿Cuánto mejor que no saber nada y decir siempre el promedio?

¿CUÁL USA CADA INDUSTRIA?

MAE **Demanda y operaciones**

"Fallamos por 2 bicis por hora" lo entiende cualquiera en la junta. Está en las mismas unidades que el negocio.

RMSE **Cuando un error grande sale caro**

Inventario de seguridad, una estación vacía en hora pico. Mejor muchos errores chicos que uno enorme.

R^2 **Reportes y comparar modelos**

Útil para comparar modelos en los mismos datos. Para hablar con operaciones, mejor en bicis.

MAPE y WAPE **Retail: el error en %**

Se usan mucho para pronosticar demanda. Ojo: MAPE divide entre lo real y con ceros se rompe, como MiBici de madrugada. WAPE suma todo antes de dividir y aguanta.

Escojan la vara por lo que cuesta equivocarse, y digan cuál usaron.

LA MÉTRICA DECIDE QUIÉN GANA

¿QUÉ PASA SI…? menti.com, código 6445 2630

En julio, la regla 'hace una semana' tiene MAE 2.30 y la recta con esa misma columna, 2.35. ¿Qué pasa con RMSE?

A. La regla sigue ganando

B. Ahora gana la recta

C. Empatan

D. El RMSE no se puede comparar

MiBici, julio	MAE	RMSE	R^2
Siempre el promedio de train	3.59	5.42	≈ 0
Regla: hace una semana	**2.30**	4.16	0.41
Recta: hace una semana	2.35	**3.84**	**0.50**
Recta: ayer, semana y hora	1.99	3.52	0.58

La regla se equivoca poco casi siempre, pero cuando se equivoca, se equivoca feo. El RMSE castiga esos errores al cuadrado; el MAE, en proporción.

R^2: ¿QUÉ QUIERE DECIR?

Si sale…	Quiere decir
$R^2 = 1$	Perfecto: ningún error
$R^2 = 0.50$	Le quitas la mitad del error al promedio
$R^2 = 0$	Igual que decir siempre el promedio
$R^2 < 0$	Peor que decir siempre el promedio

¿Por qué "al cuadrado"? Con una sola columna, la correlación entre hace una semana y hoy es $r = 0.70$, y $0.70^2 = 0.49$: justo el R^2 de la recta en train.

Cuidado: un R^2 alto no dice que la forma sea la correcta (Anscombe, en la demo). Y solo se compara entre modelos en los mismos datos.

PARA MIBICI, ¿CUÁL REPORTAMOS?

Al equipo de las camionetas

MAE: "fallamos por 2 bicis por hora". Con eso planean cuántas mover.

A quien cuida la hora pico

RMSE: una estación vacía a las 8 a.m. sale cara, y el RMSE castiga esas horas.

En el reporte técnico

R^2, junto al MAE, para comparar modelos en los mismos datos.

MAE en julio	Regla: hace una semana	Recta: esa columna	Mejor recta del reto	Tabla por estación y hora
bicis por hora	2.30	2.35	1.99	**1.95**

Un modelo se vende en las unidades del negocio y siempre al lado de la regla simple que tiene que vencer.

REFERENCIAS DEL BLOQUE C

Anscombe, F. J. (1973). Graphs in statistical analysis. *The American Statistician, 27*(1), 17–21.

Gergonne, J. D. (1974). The application of the method of least squares to the interpolation of sequences (R. St. John & S. M. Stigler, Trads.). *Historia Mathematica, 1*(4), 439–447. (Trabajo original publicado en 1815)

Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and practice* (3a ed.). OTexts. https://otexts.com/fpp3/

Hyndman, R. J., & Koehler, A. B. (2006). Another look at measures of forecast accuracy. *International Journal of Forecasting, 22*(4), 679–688.

Kolassa, S., & Schütz, W. (2007). Advantages of the MAD/Mean ratio over the MAPE. *Foresight: The International Journal of Applied Forecasting, 6*, 40–43.

Ng, A. (2022). *Machine learning specialization* [Curso en línea]. DeepLearning.AI; Stanford Online. https://www.coursera.org/specializations/machine-learning-introduction

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830.

Stigler, S. M. (1974). Gergonne's 1815 paper on the design and analysis of polynomial regression experiments. *Historia Mathematica, 1*(4), 431–439.

PAUSA DE 5 MIN

Lejos de la pantalla. Agua, estírate, mira por la ventana.

REGRESAMOS EN **05:00**

LAB 1 | VI.2 Regresión | ⏱ 227 a 277

LAB 1, PARTE 3: TRES VARAS

Los mismos modelos de hoy, medidos con MAE, RMSE y R^2. ¿Cambia el ganador?

LAB 1, PARTE 3: CÓMO VA A SER

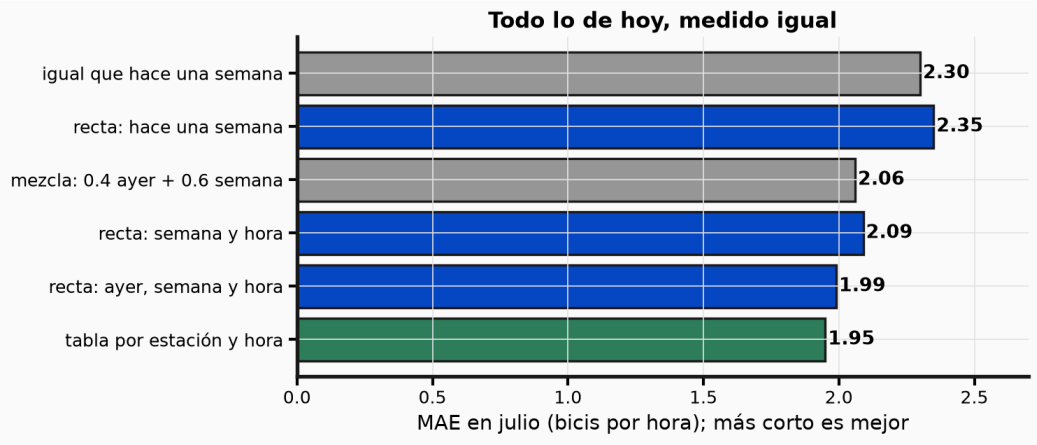
Fase	Min	Quién	Qué pasa
1. En vivo	15	Yo corro y ustedes también	Las tres varas con las tortillas y con MiBici
2. Ustedes	25	Cada quien en su notebook	Su mejor recta del reto con las tres varas, el *Entregable 2* (`rmse` y `r2`) y su interpretación
3. Cierre	10	Todos	Todo lo de hoy en una gráfica

FASE 2 notebook L1, parte 3 TIEMPO **25:00**

Lo hacemos **juntos, al mismo ritmo**. Antes de correr cada celda, escribe qué crees que va a pasar.

Se califican los *Entregables* 1 y 2 (los revisa el evaluador) y tus dos **interpretaciones**. Moodle, **dom 8 nov, 23:59** (tolerancia hasta el mié 11 nov).

TODO LO DE HOY, EN UNA GRÁFICA



- La regla más simple, **la semana se repite**, ya es difícil de vencer.
- La recta mejora cuando le damos **las columnas correctas**, no todas.
- La tabla por estación y hora sigue ganando: tiene un promedio para cada combinación; la recta suma efectos por separado.

PARA HACER LA TAREA 1

Qué es: escoger, interpretar en 2 o 3 líneas y, a veces, una función chica. **Sin NumPy:** listas, `for` y `sum`.

A su ritmo, unas 2 horas, sola o solo.

Entrega en Moodle: **dom 8 nov, 23:59**. Se acepta hasta el mié 11.

Cómo empezar, en 3 pasos:

1. Abran la liga:

https://colab.research.google.com/github/HesusG/dammg-supervisado/blob/main/notebooks/tareas/T1/tarea.ipynb

2. *Archivo*, *Guardar una copia en Drive*. No cambien los nombres de variables ni funciones.
3. Empiecen por la sección 1. Para entregar: *Archivo*, *Descargar .ipynb*.

LA TAREA 1 Y LO DE HOY

Sección de la T1	Con qué de hoy
1a y 1b. Inductivo, deductivo y sesgos	Bloque A: las reglas y las apuestas
2a. Métricas	Las tres varas y cuál usa cada industria
2b. Regresión lineal	Bloque B y la recta con scikit-learn
2c. Regresión polinomial	La recta se queda corta y la demo en Python
2d, 3a y 3b. Características, clasificación y logística	Mañana

¿Sobra tiempo? Ábranla ya, empiecen por la sección 1 y pregunten en vivo.

CUESTIONARIO RÁPIDO (1 DE 2)

¿QUÉ PASA SI…? menti.com, código 6445 2630

¿Qué hace modelo.fit(X, y)?

A. Predice casos nuevos
B. Busca w y b con el menor error
C. Calcula el MAE

¿QUÉ PASA SI…? menti.com, código 6445 2630

En MiBici, un MAE de 2 quiere decir…

A. Acertamos 2 de cada 10 horas
B. El error es de 2 %
C. Fallamos por 2 bicis en promedio

¿QUÉ PASA SI…? menti.com, código 6445 2630

¿Cuándo conviene el RMSE?

A. Cuando un error grande sale caro
B. Cuando hay ceros en los datos
C. Nunca: da lo mismo que el MAE

CUESTIONARIO RÁPIDO (2 DE 2)

¿QUÉ PASA SI…? menti.com, código 6445 2630

$R^2 = 0$ quiere decir que el modelo...

A. Es perfecto
B. Es igual que decir siempre el promedio
C. Es peor que el promedio
D. No tiene datos

¿QUÉ PASA SI…? menti.com, código 6445 2630

Si subo el grado del polinomio, el error en train...

A. Sube
B. Baja o se queda igual
C. Primero baja y luego sube
D. No cambia nunca

PARA MAÑANA (OPCIONAL)

Si quieres repasar, unos 45 minutos:

1. Cuatro videos sobre la recta y el costo (en inglés, con subtítulos en español): 1, 2, 3, 4. Usa casas en lugar de tortillas; es el mismo argumento.
2. Si no terminaste el Lab 1 (partes 1, 2 y 3), termínalo: va en el mismo notebook.

Pregunta guía para los videos: ¿qué hacen los videos con $b = 0$ y por qué ayuda a entender el costo?

No se entrega. Lo que sí vence el **dom 8 nov**: L1, L2 y la T1.

TICKET DE SALIDA (3 MIN)

1. En una frase: ¿qué **sesgo inductivo** tiene la regresión lineal?
2. Con MAE ganó la regla y con RMSE la recta. ¿Por qué?
3. ¿Qué fue lo **más confuso** de hoy?

Mañana 9:00: características derivadas, sobreajuste, Ridge y regresión logística. Trae Colab abierto.

Material propio CC BY-NC-SA 4.0. Las referencias van al final de cada bloque.

APÉNDICE Para consultar

APÉNDICE DE LA SESIÓN 1

Glosario, derivaciones y las fórmulas completas. No se presenta en clase: es para leer.

A. GLOSARIO (1 DE 2)

Término	Qué es
Deducir	Aplicar una regla conocida a un caso; si la regla es cierta, la conclusión es segura
Inducir	Proponer una regla a partir de ejemplos; la conclusión puede fallar con casos nuevos
Aprendizaje supervisado	Inducir una regla con ejemplos que traen su respuesta y
Hipótesis h	Una regla candidata; H es el menú de reglas que nos permitimos
Sesgo inductivo	Lo que suponemos antes de ver los datos: qué reglas se valen y cuáles preferimos
Característica, x_j	Una columna de entrada; $x_j^{(i)}$ es su valor en la fila i
Etiqueta, y	La respuesta que queremos predecir
Predicción, $\hat{y}$	Lo que dice la regla para una entrada
Error (residuo)	$\hat{y} - y$: predicción menos respuesta, con signo
Train, validación, prueba	Datos para entrenar (oct a jun), para escoger (julio) y para el examen final (ago y sep)

A. GLOSARIO (2 DE 2)

Término	Qué es
Costo $J(w, b)$	El promedio de los errores al cuadrado, a la mitad; entrenar es buscar su mínimo
Descenso de gradiente	Bajar por J dando pasos en contra de la pendiente; α es el tamaño del paso
Ecuación normal	La fórmula que da el mínimo de J en un solo paso (apéndice C)
MAE, RMSE	Error absoluto medio y raíz del error cuadrático medio; los dos en unidades de y
R^2	Qué fracción del error cuadrático de "decir siempre el promedio" quita el modelo
Correlación r	Qué tan alineados están x y y, de −1 a 1; con una columna y mínimos cuadrados con intercepto, en train, $R^2 = r^2$
Regresión polinomial	Regresión lineal con columnas $x, x^2, \ldots, x^d$
Sobreajuste	El error en train baja y en validación sube: el modelo se aprende el ruido
Rezago	$x_t = y_{t-k}$: lo que pasó k horas antes
Fuga	Usar una columna que no se conoce al momento de predecir

B. MÍNIMOS CUADRADOS CON UNA VARIABLE

Queremos el mínimo de $J(w,b) = \frac{1}{2m}\sum_{i=1}^{m}(wx^{(i)} + b - y^{(i)})^2$. En el mínimo, las dos derivadas valen cero.

Respecto a b:

$$\frac{\partial J}{\partial b} = \frac{1}{m}\sum_i (wx^{(i)} + b - y^{(i)}) = 0$$

$$\Rightarrow \quad b = \bar{y} - w\,\bar{x}$$

Respecto a w, sustituyendo b:

$$\frac{\partial J}{\partial w} = \frac{1}{m}\sum_i (wx^{(i)} + b - y^{(i)})\,x^{(i)} = 0$$

$$\Rightarrow \quad w = \frac{\sum_i (x^{(i)} - \bar{x})(y^{(i)} - \bar{y})}{\sum_i (x^{(i)} - \bar{x})^2} = \frac{S_{xy}}{S_{xx}}$$

En palabras: la recta pasa por el punto promedio $(\bar{x}, \bar{y})$.

Con $b = 0$ (las tortillas) solo queda la segunda ecuación: $\sum_i (wx^{(i)} - y^{(i)})x^{(i)} = 0$, así que $w = \dfrac{\sum xy}{\sum x^2} = \dfrac{349}{14} \approx 24.93$.

Hace falta $S_{xx} > 0$: que no todas las x sean iguales. Que es un mínimo y no un máximo lo muestra el apéndice C (convexidad).

C. FORMA MATRICIAL: LA ECUACIÓN NORMAL

Con n columnas, juntamos los datos en la matriz X ($m \times (n+1)$, con una columna de unos para b) y los pesos en $\theta = (b, w_1, \ldots, w_n)$:

$$J(\theta) = \frac{1}{2m}\,\|X\theta - y\|^2 \qquad\qquad \nabla J(\theta) = \frac{1}{m}\,X^\top (X\theta - y)$$

El mínimo: $\nabla J = 0$ da

$$X^\top X\,\theta = X^\top y$$

Si $X^\top X$ es invertible (ninguna columna es combinación de las otras):

$$\theta = (X^\top X)^{-1} X^\top y$$

En la práctica no se invierte: `np.linalg.lstsq` resuelve el sistema de forma estable.

La geometría: $X\theta$ es la sombra de y sobre el espacio de las columnas de X. El residuo $X\theta - y$ queda perpendicular a todas las columnas: eso dice $X^\top(X\theta - y) = 0$.

Es convexa: la segunda derivada es $\frac{1}{m}X^\top X$, que cumple $v^\top X^\top X\, v = \|Xv\|^2 \geq 0$. No hay mínimos falsos.

Polinomios: es la misma ecuación con las columnas $1, x, x^2, \ldots, x^d$. Con $m = d + 1$ puntos de abscisas distintas, la curva pasa por todos y el error en train es 0.

D. DESCENSO DE GRADIENTE

La regla: con el gradiente del apéndice C,

$$\theta \leftarrow \theta - \alpha\, \nabla J(\theta) = \theta - \frac{\alpha}{m} X^\top (X\theta - y)$$

Por componentes, con una variable:

$$w \leftarrow w - \frac{\alpha}{m} \sum_i (\hat{y}^{(i)} - y^{(i)})\, x^{(i)}$$

$$b \leftarrow b - \frac{\alpha}{m} \sum_i (\hat{y}^{(i)} - y^{(i)})$$

Se actualizan los dos a la vez, con el $\hat{y}$ del paso anterior.

Cuándo converge. En una parábola $J(w) = \frac{a}{2}(w - w^*)^2$, un paso hace

$$w - w^* \;\leftarrow\; (1 - \alpha a)(w - w^*)$$

Converge si $|1 - \alpha a| < 1$, es decir, $0 < \alpha < 2/a$. Con varias columnas, a es el mayor valor propio de $\frac{1}{m} X^\top X$: la dirección más empinada manda.

Tortillas, con $b = 0$ fijo: $a = \frac{1}{m}\sum x^2 = \frac{14}{3}$, así que $\alpha < \frac{3}{7} \approx 0.43$. Si se mueven w y b a la vez, el mayor valor propio es 5.55 y el límite baja a 0.36.

Escalar acerca las curvaturas de las direcciones (no las iguala si las columnas están correlacionadas) y suele permitir un α más grande.

E. LAS MÉTRICAS DE REGRESIÓN

$$\text{MAE} = \frac{1}{m}\sum_i |\hat{y}^{(i)} - y^{(i)}| \qquad \text{MSE} = \frac{1}{m}\sum_i (\hat{y}^{(i)} - y^{(i)})^2$$

$$\text{RMSE} = \sqrt{\text{MSE}} \qquad R^2 = 1 - \frac{\text{SSE}}{\text{SST}}$$

con $\text{SSE} = \sum_i (\hat{y}^{(i)} - y^{(i)})^2$ y $\text{SST} = \sum_i (\bar{y} - y^{(i)})^2$.

RMSE ≥ MAE siempre. Por Cauchy-Schwarz, $\left(\frac{1}{m}\sum |e_i|\right)^2 \leq \frac{1}{m}\sum e_i^2$. Son iguales solo si todos los errores miden lo mismo; mientras más se separan, más desiguales son los errores.

$R^2 \leq 1$ (si $\text{SST} > 0$), porque $\text{SSE} \geq 0$. Puede ser negativo si $\text{SSE} > \text{SST}$: el modelo es peor que el promedio.

En train, con intercepto, $0 \leq R^2 \leq 1$. Mínimos cuadrados cumple la descomposición

$$\underbrace{\sum (y - \bar{y})^2}_{\text{SST}} = \underbrace{\sum (\hat{y} - \bar{y})^2}_{\text{SSR}} + \underbrace{\sum (\hat{y} - y)^2}_{\text{SSE}}$$

así que $R^2 = \text{SSR}/\text{SST}$, la fracción de la variación que explica el modelo.

Con una columna, $R^2 = r^2$. Como $\hat{y} - \bar{y} = w(x - \bar{x})$ y $w = S_{xy}/S_{xx}$:

$$R^2 = \frac{w^2 S_{xx}}{S_{yy}} = \frac{S_{xy}^2}{S_{xx} S_{yy}} = r^2$$

En MiBici (train): $r = 0.703$ y $R^2 = 0.494$.

F. POR QUÉ EL CUADRADO: MÁXIMA VEROSIMILITUD

El supuesto: $y^{(i)} = wx^{(i)} + b + \varepsilon^{(i)}$, con ruido $\varepsilon^{(i)} \sim \mathcal{N}(0, \sigma^2)$ independiente.

La verosimilitud: la densidad conjunta de las respuestas observadas, dadas las entradas.

$$L(w, b) = \prod_i \frac{1}{\sqrt{2\pi}\,\sigma} \exp\left(-\frac{(\hat{y}^{(i)} - y^{(i)})^2}{2\sigma^2}\right)$$

Tomando $-\log$:

$$-\log L = \frac{1}{2\sigma^2} \sum_i (\hat{y}^{(i)} - y^{(i)})^2 + m \log(\sqrt{2\pi}\,\sigma)$$

El segundo término no depende de w ni de b. Así que **los parámetros que hacen más probables los datos son los que minimizan el error al cuadrado**: es lo mismo que minimizar J.

Con otro ruido, otra vara. Si ε sigue una distribución de Laplace, $p(\varepsilon) \propto e^{-|\varepsilon|/s}$, el mismo razonamiento lleva a minimizar $\sum|\hat{y} - y|$: el MAE.

Para el outlier: el cuadrado supone colas delgadas; un concierto es un evento que la campana casi no permite, y por eso jala tanto a la recta.