DAMMG | FACULTAD DE CIENCIAS, UNAM | 1ª EMISIÓN

Facultad de Ciencias UNAM

SECRETARÍA DE EDUCACIÓN ABIERTA Y CONTINUA
FACULTAD DE CIENCIAS

DIPLOMADO EN APRENDIZAJE DE MÁQUINA Y MODELOS GENERATIVOS

MÉTRICAS, COLUMNAS NUEVAS Y LA REGRESIÓN LOGÍSTICA

DAMMG Módulo VI: Aprendizaje supervisado | Sesión 2, VI.2 y VI.3 | sáb 31 oct 2026, 9:00 a 14:00

Mtro. Hesus García Cobos

PLAN DEL DÍA

1. Repaso de ayer y quiz
2. Particularizar unas cosas: métricas de regresión
3. Características derivadas
4. Fuga de información
5. Regresión logística y métricas de clasificación
6. Hoja del camión
7. Cierre: Tarea 2 y proyecto

Cada sección tiene lo mismo: la idea en palabras, un ejemplo con MiBici, código en vivo y una hoja para ustedes en salas.

LO QUE VIMOS AYER, EN UNA FRASE

Ayer medimos cuánto se equivoca una predicción y dejamos que los datos escogieran la recta que menos se equivoca.

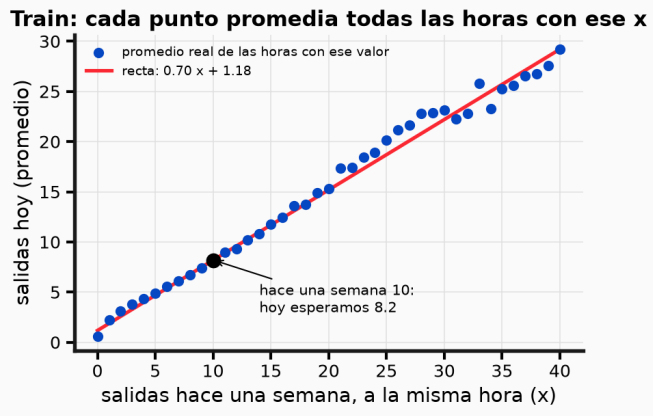
La regla: "saldrán las mismas bicis que hace una semana". En julio se equivoca por 2.30 bicis por hora (MAE).

La recta: salidas = 0.70 × (hace una semana) + 1.18. En julio, MAE 2.35 y RMSE 3.84.

Lo que quedó abierto: con MAE gana la regla y con RMSE gana la recta. ¿Cuál es mejor? Hoy lo contestamos.

Hoy: primero las métricas, una por una y en palabras. Luego, columnas nuevas para la recta y, después, predecir sí o no.

REPASO DE AYER, CON MIBICI



Yo lo corro y cambio números a mano; ustedes lo siguen en Colab:

https://colab.research.google.com/github/HesusG/dammg-supervisado/blob/main/notebooks/salas/S2_repaso.ipynb

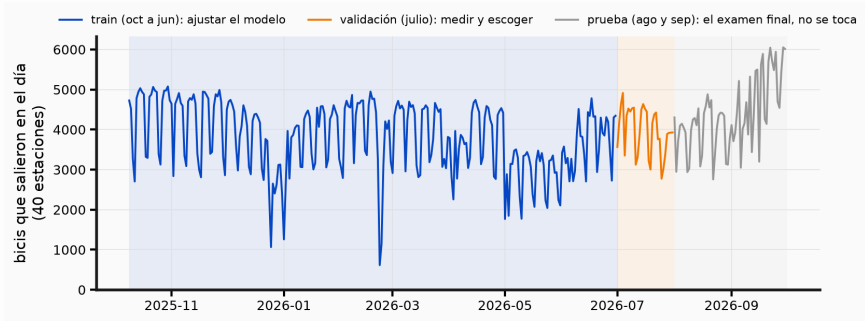
- Una fila: x, y y la predicción
- La regla de hace una semana y su error
- El costo J al mover w
- La recta: 0.70 y 1.18
- Un dato raro que jala la recta
- Julio con MAE, RMSE y R^2
- Polinomial: grado 1, 3 y 8

HOJA: INDAGA EN TU ESTACIÓN (10 MIN)

Cada quien con **su estación**. Arriba viene una tabla con **qué significa cada columna** de MiBici y cuáles son trampa.

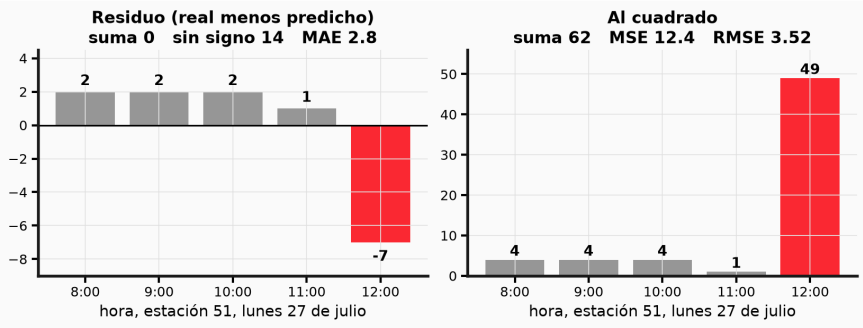
https://colab.research.google.com/github/HesusG/dammg-supervisado/blob/main/notebooks/salas/S2_hoja_repaso.ipynb

1. **Grafiquen** a qué horas se usa, entre semana y en fin de semana.
2. Vean si **hace una semana** sirve para predecir hoy.
3. Ajusten **su recta** y mídanla en julio contra la regla.
4. Respondan en 3 renglones y contesten las 4 preguntas en la misma hoja.



Primero conocer la estación; después predecirla.

QUIZ: LO DE AYER, PASO A PASO (15 MIN)



Tres partes, opción múltiple:

1. Diez conceptos de ayer (5 min)
2. El error a mano con cinco horas de la 51 (8 min)
3. Qué significa cada número (4 min)

Decidan antes de dar clic. Al elegir aparece si acertaron y por qué.

https://colab.research.google.com/github/HesusG/dammg-supervisado/blob/main/notebooks/salas/S2_quiz_ayer.ipynb

SECCIÓN 1 | Métricas de regresión | ⏱ 9:50 a 11:09

PARTICULARIZAR UNAS COSAS: MÉTRICAS DE REGRESIÓN

Cada métrica contesta una pregunta. Primero la pregunta, luego un ejemplo con cinco horas, y la fórmula al final.

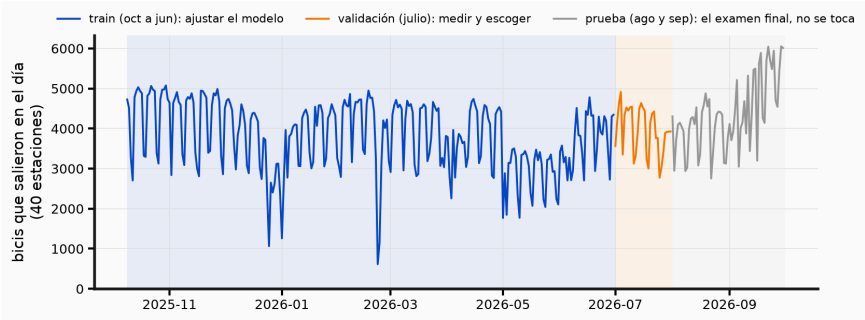
LO BÁSICO: LA Y, TRAIN, VALIDACIÓN Y PRUEBA

La y es lo que queremos predecir: `train.departures`, cuántas bicis **salieron de verdad** de una estación en una hora. Una fila es una estación en una hora.

Train (octubre a junio): con estos datos se ajusta el modelo.

Validación (julio): datos que el modelo no vio. Aquí medimos y escogemos entre modelos.

Prueba (agosto y septiembre): el examen final. No se toca hasta el final del curso.



Medimos en julio porque ahí el modelo no hizo trampa: no vio esos datos al ajustarse.

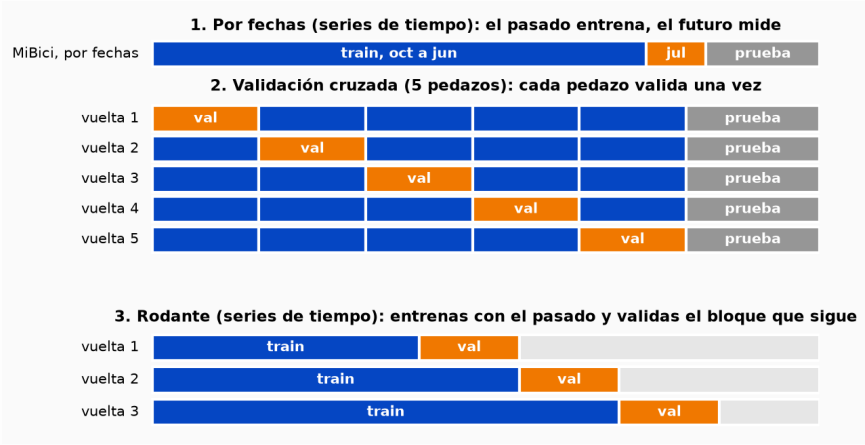
CÓMO SE PARTE: TAMAÑOS Y OTRAS FORMAS

Como en la escuela: train es estudiar con la guía, validación es el examen de práctica (para escoger cómo estudiar) y prueba es el examen final (una sola vez).

Tamaños de costumbre:

Datos	Train / validación / prueba
Miles de filas	60 / 20 / 20 o 70 / 15 / 15
Solo dos partes	80 / 20 (train / prueba)
Millones de filas	98 / 1 / 1 basta
MiBici, por fechas	**74 / 9 / 17**

Qué conviene: si hay tiempo de por medio, **partir por fechas**, nunca al azar; validación de al menos un ciclo completo (un mes trae semanas y fines de semana); la prueba, una sola vez.



EL ERROR DE UNA HORA: LO REAL MENOS LO PREDICHO

Hora	Salieron	Predijo	Error
8:00	34	32	2
9:00	22	20	2
10:00	10	8	2
11:00	12	11	1
12:00	4	11	−7

Estación 51, lunes 27 de julio. Las mismas cinco horas del quiz.

Positivo: el modelo se quedó corto.

Negativo: el modelo se pasó.

Cero: le atinó.

Con estas cinco horas vamos a sacar todas las métricas.

¿QUÉ PREGUNTA CONTESTA CADA MÉTRICA?

Métrica	La pregunta que contesta	Unidades	Mejor si es
MAE	¿Cuánto me equivoco normalmente?	bicis	más bajo
RMSE	¿Cuánto me equivoco, dando más peso a los errores grandes?	bicis	más bajo
MSE	Lo mismo que el RMSE, pero al cuadrado	bicis al cuadrado	más bajo
SSE	¿Cuánto suman todos los errores al cuadrado?	bicis al cuadrado	más bajo
R^2	¿Cuánto mejora mi modelo a decir siempre el promedio?	sin unidades	más alto

Cuatro miden error: entre más bajo, mejor. R^2 mide mejora: entre más alto, mejor.

MAE: ¿CUÁNTO ME EQUIVOCO NORMALMENTE?

Si sumo los errores tal cual:

2 + 2 + 2 + 1 − 7 = **0**

Parece perfecto y no lo es: los de arriba y los de abajo se cancelan.

Les quito el signo:

2 + 2 + 2 + 1 + 7 = 14

14 entre 5 horas = **2.8 bicis**

Cómo se lee: en una hora normal fallamos por unas 3 bicis, para arriba o para abajo.

Cuándo sirve: cuando cada bici de error cuesta lo mismo.

Aguanta los extremos: un error de 7 cuenta como 7, no como 49.

Más bajo es mejor.

$MAE = \frac{1}{m}\sum|y - \hat{y}|$: quito el signo a cada error y saco el promedio.

SSE Y MSE: ¿Y SI LOS GRANDES DUELEN MÁS?

Elevo cada error al cuadrado: una lupa sobre los grandes.

Error	2	2	2	1	-7
Al cuadrado	4	4	4	1	**49**

SSE, el total: 4 + 4 + 4 + 1 + 49 = **62**

MSE, el promedio: 62 entre 5 = **12.4**

La lupa: el −7 era la mitad del MAE (7 de 14); aquí es casi todo (49 de 62). Un error de 10 pesa 100, casi lo mismo que once errores de 3 (99).

Ventaja: el modelo trata de evitar errores grandes.

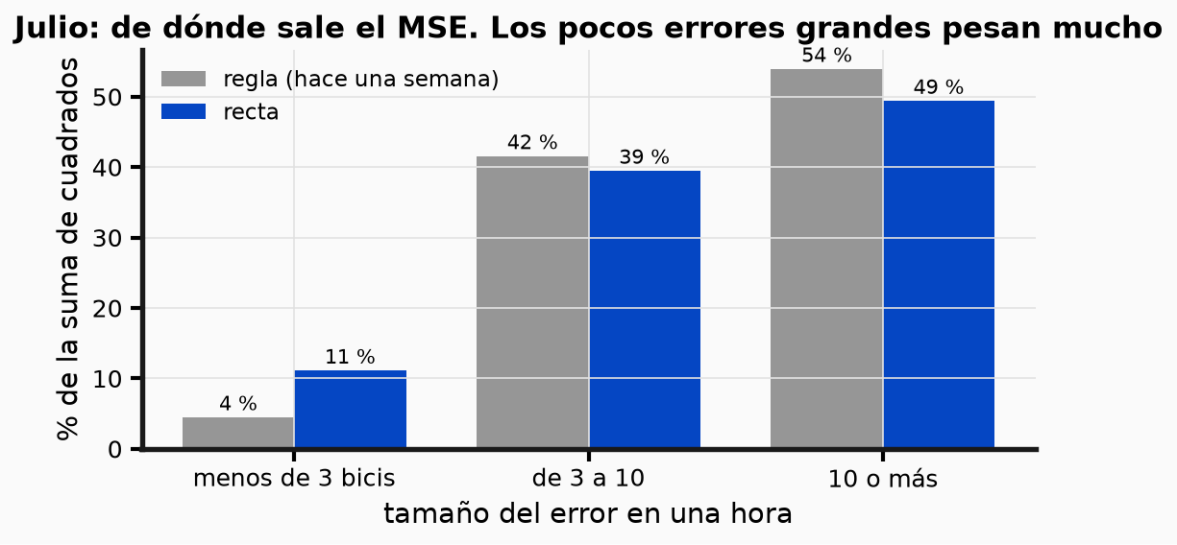
Desventaja: queda en bicis al cuadrado, difícil de leer.

El SSE crece solo por tener más filas; por eso se divide entre m.

Más bajo es mejor.

$SSE = \sum(y - \hat{y})^2$ y $MSE = \frac{SSE}{m}$: elevo al cuadrado, sumo, y para el MSE divido entre las filas.

¿DE DÓNDE SALE EL MSE? LOS ERRORES GRANDES PESAN MÁS



Las horas con error de 10 bicis o más son menos del 3 %, pero ponen la mitad del MSE. El cuadrado agranda lo grande.

RMSE: ¿CUÁNTO FALLO, CON LUPA?

Le saco raíz al MSE para volver a bicis:

raíz de 12.4 = **3.52 bicis**

	MAE	RMSE
Las 5 horas	2.8	**3.52**
Sin la hora de las 12	1.75	**1.80**

Sigue castigando lo grande: el cuadrado ya pasó antes de la raíz.

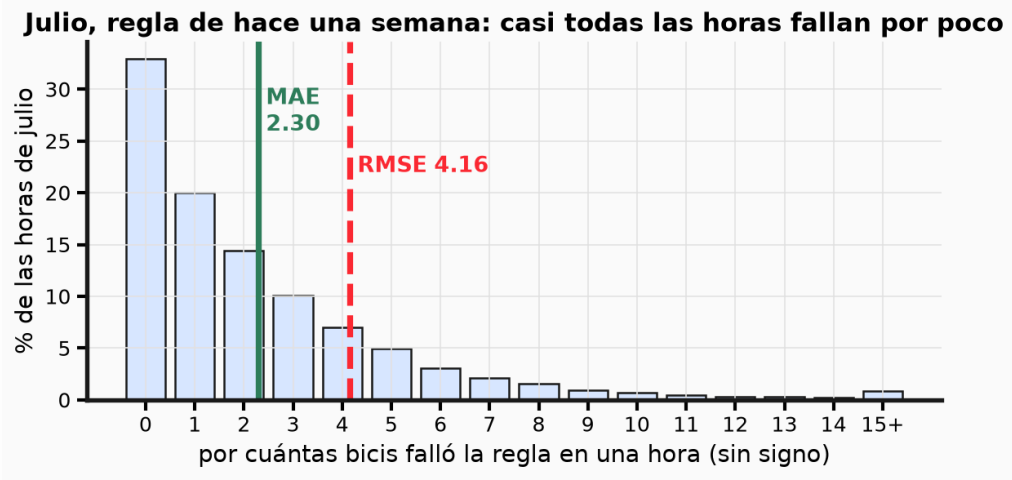
Cómo se lee junto al MAE: si el RMSE queda muy por encima del MAE, hay pocas horas con errores grandes. Si quedan parecidos, los errores son de tamaño parejo.

Cuál elegir: MAE si cada bici cuesta igual; RMSE si un error grande es mucho más grave.

Más bajo es mejor.

$RMSE = \sqrt{MSE}$: el promedio de los cuadrados, con raíz para regresar a bicis.

¿QUÉ ES UNA HORA TÍPICA?



En 2 de cada 3 horas la regla falla por 2 bicis o menos. Unas pocas horas con errores enormes suben el RMSE.

MAE: el error de una hora típica. **RMSE:** el que se fija en los errores grandes.

PASO 1. DOS MODELOS: ¿CUÁL ES MEJOR?

Hora	Error de A	Error de B
3 h	0	3
6 h	0	3
11 h	0	3
15 h	0	3
18 h (pico)	**10**	3

A: casi perfecto, pero en la hora pico falla feo.

B: nunca atina exacto, pero siempre falla poquito.

Antes de hacer cuentas: ¿a cuál le confían su estación?

PASO 2. CON EL MAE: CADA BICI CUENTA IGUAL

Hora	A	B
3 h	0	3
6 h	0	3
11 h	0	3
15 h	0	3
18 h	10	3
Suma	**10**	**15**
Entre 5 horas	**2**	**3**

MAE de A = **2** bicis. MAE de B = **3** bicis.

Con el MAE gana A: en una hora típica falla menos.

PASO 3. CON EL CUADRADO: UNA LUPA SOBRE LOS ERRORES GRANDES

Hora	A^2	B^2
3 h	0	9
6 h	0	9
11 h	0	9
15 h	0	9
18 h	**100**	9
Suma	**100**	**45**
Entre 5	20	9
Raíz: RMSE	**4.47**	**3**

El 10 de A se volvió **100**. Los 3 de B solo se volvieron 9.

Con el RMSE gana B: el cuadrado castiga el error grande de A.

PASO 4. ¿QUIÉN TIENE RAZÓN? DEPENDE DE QUÉ DUELE

Uso el MAE si cada bici de error cuesta lo mismo.

Ejemplo: una estación de barrio donde nadie se queda varado por 3 bicis.

Gana **A**.

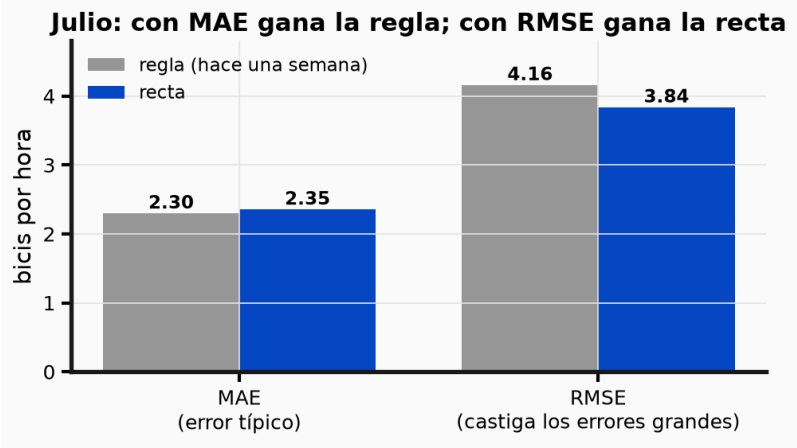
Uso el RMSE si un error grande cuesta mucho más.

Ejemplo: la estación del estadio en día de partido; quedarse sin bicis genera quejas.

Gana **B**.

Primero se decide qué error duele; después se escoge el modelo.

PASO 5. LA VOTACIÓN DE AYER: LA REGLA ES A, LA RECTA ES B



Julio	MAE	RMSE
Regla (como A)	**2.30**	4.16
Recta (como B)	2.35	**3.84**

La regla casi siempre atina, pero en días raros (un festivo, un concierto) falla en grande. La recta es más pareja.

Con el MAE gana la regla; con el RMSE gana la recta. Ninguna métrica está mal.

EL COSTO J DE AYER ES EL MSE ENTRE 2

Ayer, para escoger la recta, usamos el **costo J**:

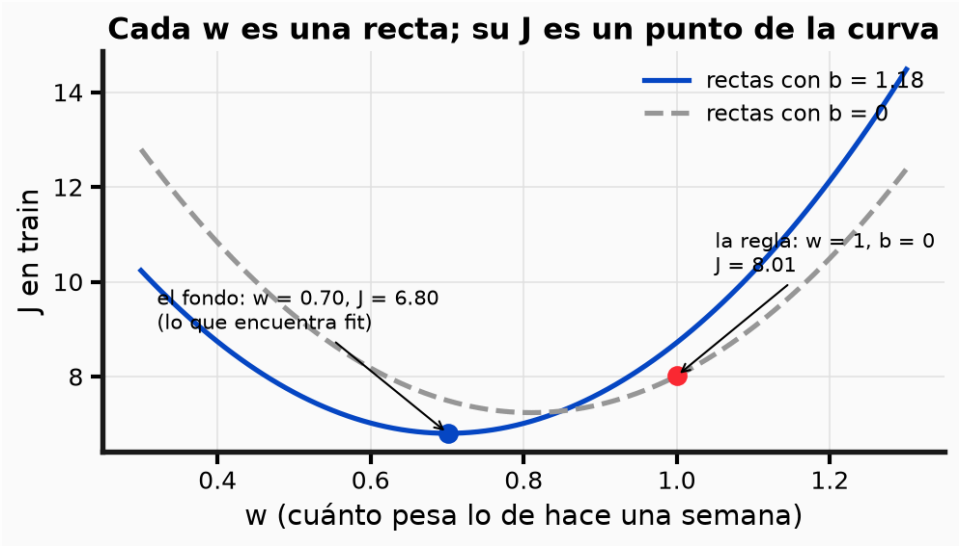
$$J(w,b) = \frac{1}{2m}\sum_{i=1}^{m}\left(\hat{y}^{(i)} - y^{(i)}\right)^2 = \frac{MSE}{2}$$

m es el número de filas, como n en las métricas. SSE es la suma; MSE = SSE / m; J = MSE / 2.

- J es el mismo MSE, partido entre 2. Recta en julio: MSE 14.73, J = 7.36.
- El ½ solo simplifica una cuenta: al derivar el cuadrado baja un 2, y el ½ lo cancela.
- Dividir todo entre 2 no mueve el mínimo: la mejor recta sigue siendo w = 0.70, b = 1.18.

Para escoger la recta da igual minimizar J, el MSE o el RMSE: las tres eligen la misma.

EL FONDO DE J: LO QUE ENCUENTRA FIT



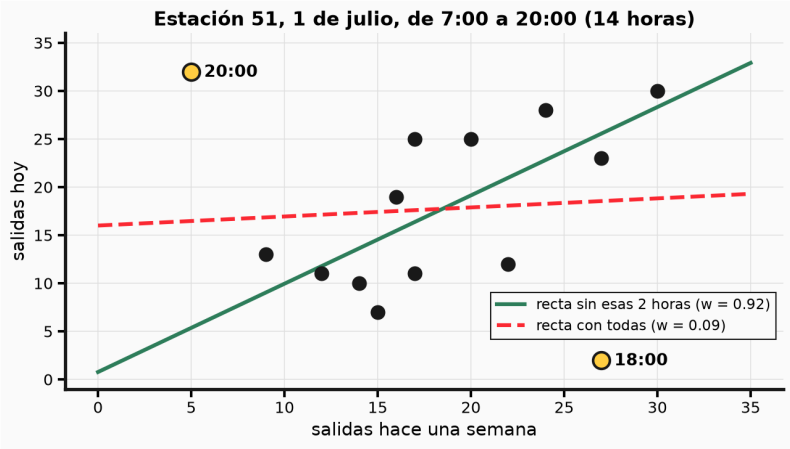
La regla de "hace una semana" es la recta w = 1, b = 0. No está en el fondo: fit encuentra una mejor, w = 0.70 y b = 1.18.

OUTLIERS: LAS HORAS RARAS

Outlier: una hora que se aleja mucho de las demás. Puede ser un error o algo que de verdad pasó (NIST/SEMATECH, 2012).

Por qué jala la recta: la recta minimiza el error al cuadrado. Una hora que falla por 25 pesa 625, como 25 horas que fallan por 5.

La pregunta no es "¿la borro?", sino "¿por qué pasó?".

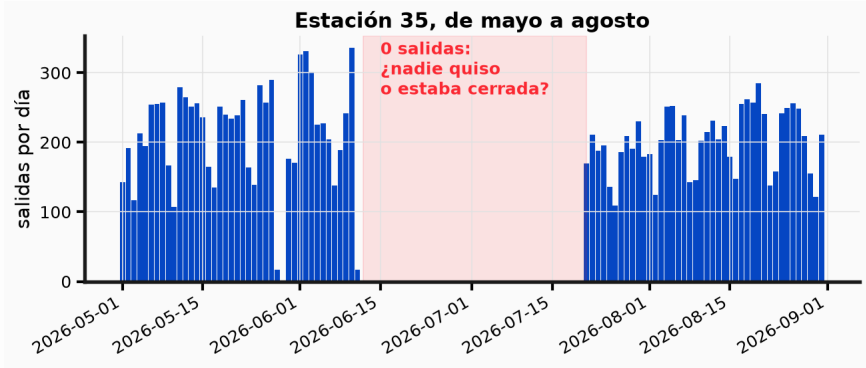


Dos horas de 14 bajan el peso de la recta de 0.92 a 0.09.

¿SE QUITA O SE DEJA?

- **Se quita** si no pertenece: error de captura, estación cerrada, algo que no se repite.
- **Se deja** si es real y se repite: partidos, conciertos, lluvia, quincena.
- **En medio:** medir con MAE o agregar una columna que explique el evento (Hyndman y Athanasopoulos, 2021).

Nunca se quita sin saber por qué.



OUTLIERS Y DATOS FALTANTES: UN TEMA ENTERO

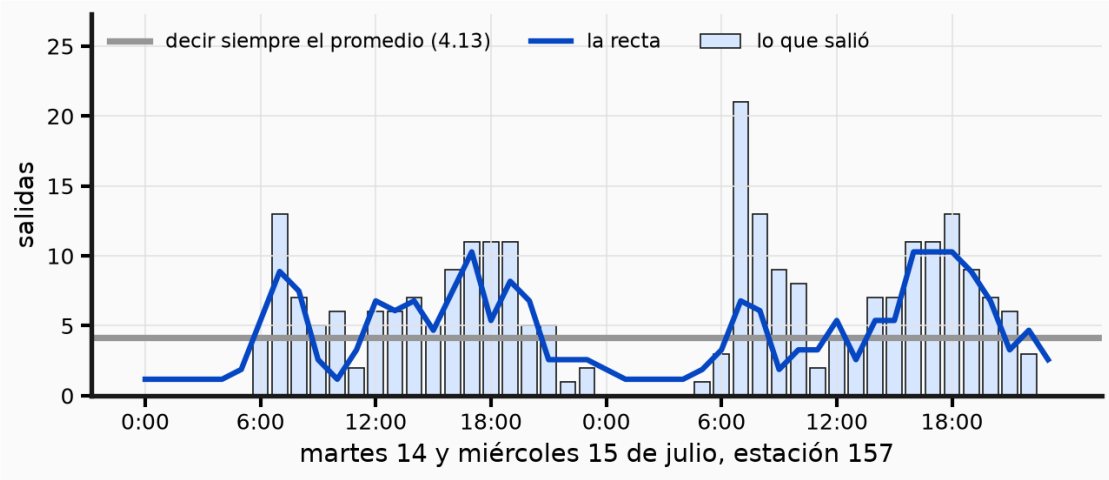
Qué hacer con datos raros y con datos que faltan (**imputación**: llenar un hueco con un valor razonable) es un tema completo: hay cursos y libros enteros sobre eso. Hoy, la receta para empezar:

1. **Mirar antes de tocar:** `df.describe()`, un histograma o un diagrama de caja.
2. **Preguntar por qué** está raro o vacío: ¿error, estación cerrada, evento real?
3. **No borrar sin razón**, y anotar lo que se hizo.
4. **Si falta un número**, llenarlo con la mediana de train y agregar una columna "faltaba" (`SimpleImputer(strategy="median", add_indicator=True)`).
5. **En series de tiempo**, el valor anterior suele ser mejor que la mediana.

La regla de oro también aplica aquí: la mediana o el promedio para llenar huecos se calculan **solo con train**. Si se calculan con todo el año, es fuga.

Para profundizar: la documentación de imputación de scikit-learn y Kuhn y Johnson (2019), capítulo 8.

¿Y SI DIGO SIEMPRE EL PROMEDIO?



La línea gris no sabe nada y falla mucho. La pregunta es cuánto de ese error le quita el modelo.

Esa comparación tiene nombre: **R^2**, coeficiente de determinación.

R^2: ¿CUÁNTO LE GANO AL PROMEDIO?

La competencia más tonta: decir siempre el promedio de julio, 4.13 bicis, a todas horas.

En julio	R^2
Decir el promedio	0
Regla de hace una semana	**0.41**
Recta	**0.50**

1: perfecto en esos datos. **0:** igual que el promedio. **Negativo:** peor que el promedio.

La recta, 0.50: le quita la mitad del error al cuadrado que tendría el promedio.

No busquen el 1: un R^2 de 1 en train suele ser sobreajuste. Compárenlo en train y en validación.

Más alto es mejor.

$R^2 = 1 - \frac{SSE \text{ del modelo}}{SSE \text{ de decir el promedio}}$: qué parte del error del promedio le quitó el modelo.

NO SE COMPARAN ENTRE SÍ

Mal: "el MAE es 4 y el RMSE es 5, entonces el MAE es mejor".

Son dos reglas de medir distintas, como centímetros y pulgadas. El RMSE casi siempre sale más grande que el MAE.

Bien: cada métrica contra sí misma, entre modelos.

En julio	Regla	Recta	Gana
MAE (más bajo)	**2.30**	2.35	regla
RMSE (más bajo)	4.16	**3.84**	recta
R^2 (más alto)	0.41	**0.50**	recta

MAE, MSE, RMSE y SSE: menor es mejor. R^2: mayor es mejor.

TRAIN, VALIDACIÓN Y PRUEBA: TRES PATRONES

Modelo (cifras de MiBici)	R^2 train	R^2 julio	MAE train	MAE julio	Patrón
Árbol sin límite, 7 columnas	**1.00**	0.33	0.02	2.53	**Sobreajuste:** memorizó train
Decir siempre el promedio	0.00	0.00	3.53	3.59	**Subajuste:** malo en todo
Árbol con 8 niveles, 7 columnas	0.63	0.60	1.83	1.93	**Bien:** bueno y parecido

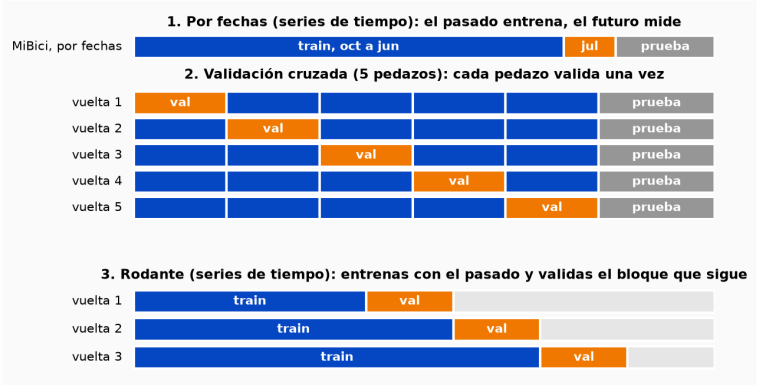
- **Train muy bueno y validación mucho peor:** sobreajuste.
- **Todos malos:** subajuste.
- **Todos buenos y parecidos:** generaliza bien.

¿Y SI USO LA PRUEBA MUCHAS VECES?

Validación: el examen de práctica. Se usa las veces que haga falta para escoger.

Prueba: el examen final. Una sola vez, al final.

> Si veo la calificación de prueba, cambio el modelo y vuelvo a ver, ya escogí con ella: **la prueba se volvió validación** y ya no dice cómo le irá al modelo con datos nuevos.



Validación cruzada: otra forma de validar. Train se parte en pedazos y cada pedazo sirve de validación una vez. Con tiempo de por medio, la rodante.

MEZCLAR DOS REGLAS CON UN PESO

Una mezcla: la predicción es un promedio con pesos de dos reglas. El peso w va de 0 a 1.

$$\hat{y} = w \times A + (1 - w) \times B$$

Cómo se lee: w es cuánto le creo a A; lo que falta para 1 se lo creo a B.

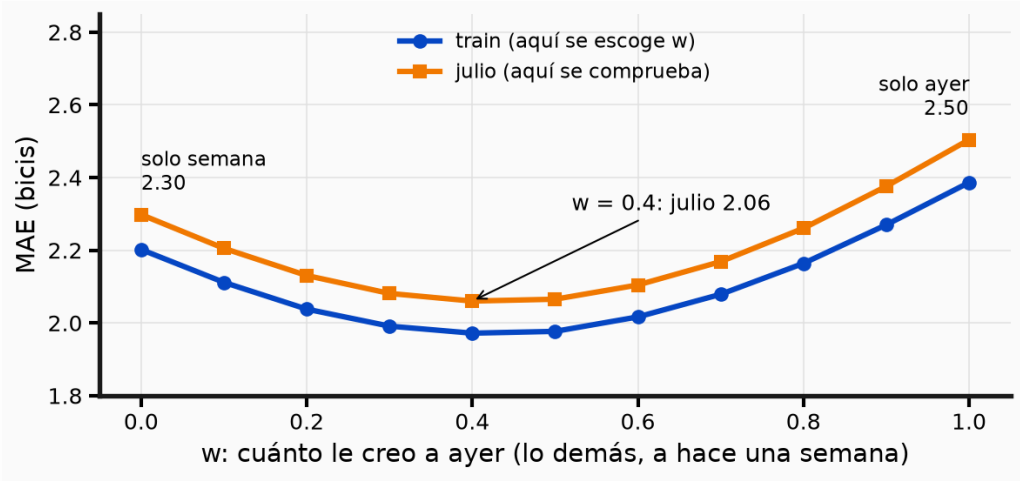
A dice 20 bicis, B dice 30, y $w = 0.4$:

$$0.4 \times 20 + 0.6 \times 30 = 8 + 18 = 26$$

w	queda
1	A sola: 20
0.4	26
0	B sola: 30

Ayer en el Lab 1: A = ayer, B = hace una semana, $w = 0.4$. MAE en julio: **2.06**, mejor que 2.30.

¿QUÉ PESO LE DAMOS A AYER?



El mejor peso en train es 0.4, y en julio también funciona: 2.06, contra 2.30 de la semana sola.

Escoger w con train y comprobarlo en julio: **ajustar** con train, **validar** con julio.

PARA ESCOGER LA MÉTRICA, EN UNA TABLA

Pregunta de negocio	Métrica	Cómo se lee
¿Por cuántas bicis fallamos en una hora típica?	**MAE**	en bicis
¿Fallamos en grande algunas horas?	**RMSE** (al lado del MAE)	en bicis; si es mucho mayor que el MAE, sí
¿Mejoramos contra decir siempre el promedio?	**R^2**	1 perfecto, 0 igual, negativo peor
¿Qué tan relacionadas están dos columnas?	**Pearson, r**	de −1 a 1; fuerte arriba de 0.6
¿Por qué porcentaje fallamos?	**MAPE**, solo si la y nunca es 0	en MiBici no: hay ceros

La métrica se escoge antes de ver resultados, según la pregunta de negocio. Escogerla después es escoger la que hace ganar a tu modelo.

HOJA: ¿CUÁNTAS BICIS SALEN MAÑANA A LAS 8?

Ábranla en salas (15 min):

https://colab.research.google.com/github/HesusG/dammg-supervisado/blob/main/notebooks/salas/S2_hoja_metricas.ipynb

La solicitud: "¿Cuántas bicis van a salir mañana a las 8 de su estación y qué tan confiable es el número?"

1. **Los datos:** corran y escojan su estación de la lista de 40.
2. **El modelo:** cambien `estacion = 51` por la suya; comparen la regla y la recta.
3. **La medición:** MAE, RMSE y R^2 de su estación en julio. Ojo con el MAPE.
4. **La respuesta:** tres renglones: el número, qué tan seguro, recomendación y riesgo.

Dejen su respuesta escrita en la hoja; al volver, la revisamos juntos.

REFERENCIAS DE LA SECCIÓN 1

Hyndman, R. J., y Athanasopoulos, G. (2021). *Forecasting: Principles and practice* (3a ed.). OTexts. Secciones 5.8 (https://otexts.com/fpp3/accuracy.html) y 13.9 (https://otexts.com/fpp3/missing-outliers.html).

NIST/SEMATECH. (2012). *e-Handbook of statistical methods*, sección 7.1.6, What are outliers in the data? https://www.itl.nist.gov/div898/handbook/prc/section1/prc16.htm

scikit-learn. (s. f.). *Metrics and scoring: Quantifying the quality of predictions*. Consultado el 31 de octubre de 2026. https://scikit-learn.org/stable/modules/model_evaluation.html

Starmer, J. (2015, 3 de febrero). *R-squared, clearly explained!!!* Video. YouTube. https://www.youtube.com/watch?v=2AQKmw14mHM

PAUSA DE 10 MIN

Lejos de la pantalla. Agua, estírate, mira por la ventana.

REGRESAMOS EN **10:00**

SECCIÓN 2 | Características derivadas | ⏱ 11:09 a 11:53

DARLE AL MODELO LO QUE UN ENCARGADO DE MIBICI YA SABE

Cinco familias de columnas nuevas, cuánto ayuda cada una y cómo no hacer trampa sin querer.

¿QUÉ ES UNA CARACTERÍSTICA DERIVADA?

las que traen los datos | las que inventamos

hora	estación	salidas (y)	hace 24 h	hace 168 h	¿hora = 8?	¿est. 51 y hora 8?
7:00	51	31	30	34	0	0
8:00	51	29	22	26	1	1
9:00	51	18	31	25	0	0
8:00	11	14	5	8	1	0

Jueves 28 de mayo de 2026, datos reales de train.

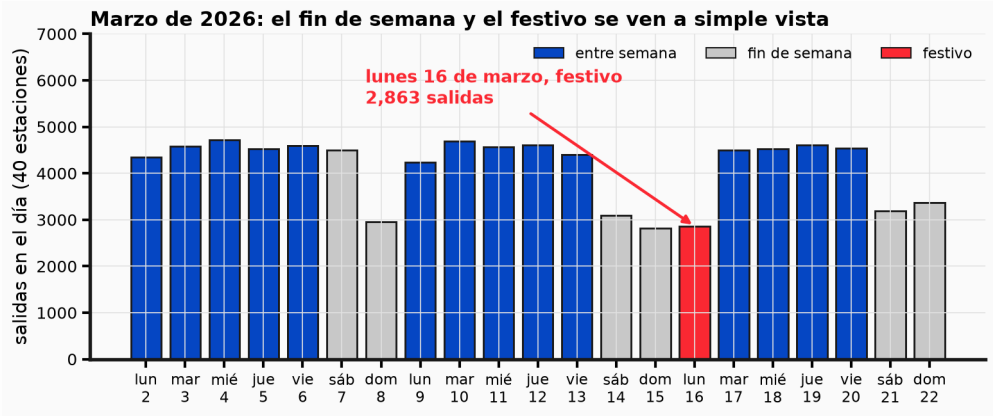
Una **columna nueva que inventamos** con las que ya tenemos.

- Sirve para darle al modelo lo que un encargado ya sabe: "la 51 se vacía a las 8".
- El modelo no cambia. Cambia la tabla que le damos.
- En inglés: *feature engineering*.

CINCO FAMILIAS

FAMILIA	LO QUE DIRÍA EL ENCARGADO
Calendario	"Es lunes a las 8 y no es festivo."
Rezagos	"Ayer a esta hora salieron 22; el jueves pasado, 26."
Promedios móviles	"Esta semana la estación anduvo floja."
Por grupo	"A las 8, entre semana, en la 51 salen como 29."
Interacciones	"La 51 se vacía en la mañana y la 194 en la tarde."

FAMILIA 1: CALENDARIO



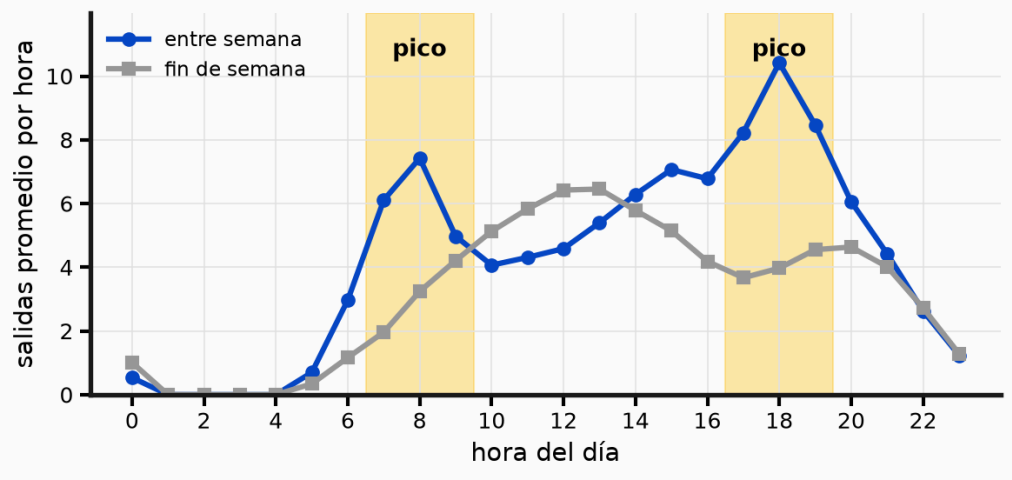
Problema: la recta no sabe qué día es. **Para operaciones:** no mandar camión un festivo como si fuera lunes normal.

Ya vienen: `hour_of_day`, `day_of_week`, `is_weekend`, `month`.

Se derivan de `hour`:

```
h = df.hour
pico = [7, 8, 9, 17, 18, 19]
df["pico"] = df.hour_of_day.isin(pico)
df["quincena"] = h.dt.day.isin([15, 30])
df["festivo"] = h.dt.date.isin(FESTIVOS)
```

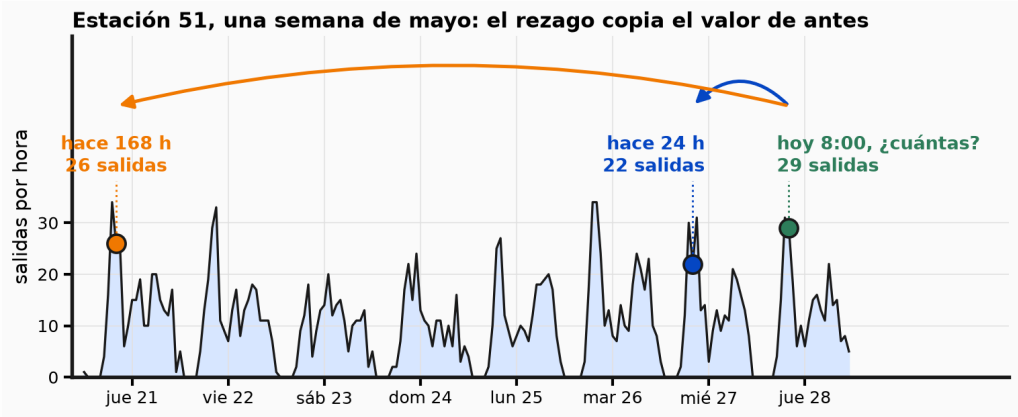
¿A QUÉ HORAS SALE MÁS GENTE?



Entre semana hay dos picos, de 7 a 9 y de 17 a 19. El fin de semana, no.

Columna nueva: **pico**, verdadero o falso. En hora pico salen el doble: 6.65 contra 3.21.

FAMILIA 2: REZAGOS



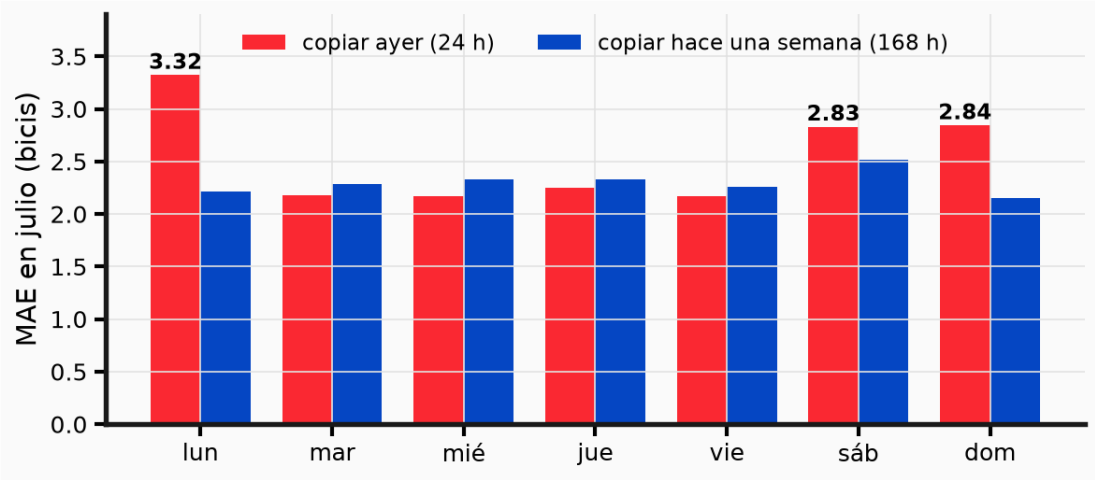
Problema: la recta no sabe qué pasó antes. **Para operaciones:** si ayer se vació, hoy probablemente también.

Ejemplos: ayer a esta hora (24 h); hace una semana a esta hora (168 h).

```
df["mi_rezago"] = (df.groupby("station_id")
                     .departures.shift(24))
```

El `groupby` evita copiar el dato de otra estación.

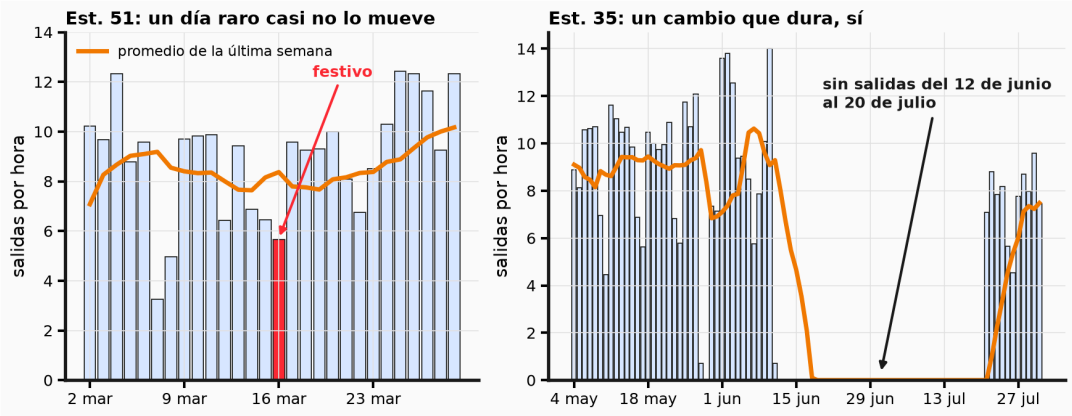
¿QUÉ REZAGO SE EQUIVOCA MÁS LOS LUNES?



Copiar ayer: el lunes copia al domingo. Hace una semana compara lunes con lunes.

En todo julio: copiar ayer, MAE 2.50; copiar hace una semana, 2.30. Al modelo le damos **los dos rezagos**.

FAMILIA 3: PROMEDIOS MÓVILES



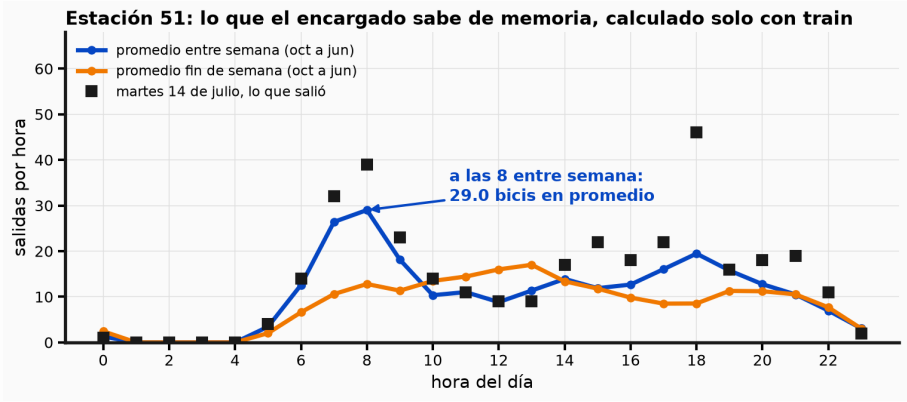
Problema: un rezago copia un solo día, aunque haya sido raro.
Para operaciones: saber si la estación anda más floja o más movida que de costumbre.

Ejemplos: el promedio de las últimas 24 horas; el de la última semana.

Ya vienen: `departures_mean_24h` y `departures_mean_168h`.

```
df.groupby("station_id").departures.transform(
    lambda s: s.shift(24).rolling(168).mean())
```

FAMILIA 4: POR GRUPO



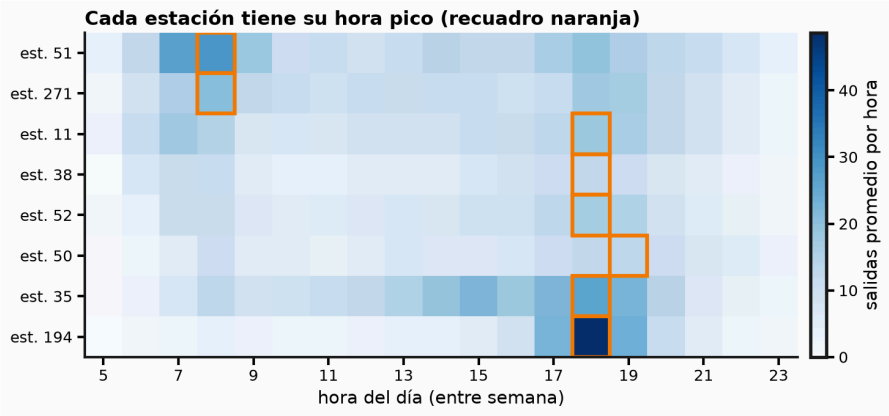
Problema: la recta no sabe cómo es un día normal en cada estación. **Para operaciones:** es lo que el encargado sabe de memoria, escrito en una columna.

Es la tabla de S1, que dio **1.95** en julio.

```
train = df[df.particion == "train"]
tabla = train.groupby(
    ["station_id", "hour_of_day",
     "is_weekend"]).departures.mean()
```

Cuidado: solo con train. Con julio, el modelo vería las respuestas.

FAMILIA 5: INTERACCIONES



Problema: cada estación tiene su propia hora pico. **Para operaciones:** el camión va a la 51 en la mañana y a la 194 en la tarde.

Ejemplos: estación × hora; estación × hora × tipo de día.

```
est = df.station_id.astype(str)
hora = df.hour_of_day.astype(str)
df["est_hora"] = est + "_" + hora
```

Luego `OneHotEncoder`: una columna de 0 y 1 por pareja.

LA INTERACCIÓN: CADA ESTACIÓN CON SU PROPIO HORARIO

Promedio de salidas entre semana, en train:

	8:00	18:00
Estación 51	29.0	19.5
Estación 194	3.1	48.7

La 51 se vacía en la mañana; la 194, en la tarde.

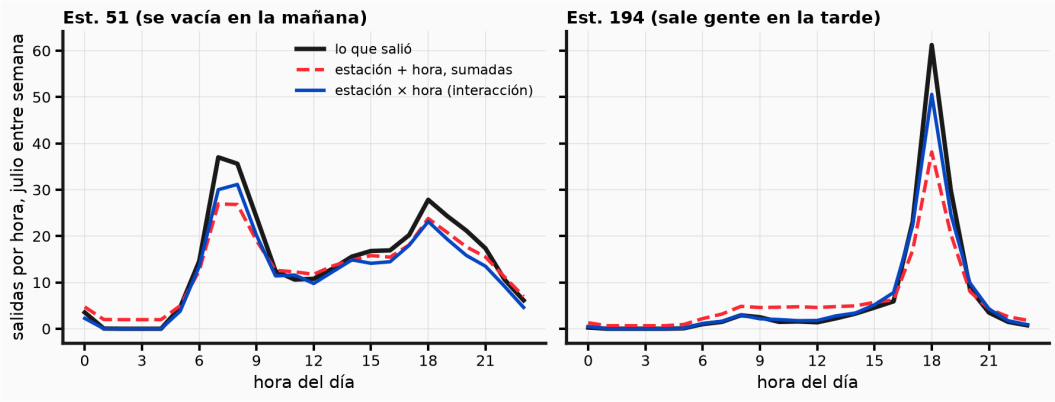
Con columnas sueltas (estación por un lado, hora por otro), la recta suma: "lo de la estación" más "lo de la hora". Las 18:00 suman lo mismo en todas las estaciones. Lo que predice:

	8:00	18:00
51	15.2	33.3
194	16.9	34.9

Se equivoca en las cuatro: no puede dar un horario distinto a cada estación.

Con la interacción (una columna por pareja: "51 a las 8", "194 a las 18"...), cada estación tiene su propio horario y acierta los cuatro promedios.

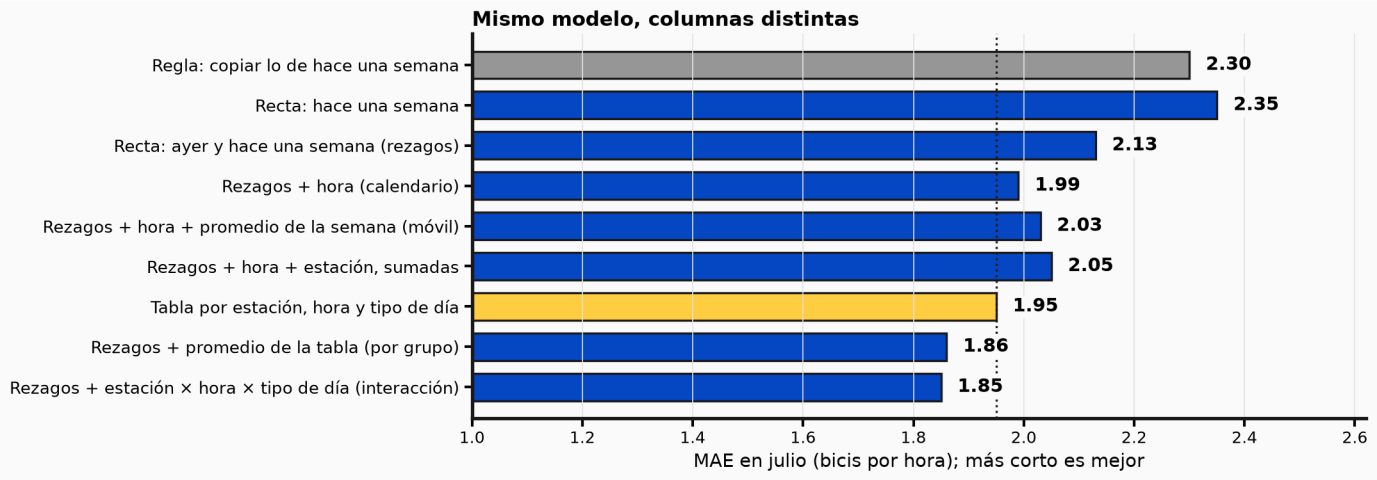
LA INTERACCIÓN CON TODO JULIO



Columnas sueltas, con rezagos: **MAE 2.05**. Con interacción y rezagos: **1.85**.

Familia 4 le **da** el promedio de la pareja. Familia 5 deja que el modelo lo **aprenda**. Llegan a casi lo mismo: 1.86 y 1.85.

¿CUÁNTO AYUDA CADA UNA?



VOTACIÓN 1 DE 2: ¿LE CREEMOS?

¿QUÉ PASA SI…?

menti.com, código 5604 3265

Un practicante dice que su modelo falla por 0.3 bicis. El mejor que conocemos falla por 1.85. ¿Qué haces?

A. Lo uso ya: es seis veces mejor

B. Reviso a qué hora se conoce cada columna

C. Le pido más columnas

HOJA: COLUMNAS PARA TU ESTACIÓN (15 MIN)



Operaciones pide: escoge dos columnas para mejorar el pronóstico de tu estación y di cuánto baja el error en julio.

Después: un practicante reporta un error de 0.00. ¿Le creemos?

Solo editan `estacion` y `mis_columnas`.

https://colab.research.google.com/github/HesusG/dammg-supervisado/blob/main/notebooks/salas/S2_hoja_derivadas.ipynb

Fuentes: Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and practice* (3a ed.). OTexts. https://otexts.com/fpp3/. Kaufman, S., Rosset, S., Perlich, C., & Stitelman, O. (2012). Leakage in data mining: Formulation, detection, and avoidance. *ACM Transactions on Knowledge Discovery from Data, 6*(4), 1-21. https://doi.org/10.1145/2382577.2382579

SECCIÓN FUGA | Fuga de información | ⏱ 11:53 a 12:43

FUGA DE INFORMACIÓN

¿QUÉ SABE QUIEN COPIÓ EN EL EXAMEN?

Un alumno consigue las respuestas un día antes y saca **10**.

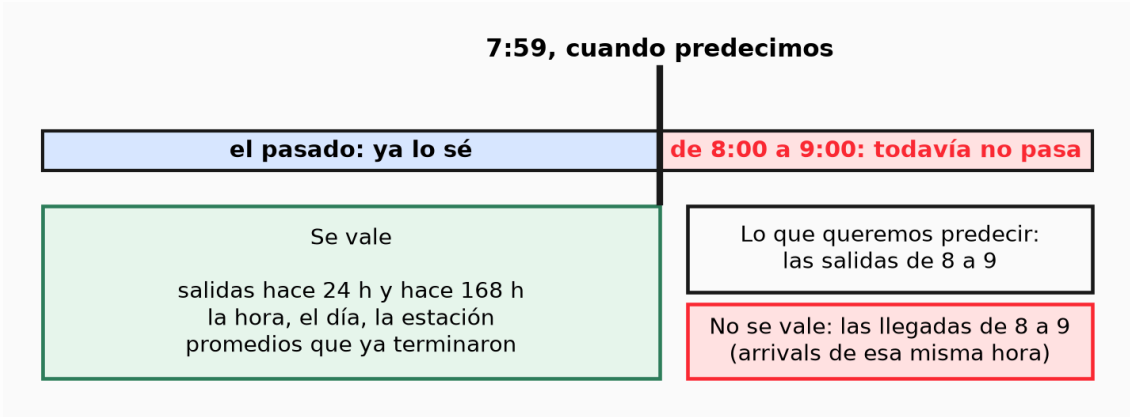
El 10 es real. Lo que **no** es real es lo que dice de él: en el siguiente examen, sin respuestas, no sabe nada.

Un modelo que en el entrenamiento ve un dato **que viene de la respuesta** saca un error bajísimo.

En la operación ese dato no está, y el modelo se cae.

Eso se llama fuga de información (en inglés, *data leakage*).

¿A QUÉ HORA CONOZCO ESTA COLUMNA?



Solo se vale lo que ya sabía en el momento de predecir.

CELDA 1: LOS DATOS, PARTIDOS POR FECHAS

```
# Celda 1
df = pd.read_parquet(RUTA_DATOS)
df["est_hora_finde"] = (df.station_id.astype(str) + "_"
                        + df.hour_of_day.astype(str) + "_" + df.is_weekend.astype(str))
train = df[df.particion == "train"]    # octubre a junio: para ajustar
julio = df[df.particion == "val"]      # julio: para medir y escoger
prueba = df[df.particion == "test"]    # agosto y septiembre: el examen final
```

El pasado ajusta, el futuro mide. No imprime nada.

CELDA 2: DOS FUNCIONES PARA TODA LA SECCIÓN

```
# Celda 2
def ajusta(datos, columnas):            # la recta, ajustada SOLO con `datos`
    unos = ColumnTransformer([("oh", OneHotEncoder(), ["est_hora_finde"])],
                             remainder="passthrough")
    return make_pipeline(unos, LinearRegression()).fit(datos[columnas], datos.departures)

def mae(modelo, datos, columnas):       # el error promedio en bicis, con 2 decimales
    return round(mean_absolute_error(datos.departures, modelo.predict(datos[columnas])), 2)
```

`ajusta(train, columnas)`: entrena la recta con train.

`mae(modelo, julio, columnas)`: por cuántas bicis falla en julio.

CELDA 3: ¿CUÁNTO FALLA EL MODELO HONESTO?

```
# Celda 3
rezagos = ["departures_lag_24h", "departures_lag_168h"]   # ayer y hace una semana
honesto = rezagos + ["est_hora_finde"]                    # todo se conoce a las 7:59
modelo = ajusta(train, honesto)
print("train", mae(modelo, train, honesto), "  julio", mae(modelo, julio, honesto))
```

```
train 1.77   julio 1.85
```

1.85 bicis en julio: ese es nuestro punto de comparación.

FUGA 1, DE COLUMNA: ¿Y SI LE DOY LAS LLEGADAS?

```
# Celda 4
con_llegadas = honesto + ["arrivals"]      # las bicis que LLEGAN de 8 a 9
modelo = ajusta(train, con_llegadas)
print("julio", mae(modelo, julio, con_llegadas))
```

```
julio 1.43
```

De 1.85 a 1.43 con una sola columna. Demasiado bueno: sospechen.

Nombre técnico: **fuga de columna** (*target leakage*): una columna que solo se conoce después de la respuesta.

LA MISMA FUGA, COMPLETA: EL FLUJO NETO

```
# Celda 5
con_neto = con_llegadas + ["net_flow"]     # salidas menos llegadas de 8 a 9
modelo = ajusta(train, con_neto)
print("julio", mae(modelo, julio, con_neto))
```

`net_flow = departures - arrivals`, así que `departures = arrivals + net_flow`

```
julio 0.0
```

Error cero: no hay modelo, hay una suma.

¿LA PRUEBA LA DETECTA?

```
# Celda 6
for nombre, cols in [("honesto", honesto), ("con llegadas", con_llegadas)]:
    modelo = ajusta(train, cols)
    print(nombre, "  julio", mae(modelo, julio, cols), "  prueba", mae(modelo, prueba, cols))
```

```
honesto   julio 1.85   prueba 1.93
con llegadas   julio 1.43   prueba 1.53
```

No. La columna tramposa también está en la prueba, y ahí también gana.

FUGA 2, DE CÁLCULO: EL PROMEDIO POR GRUPO

```
# Celda 7
grupo = ["station_id", "hour_of_day", "is_weekend"]
for nombre, datos in [("solo train", train), ("todo el año", df)]:
    tabla = datos.groupby(grupo).departures.mean().rename("prom")   # el promedio de cada grupo
    pred = julio.join(tabla, on=grupo).prom                         # se lo pegamos a julio
    print(nombre, round(mean_absolute_error(julio.departures, pred), 2))
```

```
solo train 1.95
todo el año 1.91
```

Con todo el año, julio ya venía adentro del promedio.

Nombre técnico: **fuga de cálculo** (en inglés, *train-test contamination*). Mejora poco y por eso nadie la ve.

FUGA 3, AL ESCALAR: ¿CON QUÉ FILAS SACAS LA MEDIA?

```
# Celda 8
for nombre, datos in [("todo el año", df), ("solo train", train)]:
    esc = StandardScaler().fit(datos[rezagos])        # aprende la media y la desviación
    modelo = Ridge().fit(esc.transform(train[rezagos]), train.departures)
    pred = modelo.predict(esc.transform(julio[rezagos]))
    print(nombre, esc.mean_.round(2), round(mean_absolute_error(julio.departures, pred), 2))
```

$$\text{Escalar: } z = \frac{x - \text{media}}{\text{desviación}}$$

```
todo el año [4.07 4.05] 2.13
solo train [3.96 3.97] 2.13
```

El error no cambió. Igual está mal: la media de todo el año ya vio julio.

FUGA 4: PARTIR AL AZAR UNA SERIE DE TIEMPO

```
# Celda 9
hasta_julio = df[df.particion ≠ "test"]                    # octubre a julio
train_azar, val_azar = train_test_split(hasta_julio, test_size=0.1, random_state=0)
print("al azar   ", mae(ajusta(train_azar, honesto), val_azar, honesto))
print("por fechas", mae(ajusta(train, honesto), julio, honesto))
```

```
al azar    1.78
por fechas 1.85
```

Al azar, el modelo ajusta con horas de julio y mide con horas de octubre: ve el futuro.

CÓMO EVITARLA: UN PIPELINE

```
# Celda 10
modelo = make_pipeline(StandardScaler(), Ridge())   # el escalador va DENTRO del modelo
modelo.fit(train[rezagos], train.departures)        # fit solo ve train
print("media aprendida", modelo[0].mean_.round(2))
print("julio", mae(modelo, julio, rezagos))
```

```
media aprendida [3.96 3.97]
julio 2.13
```

Un solo `fit` con train: todo lo que el modelo aprende, lo aprende de train.

ANTES DE CREERLE A UN MODELO

PREGUNTA	ATRAPA
1. ¿A qué hora conozco cada columna?	La fuga de columna: arrivals, net_flow.
2. ¿Con qué filas calculé cada promedio o escala?	La fuga de cálculo y la de escalar. Solo con train, dentro de un Pipeline.
3. ¿Partí por fechas?	La partición al azar. El pasado ajusta, el futuro mide.
4. ¿El error bajó de golpe?	Lo que se escapó a las tres de arriba. Quiten columnas una por una hasta encontrar la que hace el milagro.

CIERRE: LA FUGA EN UNA FRASE

Un modelo solo puede usar lo que sabría en el momento de predecir, y aprender solo de train.

En julio: honesto 1.85; con llegadas 1.43; con flujo neto 0.00; tabla con todo el año 1.91 en lugar de 1.95; al azar 1.78 en lugar de 1.85.

PAUSA DE 18 MIN

Lejos de la pantalla. Agua, estírate, mira por la ventana.

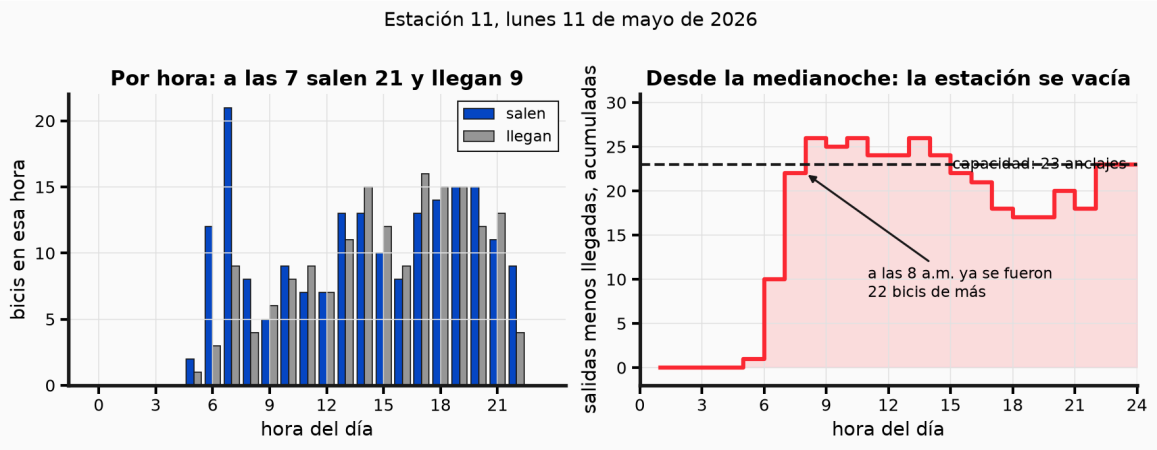
REGRESAMOS EN **18:00**

SECCIÓN 3 | Regresión logística: de cuántas bicis a sí o no | ⏱ 12:43 a 14:43

REGRESIÓN LOGÍSTICA: DE CUÁNTAS BICIS A SÍ O NO

Siguiendo paso a paso el video de StatQuest, con horas reales de MiBici.

PARTE A. ¿A QUÉ ESTACIÓN MANDAMOS EL CAMIÓN?



Primero, la pregunta de negocio y los datos.

OPERACIONES TIENE CAMIONES PARA MOVER BICIS

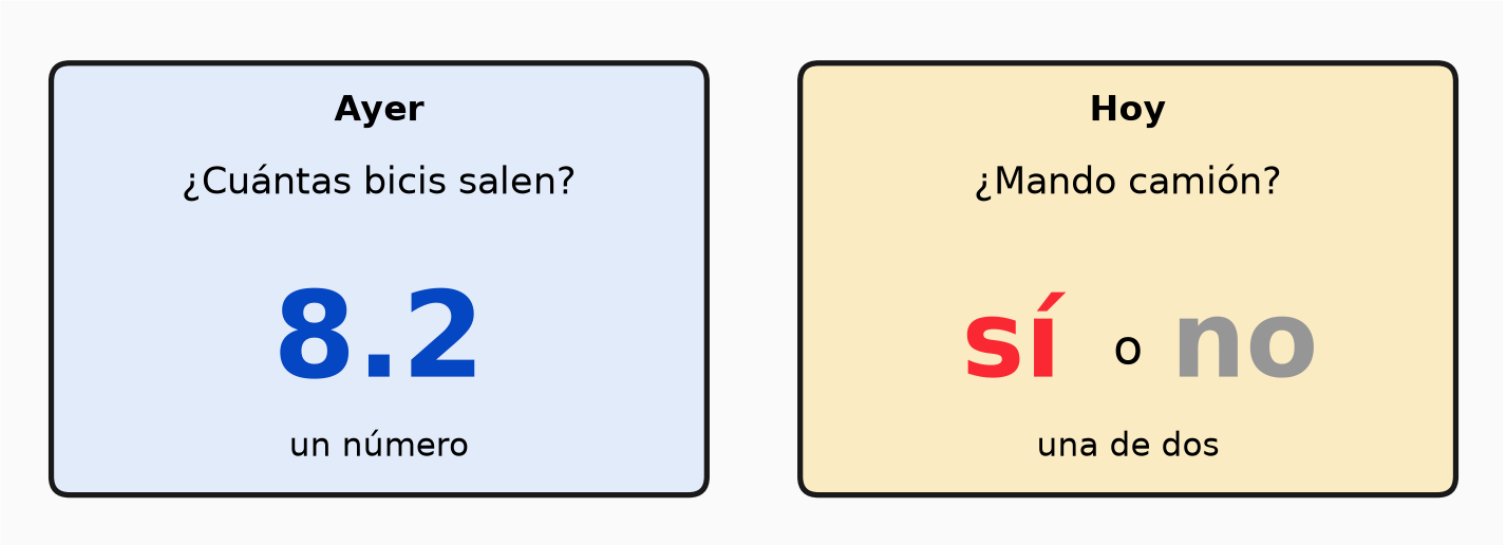


MiBici mueve bicis en camión de las estaciones llenas a las vacías.

Hay pocos camiones y muchas estaciones. Cada mañana alguien decide:

¿A qué estación mandamos uno en las próximas 3 horas?

¿QUÉ CAMBIA RESPECTO A AYER?



Ayer la respuesta era un número. Hoy es sí o no. A eso se le llama clasificación.

VOTACIÓN 2 DE 2: ¿NÚMERO O SÍ O NO?

¿QUÉ PASA SI…?

menti.com, código 5604 3265

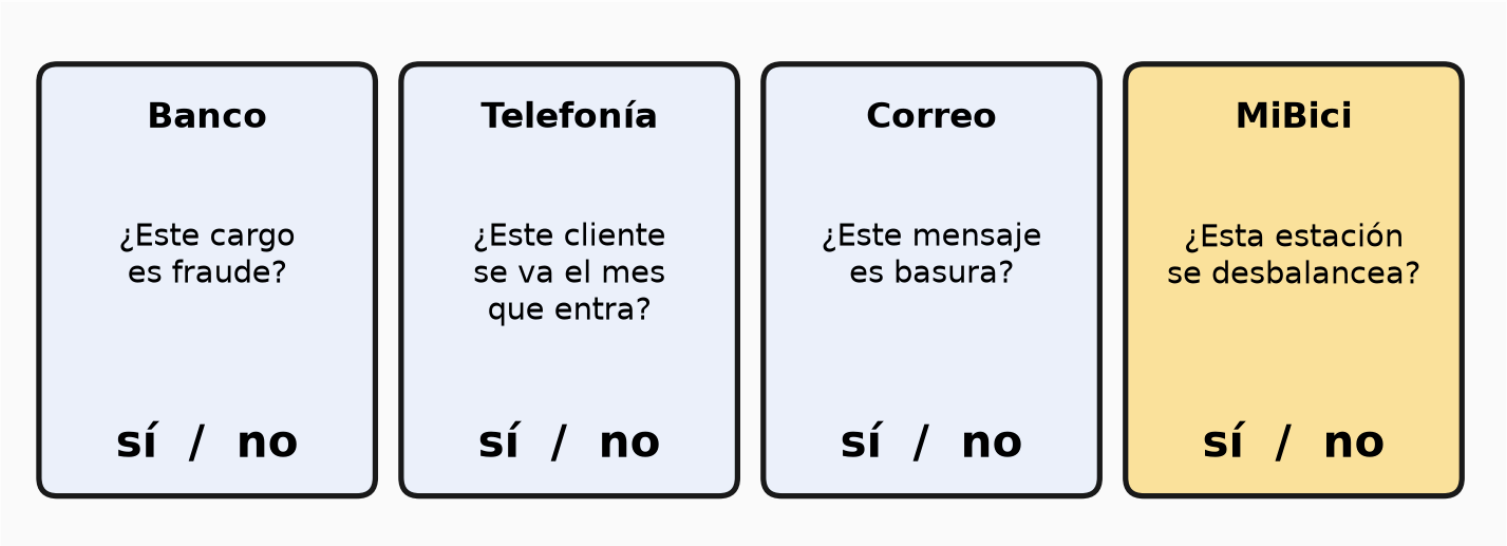
¿Cuál de estas preguntas se contesta con sí o no?

A. ¿Cuántas bicis salen a las 8?

B. ¿Esta estación se va a vaciar en las próximas 3 horas?

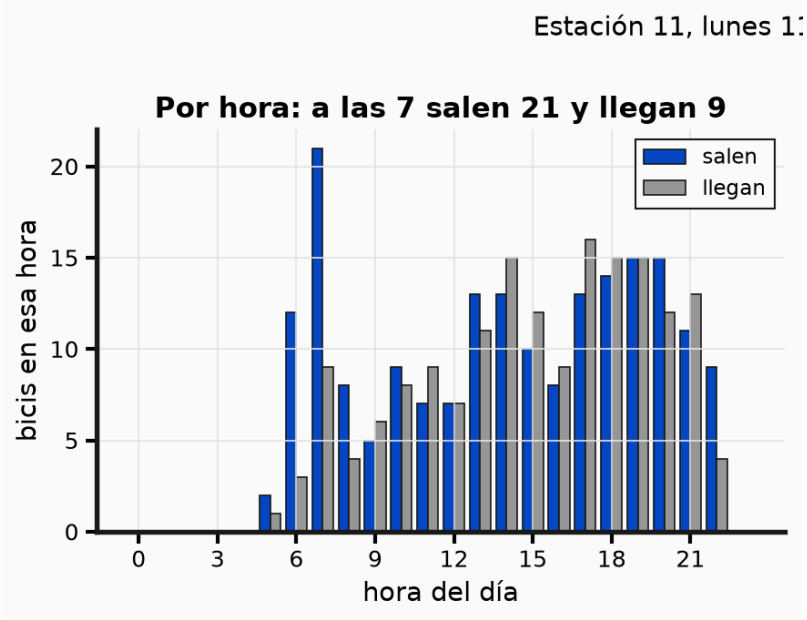
C. ¿Cuántos minutos dura un viaje?

¿DÓNDE MÁS SE PREGUNTA SÍ O NO?



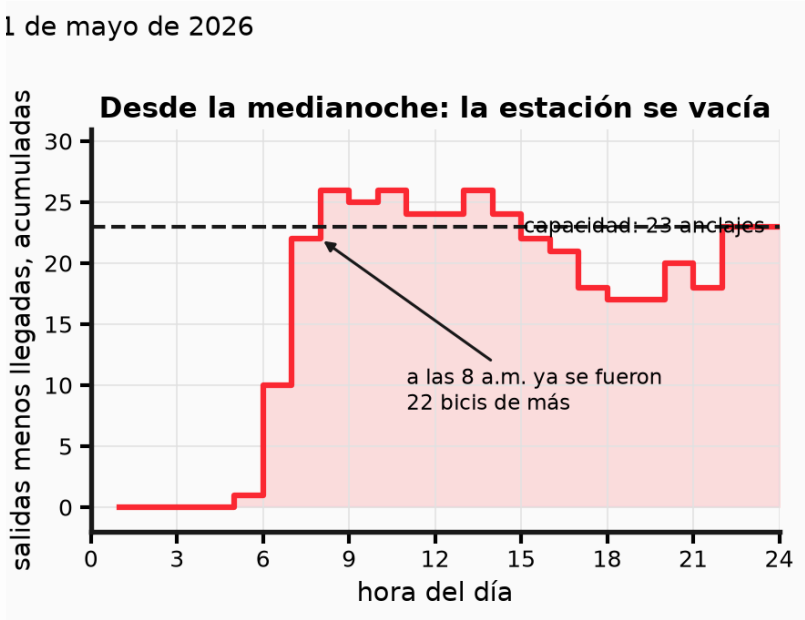
Lo que aprendamos con MiBici sirve igual para las otras tres.

¿QUÉ LE PASA A LA ESTACIÓN 11 UN LUNES?



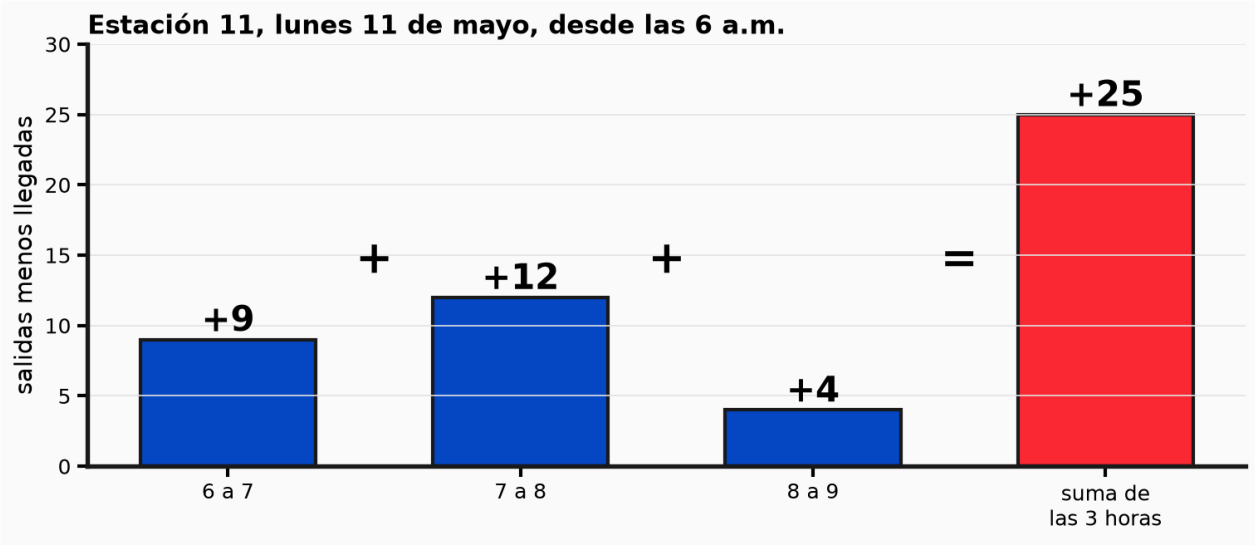
De 6 a 9 a.m. la gente sale y casi nadie llega.

¿CUÁNTAS BICIS SE FUERON DE MÁS?



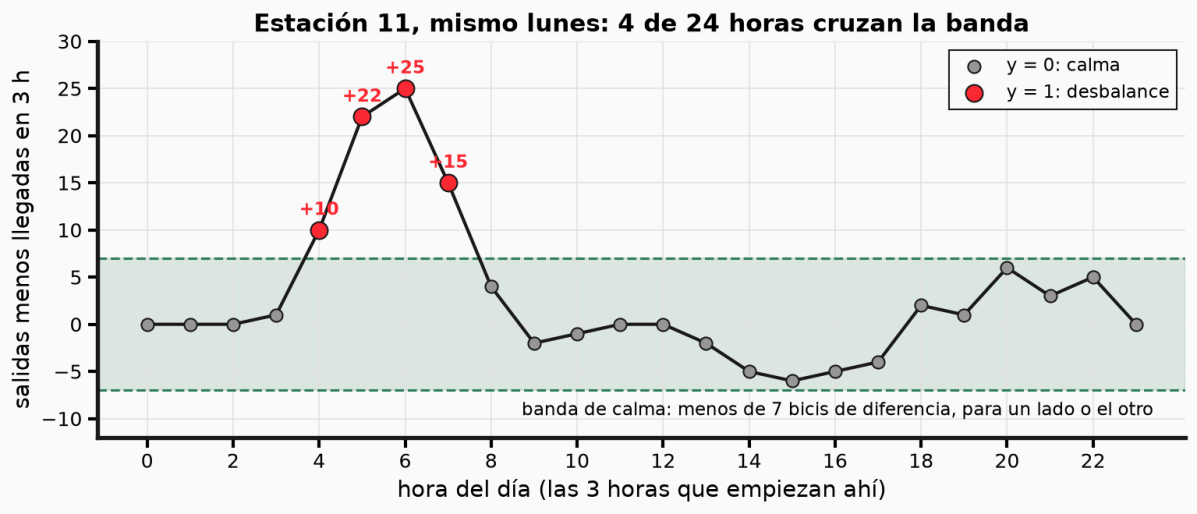
A las 8 a.m. ya se fueron 22 bicis de más. La estación tiene 23 lugares.

¿CUÁNTO SE MUEVE LA ESTACIÓN EN 3 HORAS?



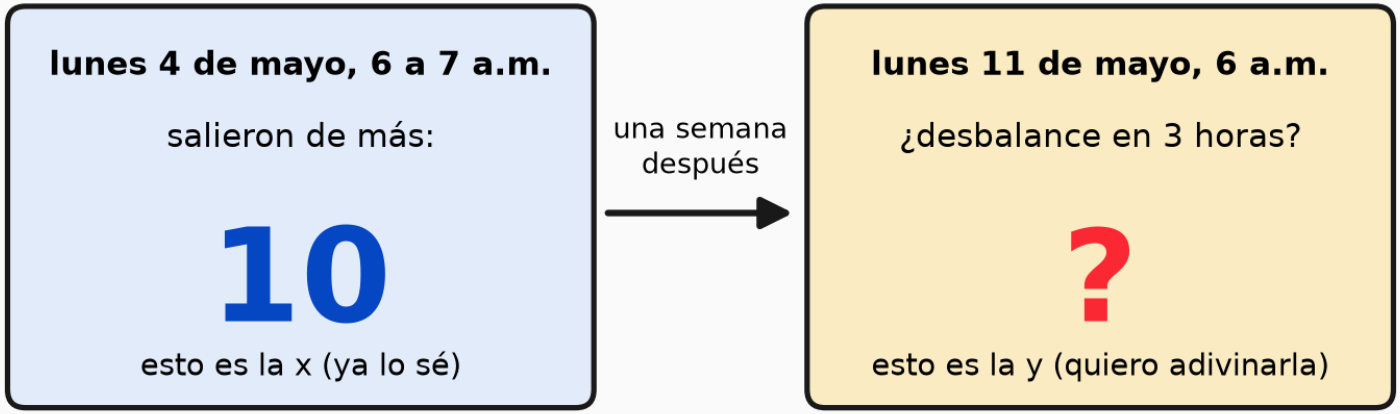
Sumo 3 horas porque es lo que tarda en llegar un camión.

¿CUÁNDO DECIMOS QUE HUBO DESBALANCE?



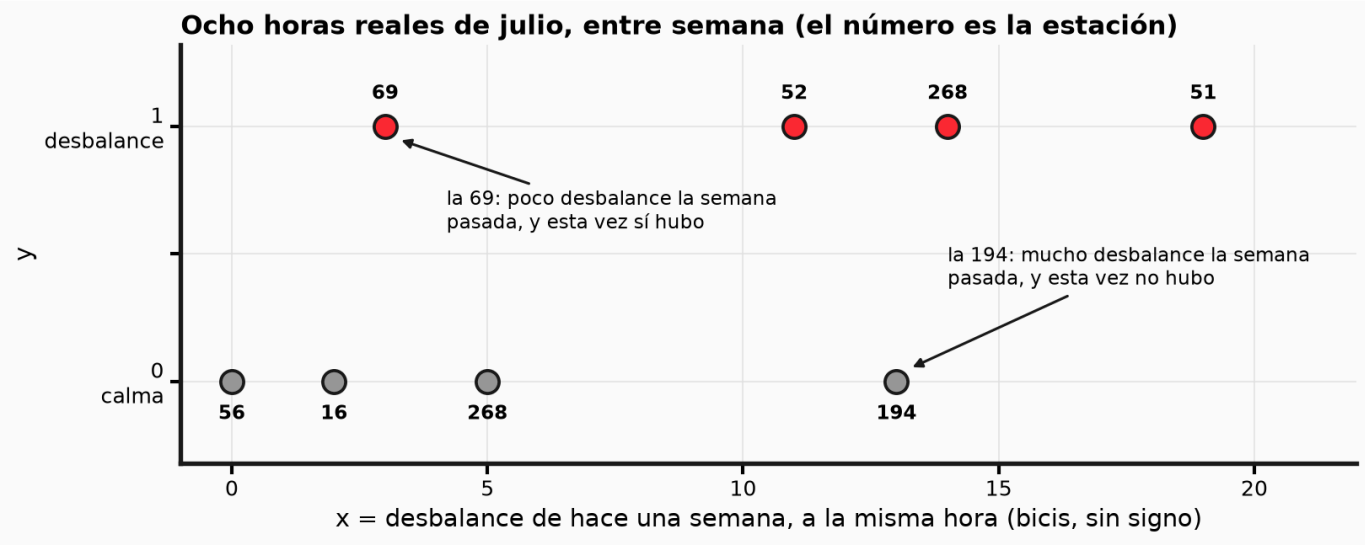
- Fuera de la banda de 7 bicis, para un lado o el otro: **1, desbalance**. Dentro: **0, calma**.
- Pasa en el **16 %** de las horas.

¿CON QUÉ DATO LO VAMOS A ADIVINAR?



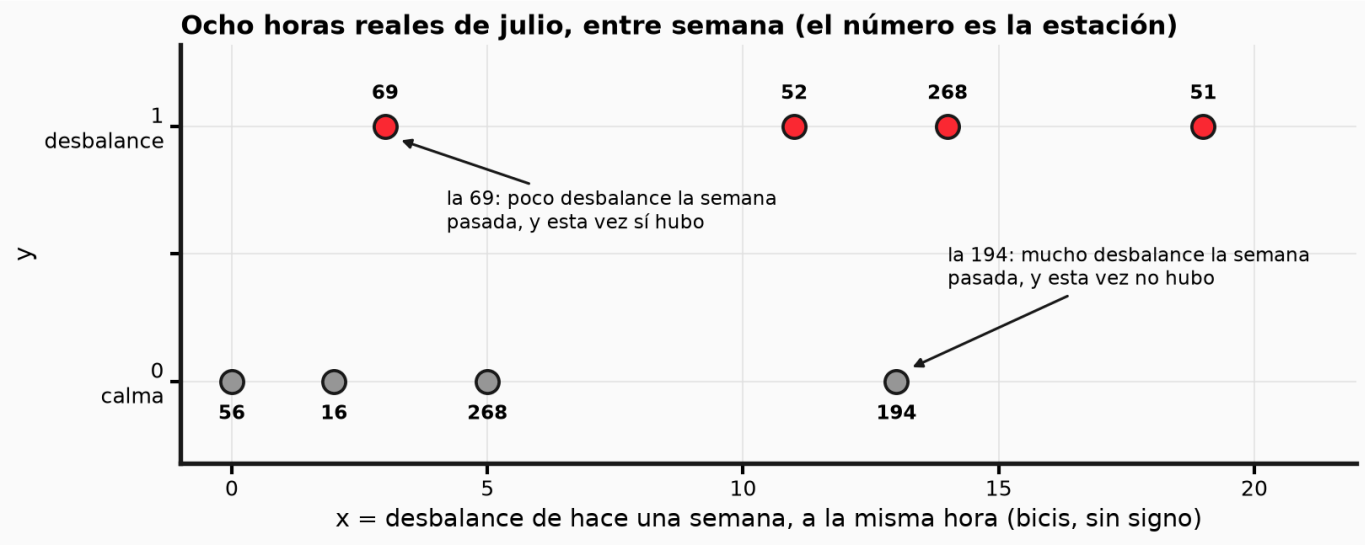
La x: el desbalance de esa misma hora, hace una semana.

OCHO HORAS REALES DE JULIO



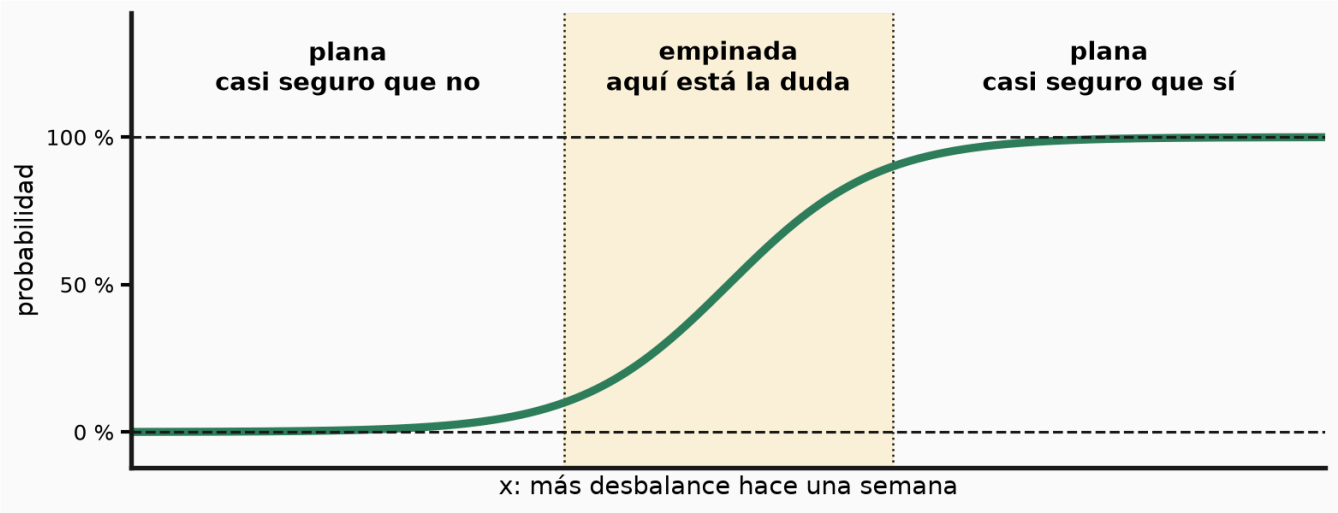
- Abajo, 4 horas de calma ($y = 0$). Arriba, 4 con desbalance ($y = 1$). El eje de abajo es la x.
- A la derecha hay más rojos, pero no es perfecto: la **69** y la **194** se portan al revés.

¿DÓNDE PONDRÍAN EL CORTE PARA MANDAR CAMIÓN?



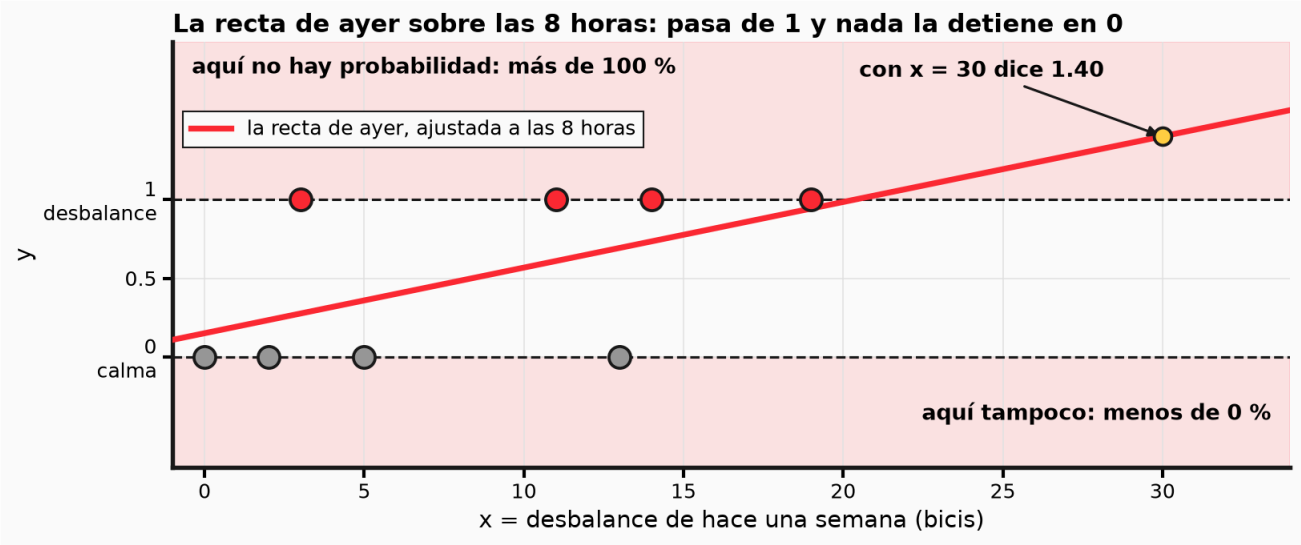
Cualquier corte se equivoca con alguna. Mejor que una regla fija: una probabilidad.

PARTE B. ¿CÓMO SACAMOS UNA PROBABILIDAD?



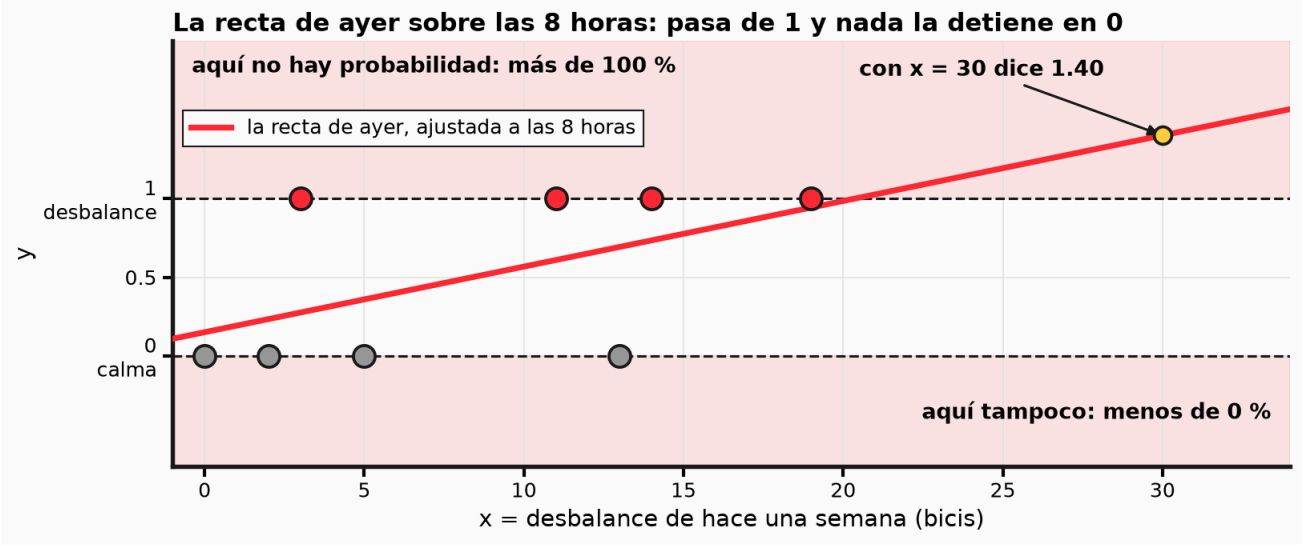
De la recta de ayer a una curva que se queda entre 0 y 1.

PRIMER INTENTO: LA RECTA DE AYER. ¿QUÉ VEN RARO?



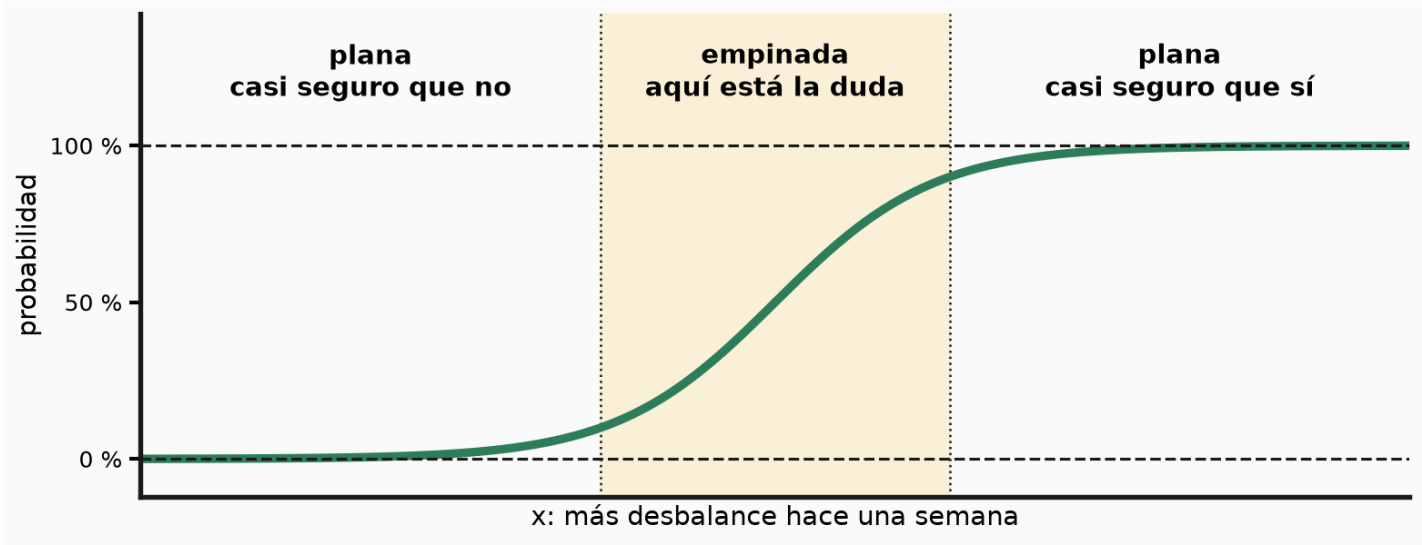
La recta no conoce topes: después de 20 bicis ya pasa de 1.

CON X = 30 LA RECTA DICE 1.40. ¿QUÉ PROBABILIDAD ES ESA?



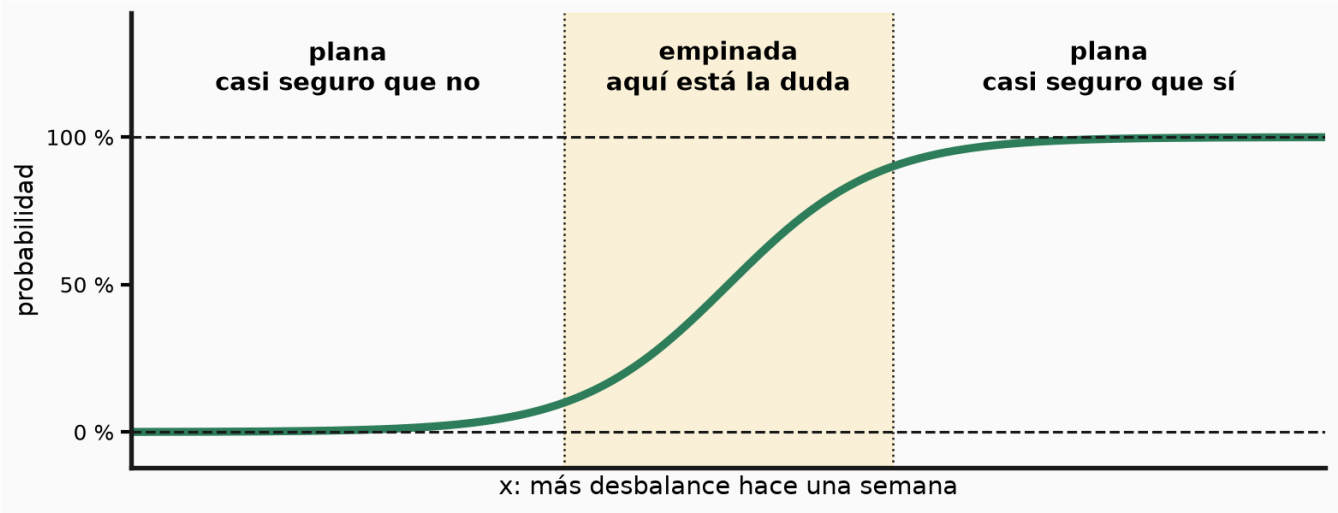
- ¿140 % de probabilidad de desbalance? No existe.
- Con todas las horas de train pasa lo mismo: con x = 60 la recta dice 2.23.

¿QUÉ FORMA DEBERÍA TENER LA LÍNEA?



Una línea que se dobla en las orillas: nunca baja de 0 ni pasa de 1.

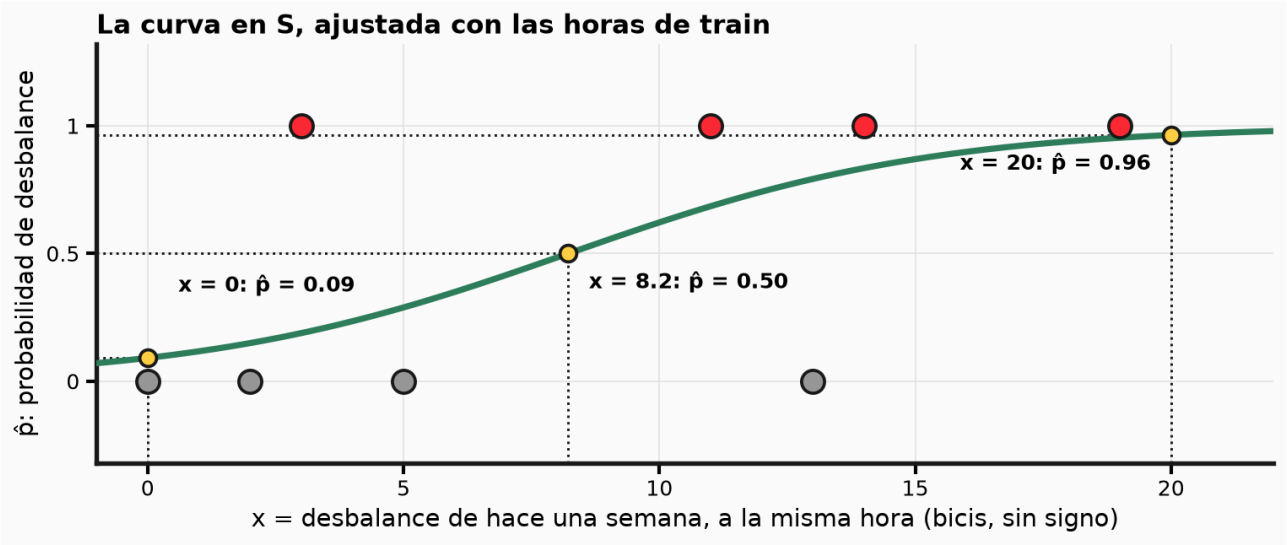
¿DÓNDE CAMBIA RÁPIDO Y DÓNDE CASI NO CAMBIA?



Como un regulador de luz: apagado abajo, encendido arriba, y en medio la perilla cambia rápido.

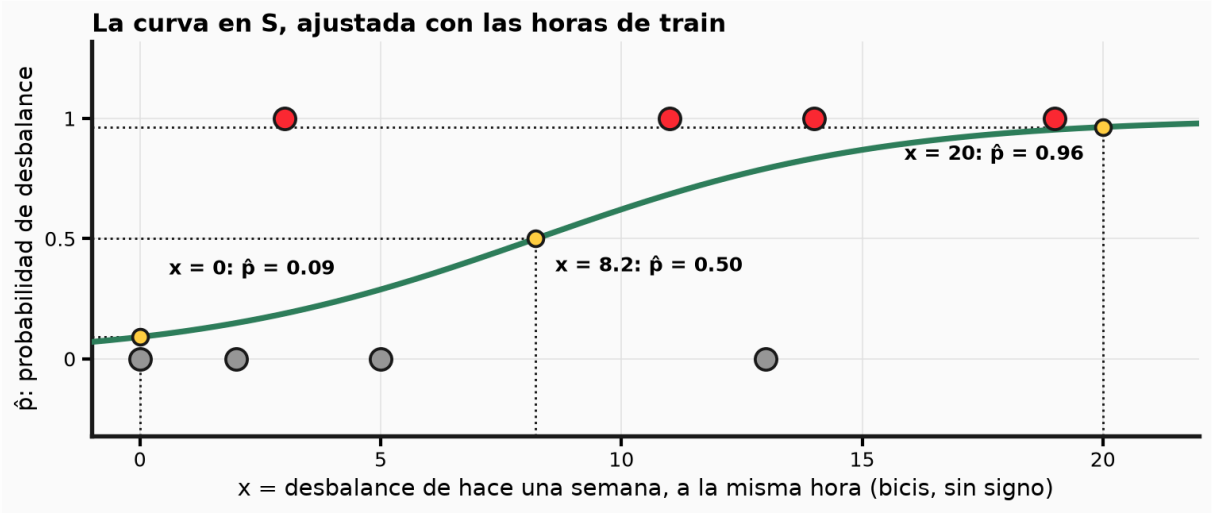
Esta curva en S se llama sigmoide.

LA CURVA EN S CON LAS 8 HORAS



Esto es la regresión logística: una S ajustada a los datos que da una probabilidad.

¿CÓMO SE LEE LA CURVA?



- Sin desbalance hace una semana ($x = 0$): **9 %**.
- Con 8.2 bicis: **50 %**, una moneda al aire.
- Con 20 bicis: **96 %**, casi seguro.

MUÉVELO: LA CURVA EN S CON MIBICI

LA CURVA EN S CON MIBICI

Cada punto: qué parte de las horas terminó en **desbalance fuerte**, según el desbalance de hace una semana. Mueve la curva hasta que pase por los puntos.

Qué tan empinada: **0.08**

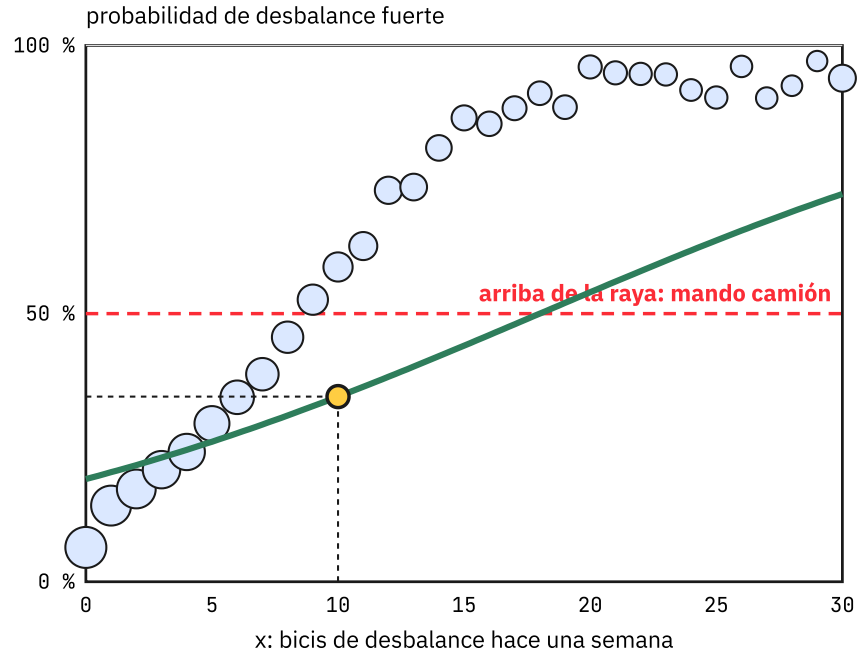
Dónde está el centro (cruza 50 %): x = **18.0**

Mejor ajuste

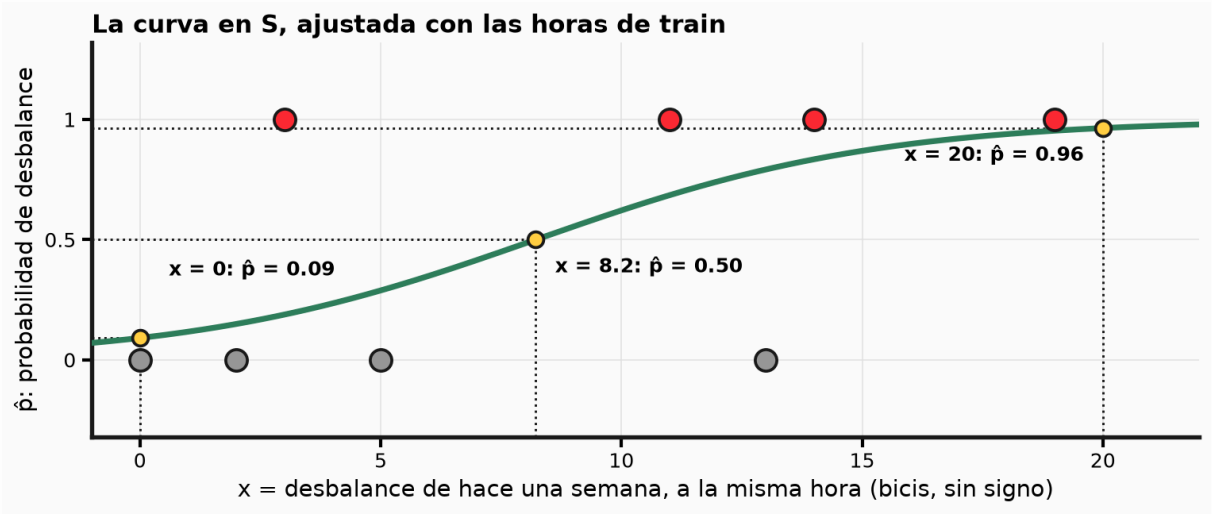
con x = 10 la probabilidad es 35 %

Pasa el mouse por la gráfica o mueve esta barra: x = **10**

Multa promedio (más chica es mejor): **0.426**

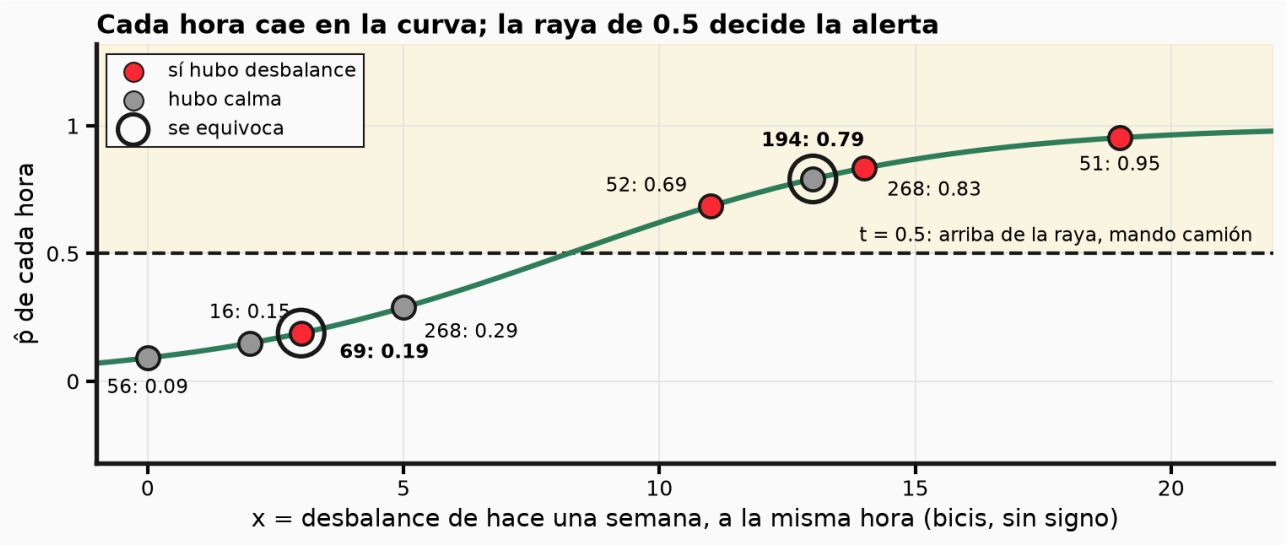


TENGO UNA PROBABILIDAD. ¿CUÁNDO MANDO CAMIÓN?



Si pasa de 50 %, mando camión. Esa raya se llama umbral.

CON EL UMBRAL DE 0.5, ¿CUÁLES SE EQUIVOCAN?



- Acierta 6 de 8.
- Falla la **69** (dijo 0.19 y sí hubo) y la **194** (dijo 0.79 y no hubo).

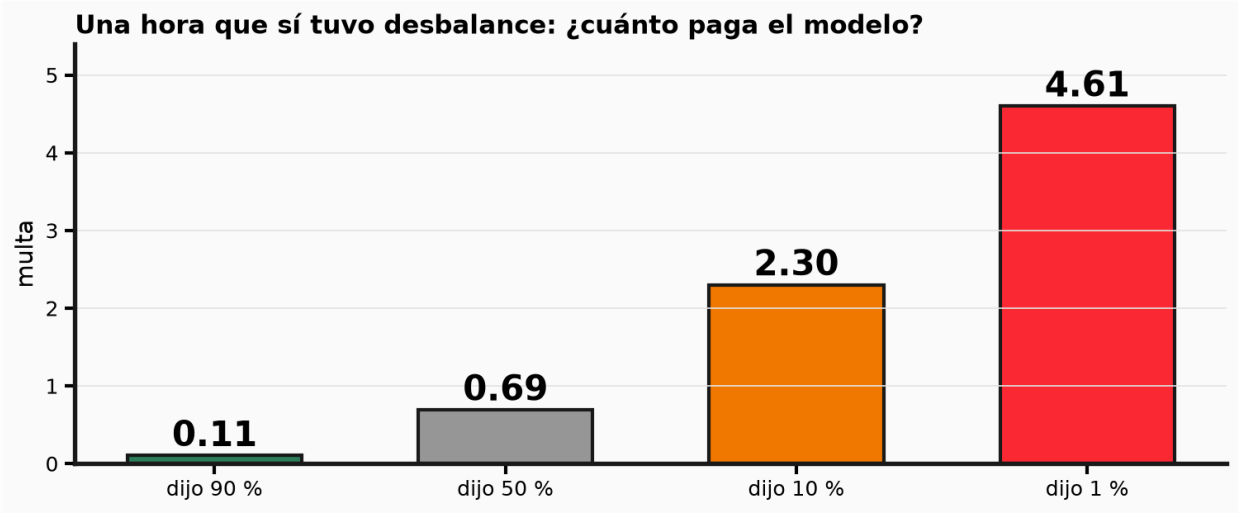
EN VIVO: LA CURVA EN PYTHON

```
m1 = LogisticRegression().fit(train[["x"]], train.y)
print(m1.coef_[0][0], m1.intercept_[0])      # 0.28  -2.30

nuevas = pd.DataFrame({"x": [0, 8.2, 20]})
m1.predict_proba(nuevas)[:, 1]               # 0.09  0.50  0.96
```

`fit` busca la curva. `coef_` dice qué tan empinada es; `intercept_`, dónde está. `predict_proba(...)[:, 1]` da la probabilidad de desbalance.

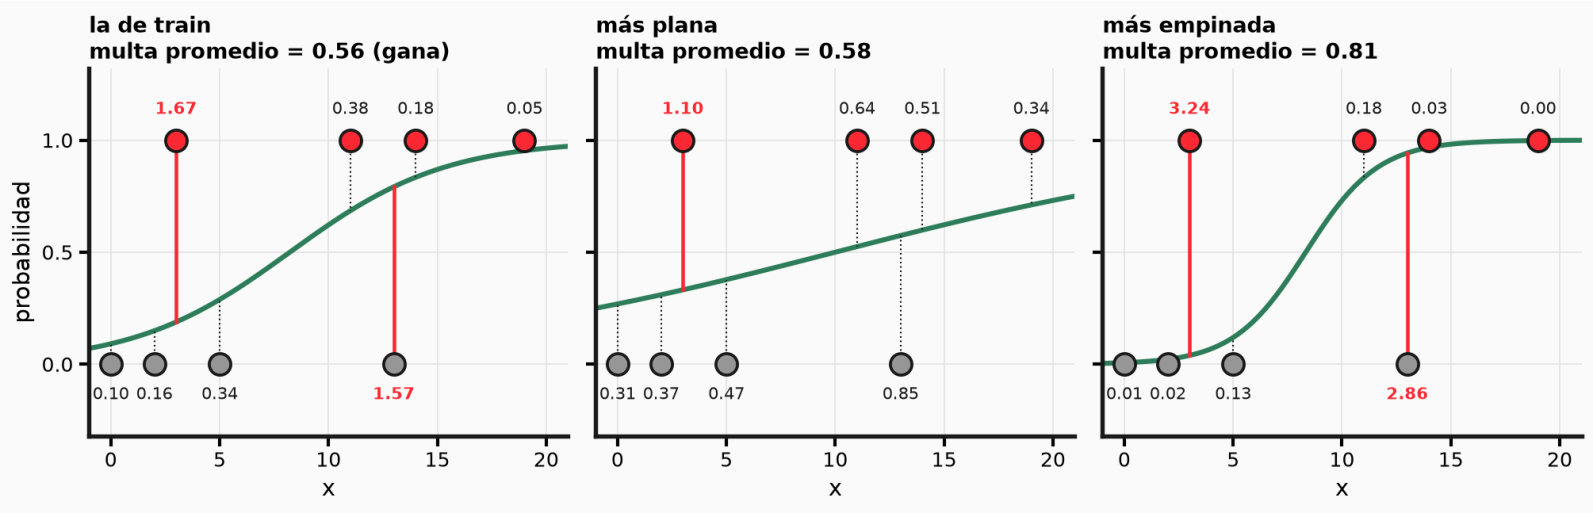
¿CUÁNTO DEBERÍA PAGAR UN MODELO QUE SE EQUIVOCA?



- Dijo 90 % y pasó: casi no paga.
- Dijo 1 % y pasó: paga carísimo.

Equivocarse muy seguro sale caro. Esa multa se llama log-loss.

TRES CURVAS: ¿CUÁL PAGA MENOS MULTA?



- La empinada paga **3.24** por la 69 y **2.86** por la 194: estaba muy segura y falló.
- Gana la de train: **0.56** de multa promedio.

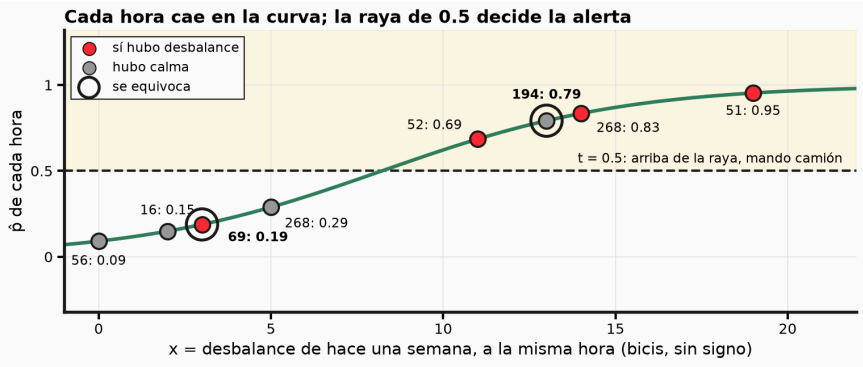
¿SIRVE SABER SI EL DÍA DEL MES ES PAR?

	sin día par	con día par
peso de la columna		**0.02**
log-loss julio	0.317	0.317
exactitud julio ($t = 0.5$)	87.1 %	87.1 %

- El peso es casi cero y el error no mejora.
- scikit-learn no da valores p. Lo que hacemos: mirar el peso y comparar el error en julio **con y sin** la columna.

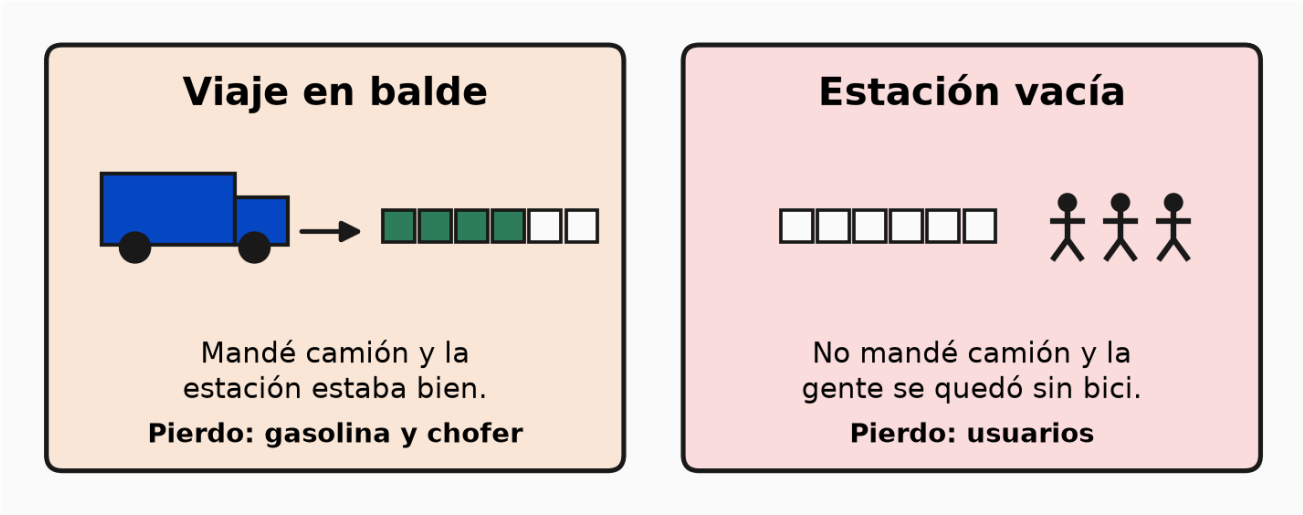
No ayuda: se descarta.

¿QUÉ NOS LLEVAMOS DE LA PARTE B?



- La recta se sale de 0 y 1; la **S** no.
- La S da una **probabilidad**.
- El **umbral** la vuelve sí o no.
- Gana la curva que paga menos **multa**.

PARTE C. ¿QUÉ TAN BUENAS SON LAS ALERTAS?



Contar aciertos y errores, y escoger el umbral.

PRIMERO CON FLORES: ¿ES VERSICOLOR?



versicolor: la que buscamos



virginica: la otra

La pregunta es de sí o no: ¿esta flor es versicolor?

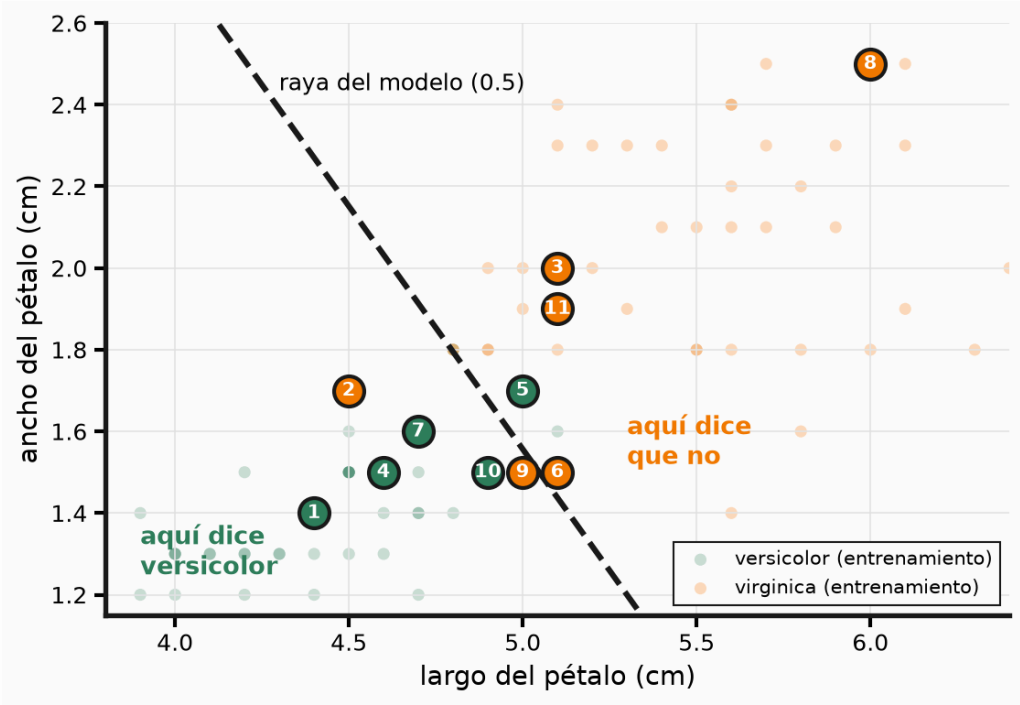
ONCE FLORES QUE EL MODELO NO VIO

flor	1	2	3	4	5	6	7	8	9	10	11
largo del pétalo (cm)	4.4	4.5	5.1	4.6	5.0	5.1	4.7	6.0	5.0	4.9	5.1
ancho del pétalo (cm)	1.4	1.7	2.0	1.5	1.7	1.5	1.6	2.5	1.5	1.5	1.9
¿es versicolor?	sí	no	no	sí	sí	no	sí	no	no	sí	no
el modelo dijo	sí	sí	no	sí	no	no	sí	no	sí	sí	no

■ versicolor ■ virginica

Arriba lo que es cada flor. Abajo lo que dijo el modelo.

¿DÓNDE QUEDÓ CADA FLOR?



El modelo dibuja una raya. De un lado dice versicolor; del otro, que no.

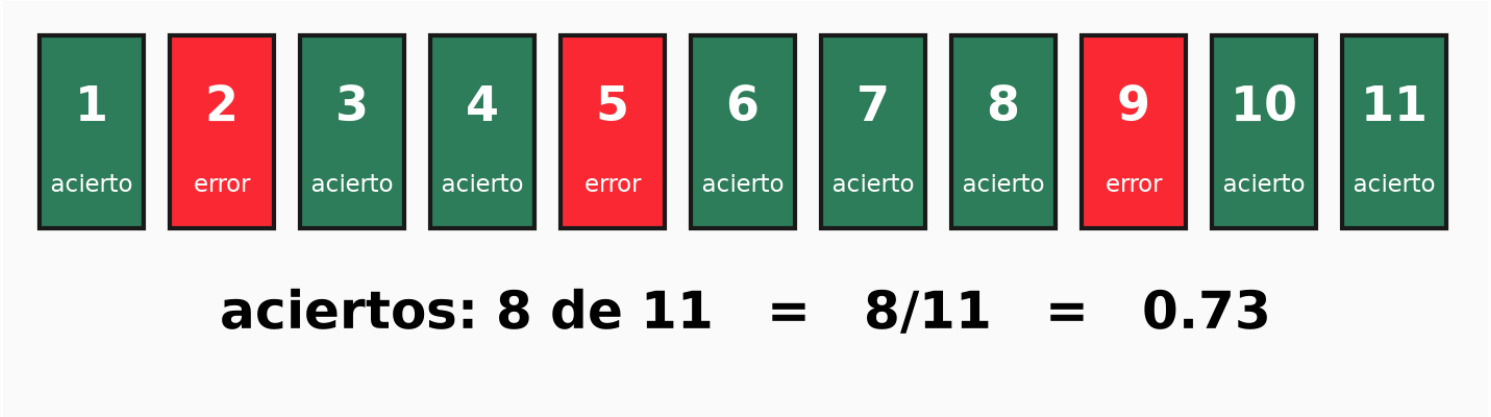
¿ACERTÓ O SE EQUIVOCÓ?

flor	1	2	3	4	5	6	7	8	9	10	11
largo del pétalo (cm)	4.4	4.5	5.1	4.6	5.0	5.1	4.7	6.0	5.0	4.9	5.1
ancho del pétalo (cm)	1.4	1.7	2.0	1.5	1.7	1.5	1.6	2.5	1.5	1.5	1.9
¿es versicolor?	sí	no	no	sí	sí	no	sí	no	no	sí	no
el modelo dijo	sí	sí	no	sí	no	no	sí	no	sí	sí	no
¿acertó?	✓	✗	✓	✓	✗	✓	✓	✓	✗	✓	✓

■ versicolor ■ virginica

Acierto: los dos renglones dicen lo mismo. Se equivocó en la 2, la 5 y la 9.

¿CUÁNTAS ACERTÓ?



8 de 11: 0.73, el 73 %. A eso se le llama exactitud.

¿DE QUÉ DOS MANERAS SE EQUIVOCÓ?

Dije versicolor
y era virginica



flores 2 y 9

falsa alarma

Dije que no
y sí era versicolor



flor 5

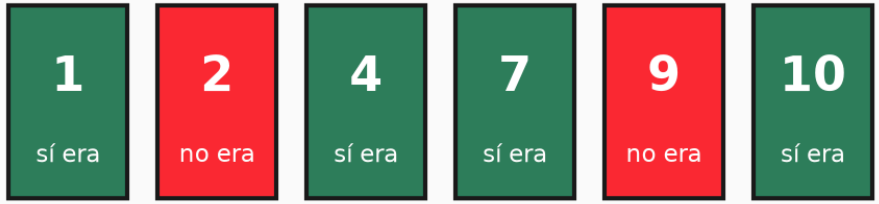
se me pasó

LA TABLA DE CUATRO CASILLAS, FLOR POR FLOR

	dijo que no	dijo versicolor
era virginica	**4** bien: flores 3, 6, 8, 11	**2** falsa alarma: flores 2, 9
era versicolor	**1** se me pasó: flor 5	**4** bien: flores 1, 4, 7, 10

4 + 2 + 1 + 4 = 11 flores. Los aciertos son la diagonal: 4 + 4 = 8.

DE LAS QUE DIJE VERSICOLOR, ¿CUÁNTAS ERAN?



dije versicolor: 6 sí eran: 4 4/6 = 0.67

- Dijo versicolor en **6** flores: 1, 2, 4, 7, 9, 10.
- De esas, sí eran **4**. Las otras 2 fueron falsa alarma.
- 4 de 6: 4 / 6 = **0.67**.

A ESO SE LE LLAMA PRECISION

precision = de las que el modelo dijo que sí, cuántas eran

$$\text{precision} = \frac{VP}{VP + FP} = \frac{4}{4+2} = \frac{4}{6} = 0.67$$

Solo mira la columna "dijo versicolor". Le importa a quien paga cada falsa alarma.

DE LAS VERSICOLOR DE VERDAD, ¿CUÁNTAS ENCONTRÉ?



- Versicolor de verdad hay **5**: 1, 4, 5, 7, 10.
- El modelo encontró **4**. Se le pasó la 5.
- 4 de 5: 4 / 5 = **0.80**.

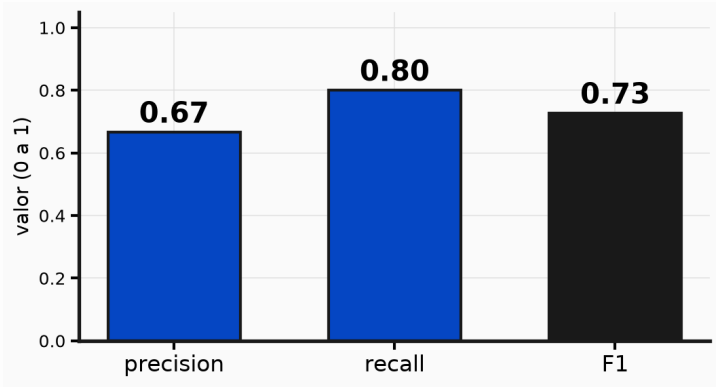
A ESO SE LE LLAMA RECALL

recall = de las que sí eran, cuántas encontró el modelo

$$\text{recall} = \frac{VP}{VP + FN} = \frac{4}{4+1} = \frac{4}{5} = 0.80$$

Solo mira el renglón "era versicolor". Le importa a quien sufre cada caso que se pasa.

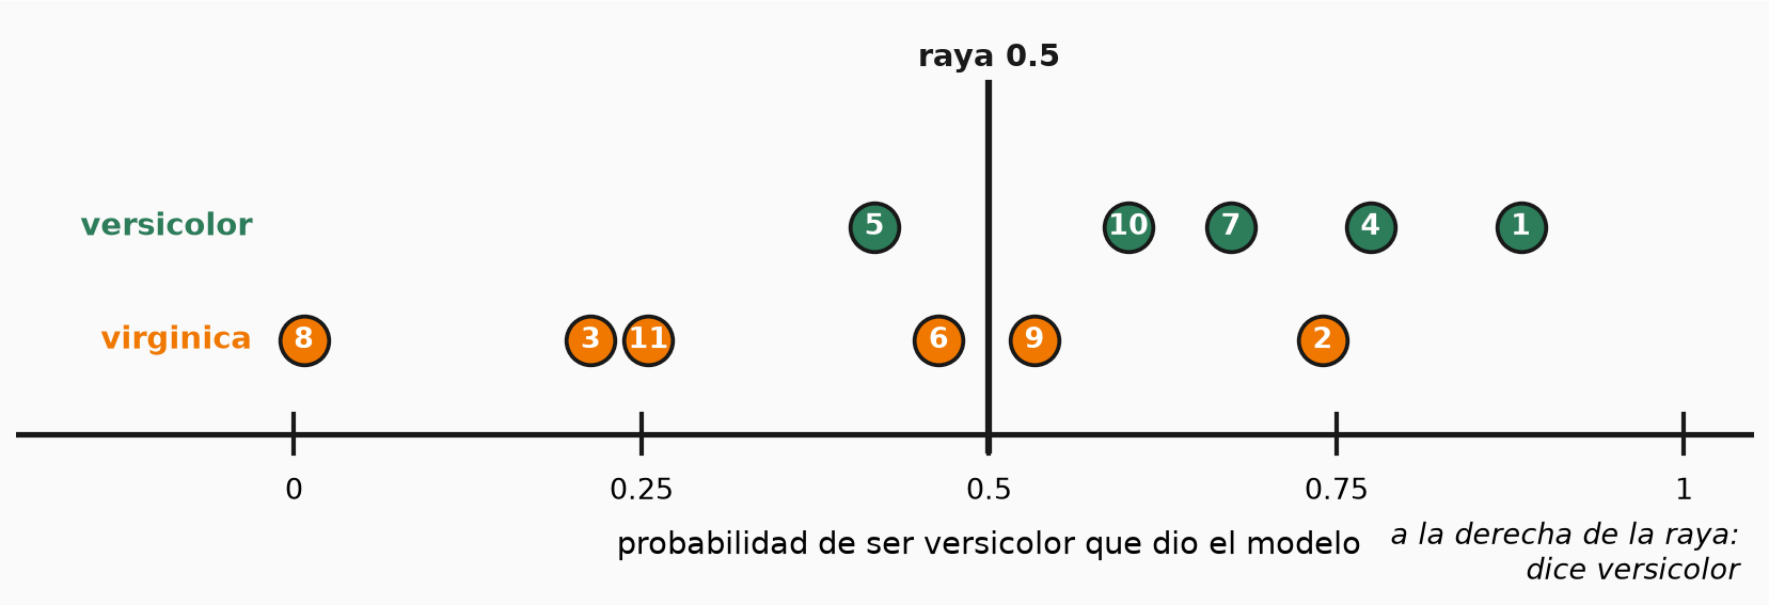
UN SOLO NÚMERO QUE JUNTA LAS DOS: F1



$$F1 = \frac{2 \times VP}{2 \times VP + FP + FN} = \frac{8}{8 + 2 + 1} = \frac{8}{11} = 0.73$$

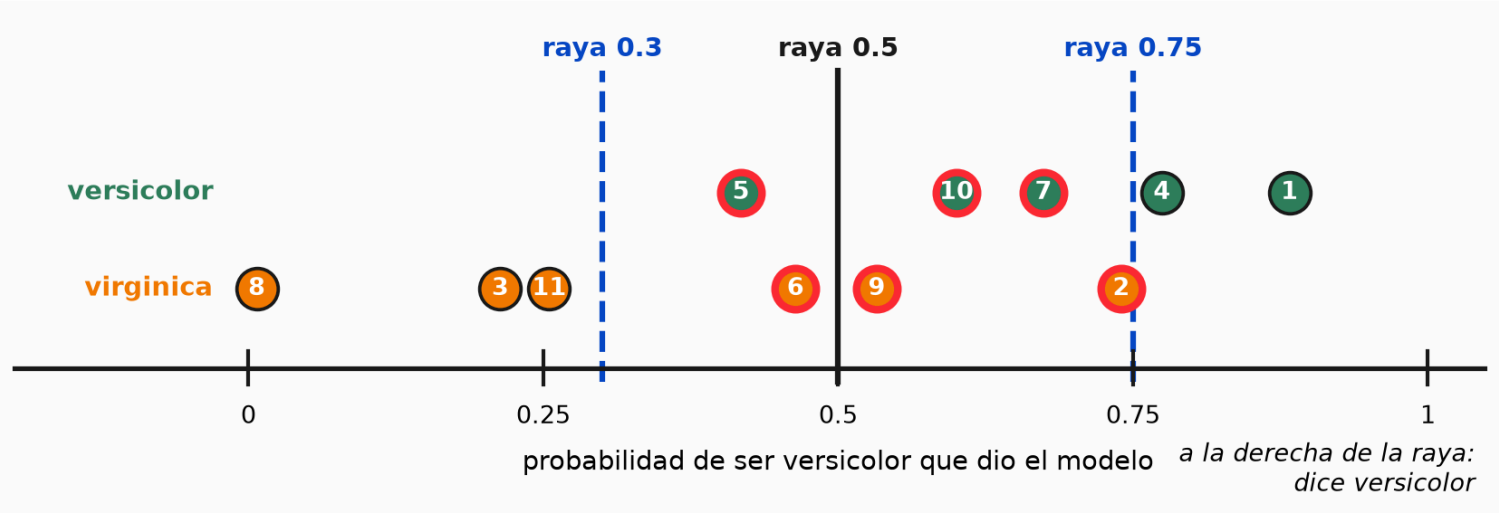
Queda entre las dos. Si una de las dos es mala, F1 también sale mala.

¿QUÉ TAN SEGURA ESTABA LA REGRESIÓN DE CADA FLOR?



El modelo da una probabilidad. La raya en 0.5 la vuelve sí o no.

¿Y SI MUEVO LA RAYA A 0.3 O A 0.75?



- **Bajo a 0.3:** la 5 pasa a "sí" (ya la encuentro) y la 6 también (una falsa alarma más).
- **Subo a 0.75:** la 2 y la 9 pasan a "no" (sin falsas alarmas), pero la 7 y la 10 también (se me pasan).

TRES RAYAS, TRES RESULTADOS

Raya	Dijo versicolor	Sí eran	Precision	Recall
0.3	8	5	5/8 = 0.625	5/5 = 1.00
0.5	6	4	4/6 = 0.67	4/5 = 0.80
0.75	2	2	2/2 = 1.00	2/5 = 0.40

Raya baja: encuentro todas, con más falsas alarmas. Raya alta: casi no me equivoco al decir sí, pero se me pasan muchas.

EL MISMO CÁLCULO EN PYTHON

```python
from sklearn.datasets import load_iris
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import confusion_matrix, accuracy_score, precision_score, recall_score

iris = load_iris(as_frame=True).frame
iris = iris[iris.target ≠ 0].copy()                    # sin setosa
iris["es_versicolor"] = (iris.target == 1).astype(int)  # 1 = versicolor, el positivo
X = iris[["petal length (cm)", "petal width (cm)"]]     # largo y ancho del pétalo
once = [65, 106, 110, 54, 77, 133, 56, 100, 119, 72, 101]  # las 11 flores de la tabla
modelo = LogisticRegression().fit(X.drop(once), iris.es_versicolor.drop(once))
real = iris.es_versicolor.loc[once]   # lo que es
dijo = modelo.predict(X.loc[once])    # lo que dijo el modelo
```

```python
confusion_matrix(real, dijo)   # [[4, 2], [1, 4]]: VN 4, FP 2; FN 1, VP 4
accuracy_score(real, dijo)     # 0.727
precision_score(real, dijo)    # 0.667
recall_score(real, dijo)       # 0.8
```

AHORA USTEDES: PINGÜINOS A MANO Y EN PYTHON (15 MIN)

Lo mismo que hicimos con las flores, con **10 pingüinos reales**.
La pregunta: **¿es Adelie?**

https://colab.research.google.com/github/HesusG/dammg-supervisado/blob/main/notebooks/salas/S2_hoja_clasificacion.ipynb

1. **A mano:** llenen las cuatro casillas en papel y contesten las preguntas: aciertos, exactitud, VP, FP, FN, VN, precision y recall.
2. **Con Python:** comprueben sus cuentas con `confusion_matrix`, `precision_score` y `recall_score`.
3. Escriban en la hoja su precision y su recall.

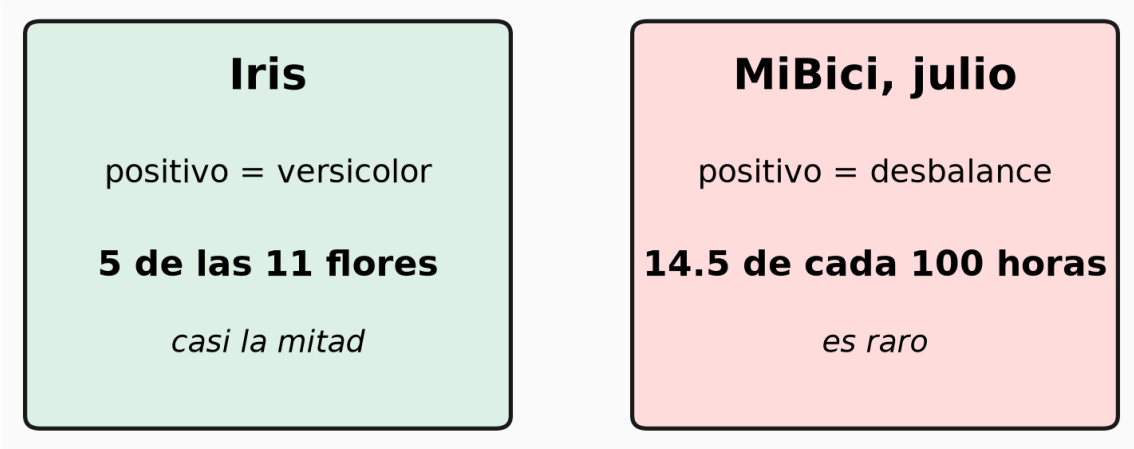
Así lo hicimos con las flores:

flor	1	2	3	4	5	6	7	8	9	10	11
largo del pétalo (cm)	4.4	4.5	5.1	4.6	5.0	5.1	4.7	6.0	5.0	4.9	5.1
ancho del pétalo (cm)	1.4	1.7	2.0	1.5	1.7	1.5	1.6	2.5	1.5	1.5	1.9
¿es versicolor?	sí	no	no	sí	sí	no	sí	no	no	sí	no
el modelo dijo	sí	sí	no	sí	no	no	sí	no	sí	sí	no

■ versicolor ■ virginica

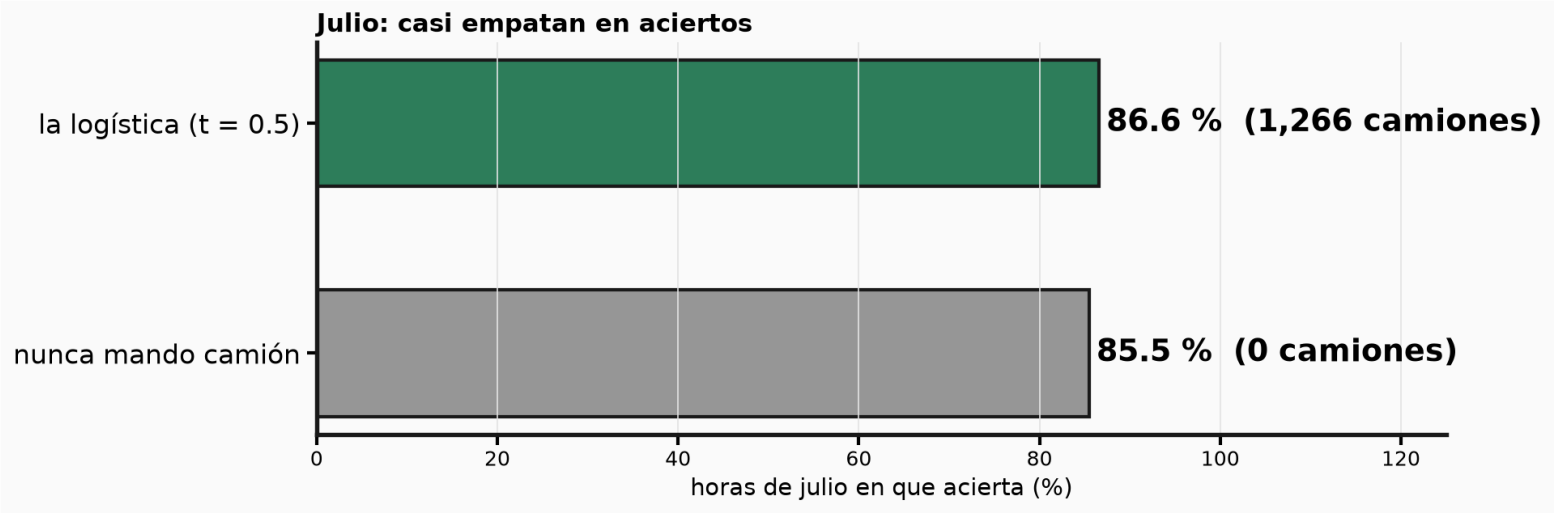
Mismos pasos que con las flores; solo cambian los datos.

LO MISMO CON MIBICI



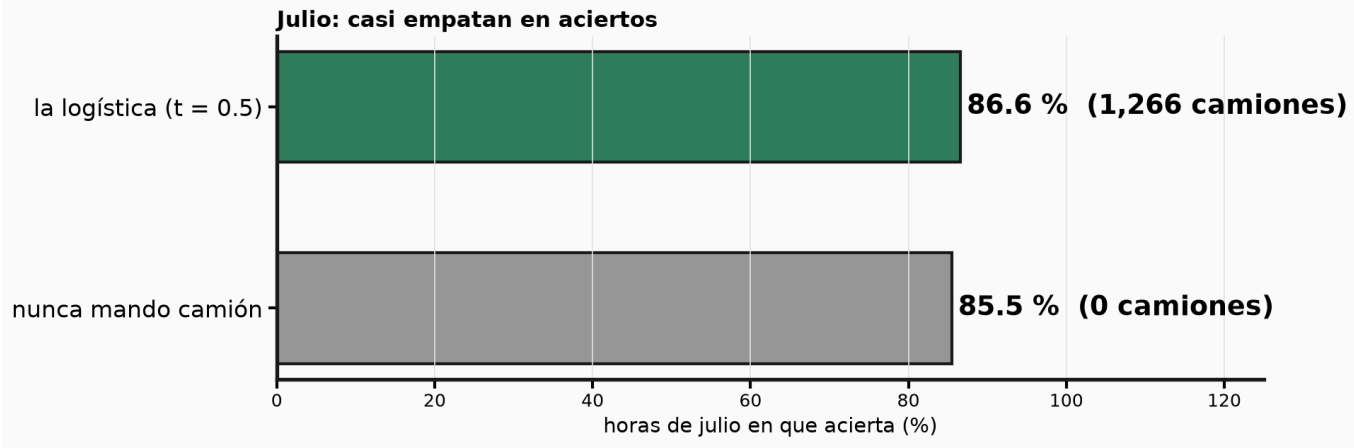
En vez de versicolor, desbalance. Las cuentas son las mismas; lo nuevo es que el positivo es raro.

¿CUÁNTO ACIERTA UN MODELO QUE NUNCA MANDA CAMIÓN?



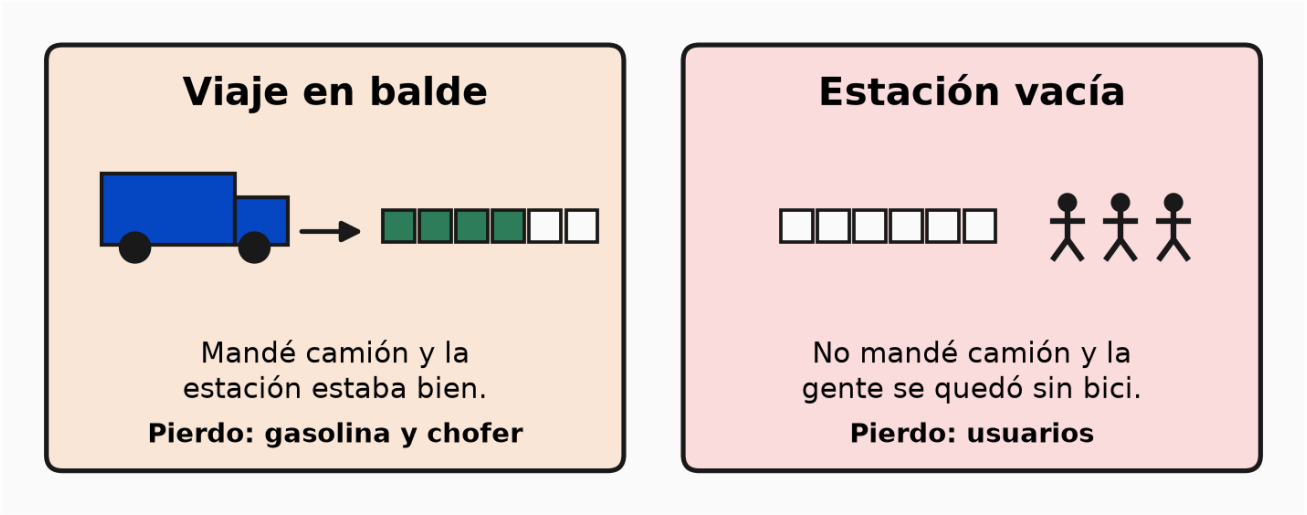
85.5 % sin mandar un solo camión, porque casi todas las horas son de calma.

¿ENTONCES EL MODELO NO SIRVE?



Sí sirve. La exactitud no distingue qué tipo de error cometió.

¿CUÁL DE LOS DOS ERRORES CUESTA MÁS?



Depende del negocio. Por eso hay que contarlos por separado.

¿CÓMO SE LLAMAN LAS CUATRO CASILLAS?

	no mandé	**mandé camión**
hubo calma	**3** **VN**: verdadero negativo	**1** **FP**: falso positivo
hubo desbalance	**1** **FN**: falso negativo	**3** **VP**: verdadero positivo

Positivo quiere decir "hay desbalance", no "algo bueno". La tabla se llama matriz de confusión.

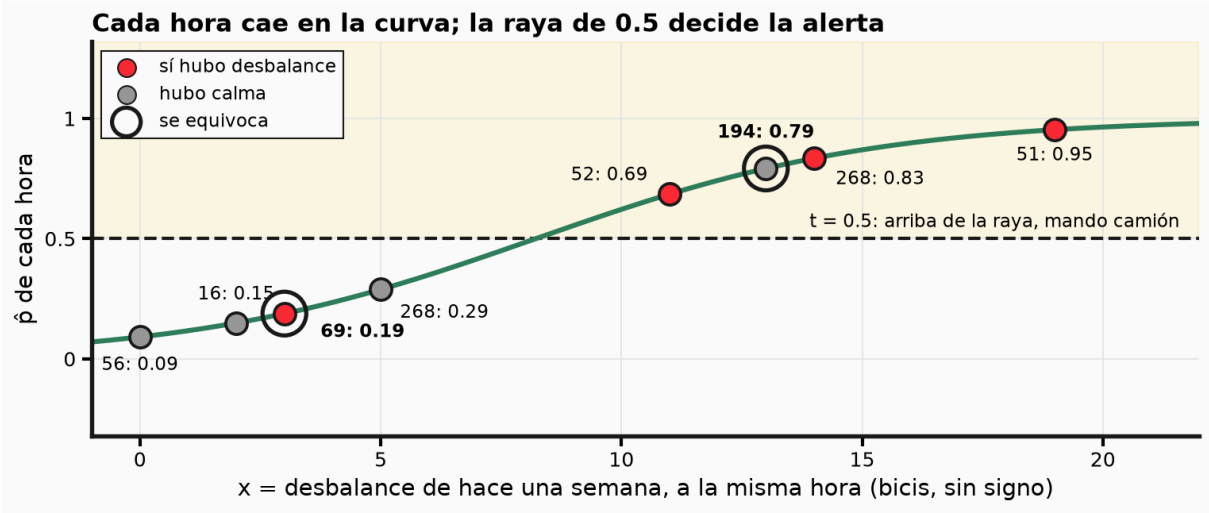
¿Y CON TODAS LAS HORAS DE JULIO?

	no mandé	mandé camión
hubo calma	**VN** **24,975**	**FP** **458**
hubo desbalance	**FN** **3,519**	**VP** **808**

Modelo de 12 columnas, umbral 0.5, las 29,760 horas de julio.

- Mandé camión 808 + 458 = **1,266** veces.
- Hubo 808 + 3,519 = **4,327** desbalances.
- **3,519** estaciones vacías: lo que la exactitud escondía.

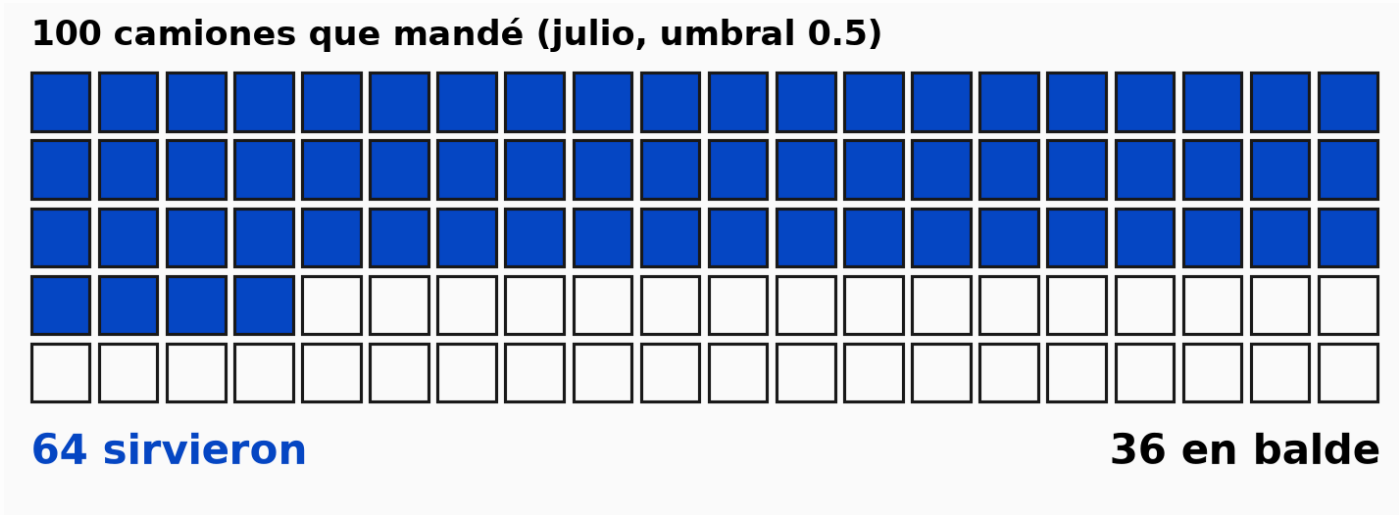
DE MIS ALERTAS, ¿CUÁNTAS ERAN CIERTAS?



- Mandé 4 camiones: la 52, la 194, la 268 del viernes y la 51.
- 3 llegaron a un desbalance de verdad. **3 de 4.**

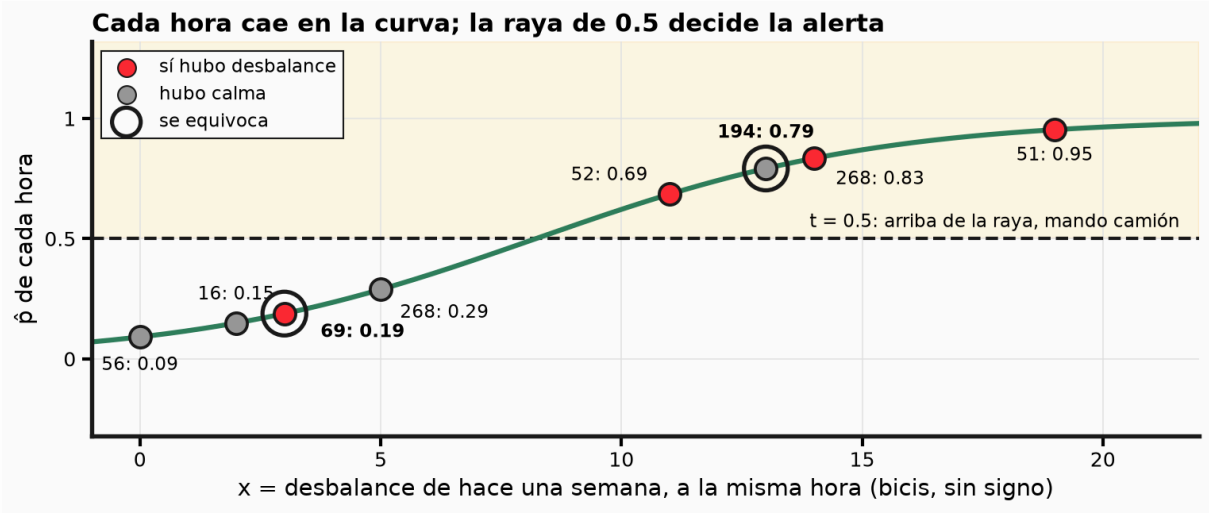
"De mis alertas, cuántas eran ciertas" se llama precision.

¿Y EN JULIO, CUÁNTOS CAMIONES SIRVIERON?



De cada 100 camiones, 64 sirvieron y 36 fueron en balde: precision de 0.64.

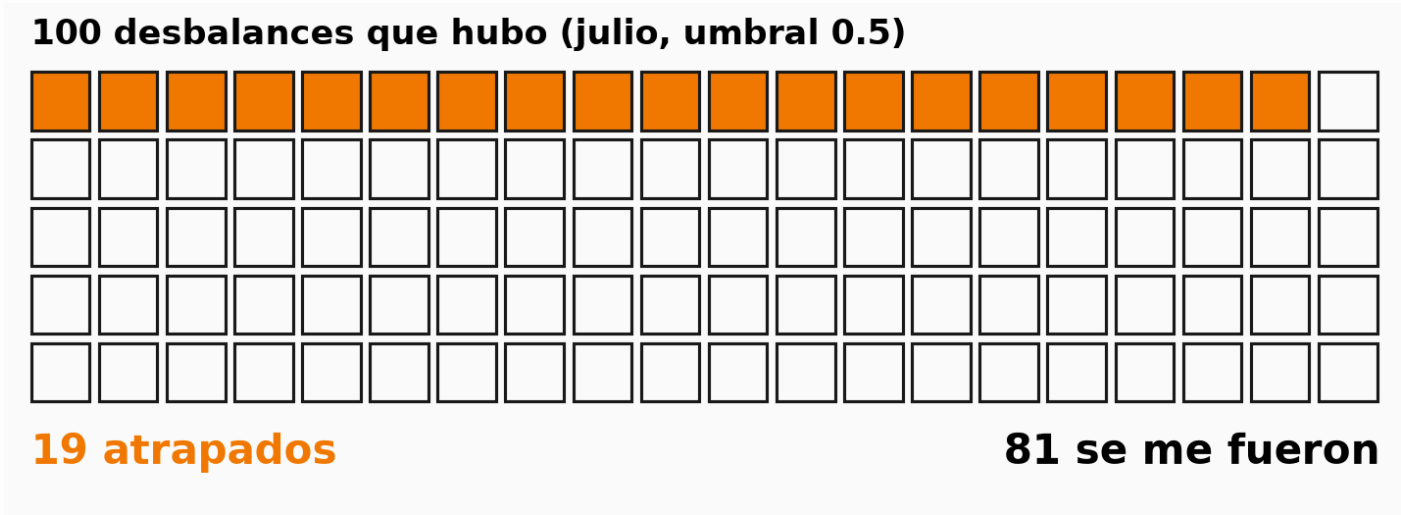
DE LOS DESBALANCES, ¿CUÁNTOS ATRAPÉ?



- Hubo 4 desbalances: los 4 puntos rojos.
- Llegó camión a 3; la 69 se quedó sin camión. **3 de 4.**

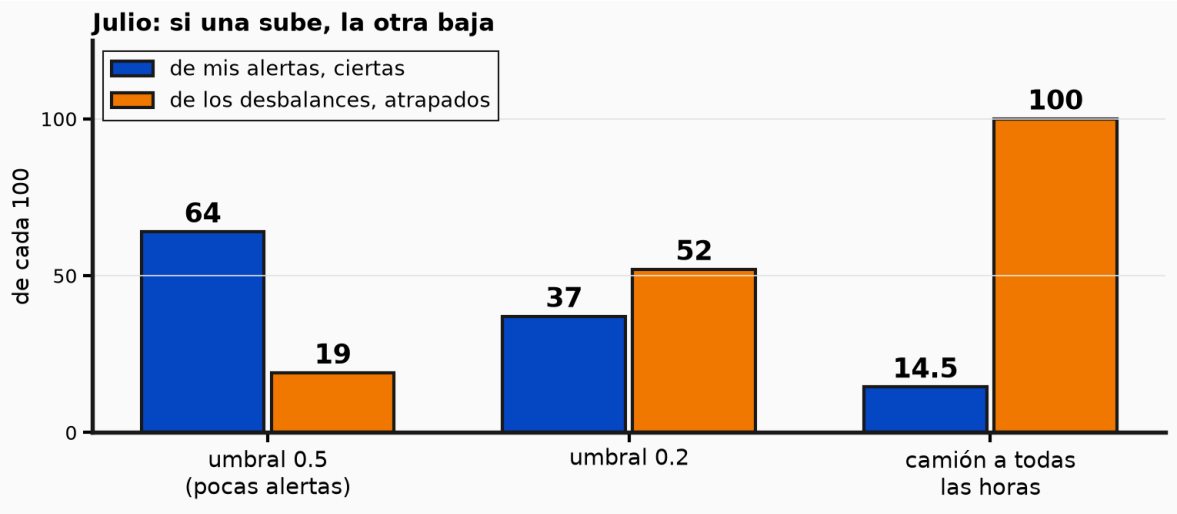
"De los desbalances, cuántos atrapé" se llama recall.

¿Y EN JULIO, CUÁNTOS DESBALANCES ATRAPÉ?



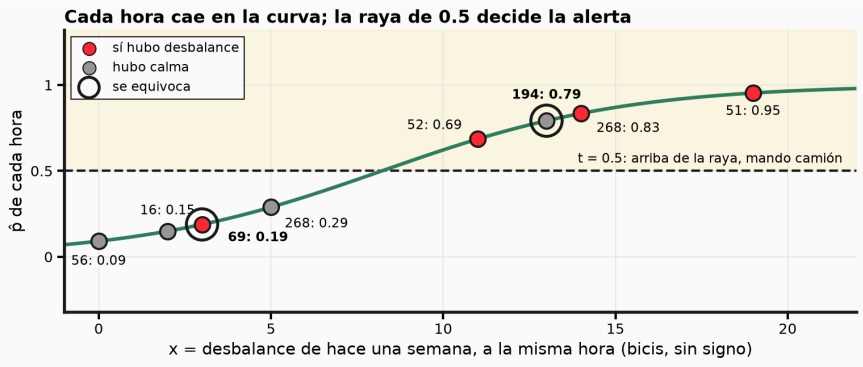
De cada 100 desbalances, atrapé 19: recall de 0.19. Preciso, pero se queda corto.

¿PUEDO TENER LAS DOS ALTAS?



Es una cobija corta: si subo una, baja la otra.

¿Y SI BAJO EL UMBRAL?

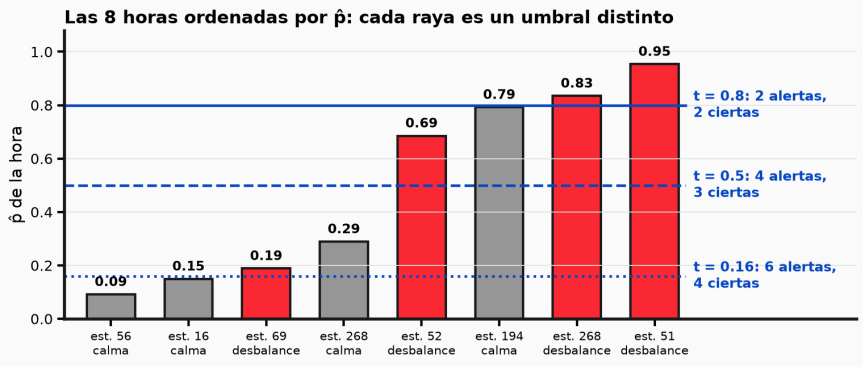


Hoy mando camión si la probabilidad pasa de 0.5. Operaciones dice que le alcanza para más viajes.

Pregunta al grupo (en el chat): Bajas el umbral de 0.5 a 0.2. ¿Qué pasa con precision y recall?

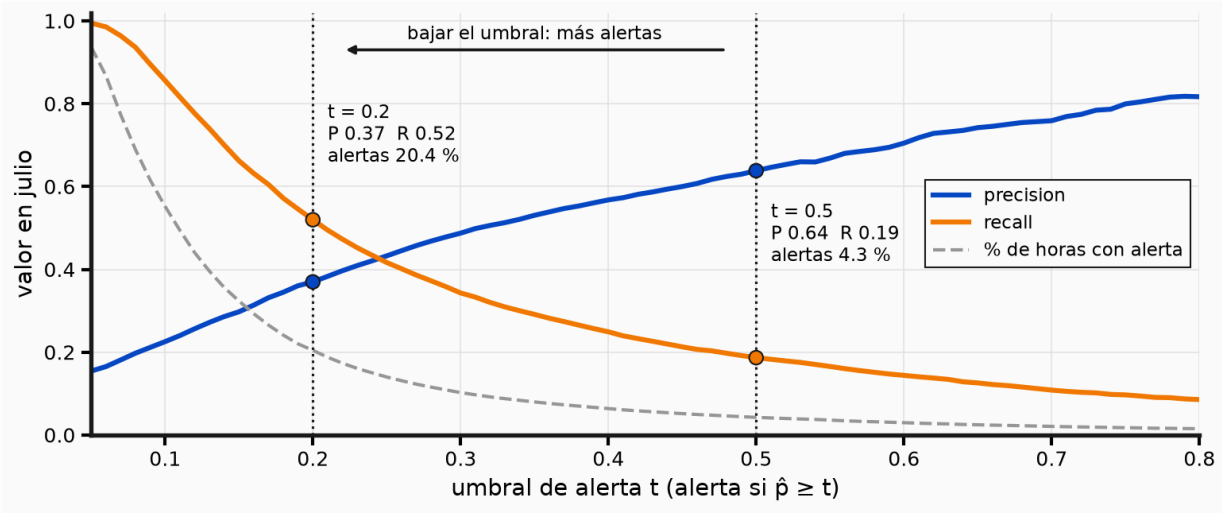
A. Las dos suben B. Recall sube, precision baja C. Precision sube, recall baja D. Ninguna cambia

¿QUÉ PASA CON LAS 8 HORAS SI MUEVO LA RAYA?



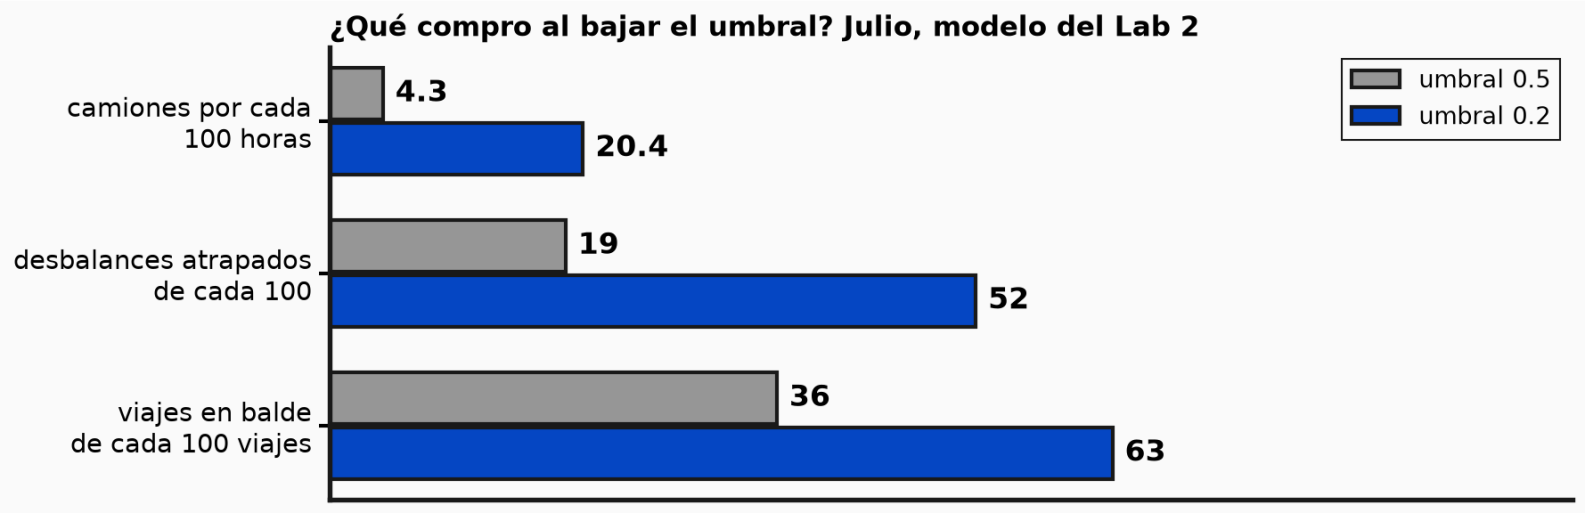
- **0.8:** 2 camiones, los 2 sirven. Atrapo 2 de 4.
- **0.5:** 4 camiones, 3 sirven. Atrapo 3 de 4.
- **0.16:** 6 camiones, 4 sirven. Atrapo 4 de 4.

EL UMBRAL EN JULIO: LO PONE EL NEGOCIO



- Con **0.5**: alerta en 4.3 % de las horas, precision 0.64, recall 0.19.
- Con **0.2**: alerta en 20.4 %, precision **0.37**, recall **0.52**. Más alertas, más recall, menos precision.

¿QUIÉN ESCOGE EL UMBRAL?



El negocio: cuántos camiones caben en el presupuesto y cuánto cuesta una estación vacía.

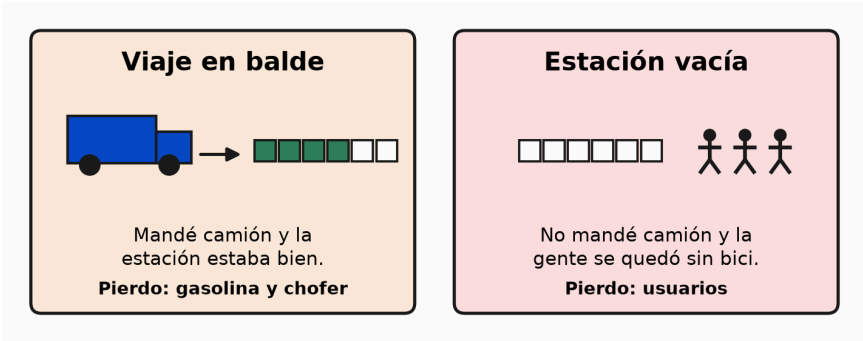
EN VIVO: LAS MÉTRICAS EN PYTHON

```
alerta = (p_julio ⩾ 0.5).astype(int)        # 1 = mando camión
confusion_matrix(julio.y, alerta).ravel()    # VN 24975, FP 458, FN 3519, VP 808

for t in [0.5, 0.2]:
    al = (p_julio ⩾ t).astype(int)
    precision_score(julio.y, al), recall_score(julio.y, al)
# t = 0.5: alertas 4.3 %, precision 0.64, recall 0.19
# t = 0.2: alertas 20.4 %, precision 0.37, recall 0.52
```

Primero lo que pasó, luego lo que dijo el modelo. Uso `p_julio ⩾ t` y no `.predict()`, que siempre corta en 0.5.

CUATRO PREGUNTAS DE NEGOCIO



- ¿Cuántas acertó? **Exactitud.** Engaña si casi todo es calma.
- ¿Qué errores cometió? **Matriz de confusión.**
- De mis camiones, ¿cuántos sirvieron? **Precision.**
- De los desbalances, ¿cuántos atrapé? **Recall.**

DESPUÉS DE LA PAUSA: LA HOJA DEL CAMIÓN

Operaciones tiene camión para atender una de cada cinco horas (20 %). ¿Con qué umbral mandamos alerta, cuántos desbalances atrapamos y cuántos viajes son en balde?

https://colab.research.google.com/github/HesusG/dammg-supervisado/blob/main/notebooks/salas/S2_hoja_camion_v2.ipynb

Pasos: 1 los datos, 2 el modelo (editan `estacion` y `umbral`), 3 la medición, 4 la respuesta en tres renglones. Ábranla y córranla hasta el paso 2 durante la pausa: el modelo tarda unos segundos.

PAUSA DE 8 MIN

Lejos de la pantalla. Agua, estírate, mira por la ventana.

REGRESAMOS EN 08:00

SECCIÓN 4 | Hoja del camión | ⏱ 14:43 a 15:23

HOJA DEL CAMIÓN

¿Con qué umbral mandamos alerta?

EN SALAS: LA SOLICITUD DE OPERACIONES (30 MIN)

SALAS DE ZOOM salas de 3 o 4 TIEMPO **30:00**

1. Una persona comparte pantalla; las demás dictan.
2. Corran en orden. Solo editan dos líneas: `estacion` y `umbral`.
3. Antes de cada pregunta de opción múltiple, voten en la sala.

La hoja:

https://colab.research.google.com/github/HesusG/dammg-supervisado/blob/main/notebooks/salas/S2_hoja_camion_v2.ipynb

En la hoja, una línea: `umbral __ / alertas __ % / precision __ / recall __`

LO QUE SALIÓ EN LA HOJA

Umbral	Alertas	Precision	Recall
0.5	3.8 %	0.71	0.19
0.26	20.3 %	0.40	0.56
0.27	**18.9 %**	**0.41**	**0.53**

Con 0.27: 2,314 desbalances atrapados y 3,319 viajes en balde. Por estación: la 51 recibe alerta en el 76 % de sus horas; la 35, en el 52 %, con precision de 0.17.

- **Caza el error:** "exactitud 85 %, es buenísimo" es la regla **"nunca"** (85.5 %). La logística con 0.27 tiene menos exactitud (82.1 %) y atrapa 2,314 desbalances.
- **El día par:** peso 0.02 y la log-loss no cambia (0.3171 contra 0.3172). Se descarta.

CIERRE | Tarea 2 y proyecto | ⏱ 15:23 a 15:37

CIERRE

TAREA 2

Vence el **domingo 15 de noviembre a las 23:59**. Tolerancia hasta el **miércoles 18**. Se entrega en Moodle.

https://colab.research.google.com/github/HesusG/dammg-supervisado/blob/main/notebooks/tareas/T2/tarea.ipynb

Trabajo individual, unas 3 horas. Al abrirla, lean la portada: dice qué se califica y qué debe tener una respuesta completa.

TU PROYECTO, HASTA HOY

Ya pueden:

- Medir con MAE, RMSE y R^2, y escoger la métrica antes de ver resultados.
- Inventar columnas (calendario, rezagos, promedios) sin fuga.
- Clasificar con la logística y reportar matriz, precision y recall.
- Escoger el umbral con julio, según el presupuesto.

Avisos de analista:

- **Exactitud sola, no.** Compárenla con "nunca" (85.5 % en julio) y reporten precision y recall.
- **El umbral no es 0.5 por defecto.** Escójanlo con julio y díganlo en camiones: "de cada 100 viajes, 41 sirven".
- **Septiembre no es julio.** Trae 21 % más salidas por hora y más desbalances (17.3 % contra 14.5 %). Reporten por mes.
- **Una salida en 0 puede ser una estación vacía,** no falta de demanda. Díganlo como limitación.
- La prueba se abre una sola vez.

REFERENCIAS DE LA SECCIÓN 3

Google. (s. f.-a). *Classification: Accuracy, recall, precision, and related metrics*. Machine Learning Crash Course. https://developers.google.com/machine-learning/crash-course/classification/accuracy-precision-recall

Google. (s. f.-b). *Classification: Thresholds and the confusion matrix*. Machine Learning Crash Course. https://developers.google.com/machine-learning/crash-course/classification/thresholding

James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An introduction to statistical learning: With applications in R* (2a ed.). Springer. https://www.statlearning.com

O'Mahony, E., & Shmoys, D. B. (2015). Data analysis and optimization for (Citi)Bike sharing. *Proceedings of the AAAI Conference on Artificial Intelligence, 29*(1), 687–694. https://doi.org/10.1609/aaai.v29i1.9245

scikit-learn. (s. f.). *Metrics and scoring: Quantifying the quality of predictions*. https://scikit-learn.org/stable/modules/model_evaluation.html

Starmer, J. (2018a, 5 de marzo). *StatQuest: Logistic regression* [Video]. YouTube. https://www.youtube.com/watch?v=yIYKR4sgzI8

Starmer, J. (2018b, 11 de junio). *Logistic regression details pt 2: Maximum likelihood* [Video]. YouTube. https://www.youtube.com/watch?v=BfKanl1aSG0

Starmer, J. (2018c, 29 de octubre). *Machine learning fundamentals: The confusion matrix* [Video]. YouTube. https://www.youtube.com/watch?v=Kdsp6soqA7o