DAMMG | FACULTAD DE CIENCIAS, UNAM | 1ª EMISIÓN

Facultad de Ciencias UNAM

SECRETARÍA DE EDUCACIÓN ABIERTA Y CONTINUA
FACULTAD DE CIENCIAS

DIPLOMADO EN APRENDIZAJE DE MÁQUINA Y MODELOS GENERATIVOS

QUÉ ERROR CUESTA MÁS, Y ÁRBOLES QUE PREGUNTAN

Métricas para clases desbalanceadas, entropía y ensambles.

DAMMG Módulo VI: Aprendizaje supervisado | Sesión 3 · VI.3 y VI.4 | vie 6 nov 2026 · 16:00–21:00

Mtro. Hesus García Cobos

QUIZ ESPACIADO (10 MIN)

CONCEPTEST 1. Voto individual (1 min) siguiente ▸

1 · Ridge con λ grande encoge primero…

- **A.** las direcciones con más varianza
- **B.** las direcciones con menos varianza (d² chica)
- **C.** el intercepto b
- **D.** todas igual

letra en el chat

CONCEPTEST 1. Voto individual (1 min) siguiente ▸

2 · La log-loss de la logística es…

- **A.** el MSE de la sigmoide
- **B.** la MLE de Bernoulli = entropía cruzada
- **C.** la distancia al hiperplano
- **D.** el hinge

letra en el chat

Pasó una semana: recuperar ahora cuesta más, y por eso consolida más (práctica espaciada).

BLOQUE A | VI.3 Clasificación | ⏱ 15–55

ELEGIR EL UMBRAL ES UNA DECISIÓN DE NEGOCIO

Ng, MLS C2 S3 «Error metrics for skewed datasets» · «Trading off precision and recall».

RECUERDEN: LO QUE VIMOS EL SÁBADO

	predice 1	predice 0
real 1	TP ✔	FN ✘ *se te pasó*
real 0	FP ✘ *falsa alarma*	TN ✔

$$P = \frac{TP}{TP+FP} \qquad R = \frac{TP}{TP+FN}$$

RECUERDEN, MÓDULO VI · S2 evaluación honesta

Baseline, partición temporal, umbral en **validación** y reporte en **test** una sola vez.

¿QUÉ PASA SI…?

Clasificador que dice «1» para TODAS las estaciones-hora. ¿Recall y precision?

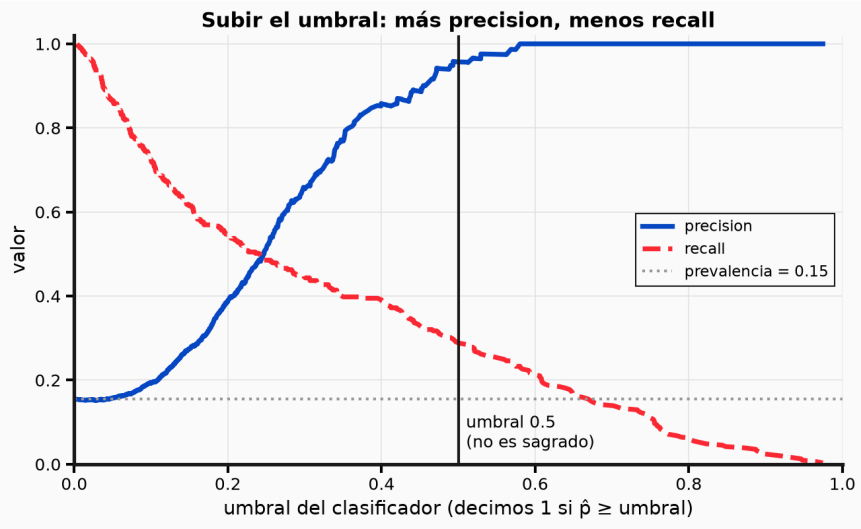
A. R = 1, P = prevalencia (≈ 0.15)

B. R = 0, P = 1

C. R = P = 0.5

D. No se puede calcular

PRECISION CONTRA RECALL: MUEVE EL UMBRAL



- Umbral alto: pocas alertas, casi todas buenas: **P alta, R baja**
- Umbral bajo: muchas alertas, se escapan pocas: **R alta, P baja**

Presupuesto de alertas: la cuadrilla puede atender 30 estaciones-hora por día. Ese número fija el umbral, **no** el 0.5.

$F_1 = \frac{2PR}{P+R}$ útil para resumir; malo si los errores cuestan distinto.

CURVAS QUE RESUMEN TODOS LOS UMBRALES

Curva PR · Average Precision

- Eje x: recall · Eje y: precision
- **Baseline = prevalencia** (≈ 0.15), no 0.5
- AP = área bajo la curva PR
- **Recomendada con desbalance**

Curva ROC · AUC

- Eje x: tasa de falsos positivos · Eje y: recall
- Baseline = diagonal (AUC 0.5)
- ⚠ Con muchos negativos, la FPR se ve chiquita aunque haya cientos de falsas alarmas: **la ROC se ve optimista**

CONCEPTEST 1. Voto individual (1 min)

siguiente ▸

Prevalencia 2 %. Modelo A: AUC-ROC 0.95, AP 0.20. Modelo B: AUC-ROC 0.90, AP 0.45. ¿Cuál despliegas para mandar cuadrillas?

A. A, por su AUC

B. B, por su AP

C. Empate

MULTICLASE EN 3 MINUTOS: SOFTMAX

$$\hat{p}_k = \frac{e^{z_k}}{\sum_{j=1}^{K} e^{z_j}}, \qquad z_k = \vec{w}_k \cdot \vec{x} + b_k$$

- Con $K = 2$ se reduce a la sigmoide
- Costo: $-\log \hat{p}_{\text{clase real}}$, la misma entropía cruzada (Mód II)
- Es la capa de salida de casi todas las redes del Módulo VIII

Ng, MLS C2 S2 «Softmax» · CS229 L4 (GLM)

RECUERDEN, MÓDULO II entropía cruzada

$H(p, q) = -\sum_k p_k \log q_k$: con p = etiqueta *one-hot*, solo sobrevive el término de la clase real.

CIERRE DEL BLOQUE A

Chat waterfall: en tu trabajo, ¿qué es peor, una falsa alarma o un caso que se te pasa? Un ejemplo, sin enviar hasta «¡ya!».

Lo usamos después de la pausa, en FigJam.

PREDECIR POR PARECIDO: K VECINOS MÁS CERCANOS

Para una flor nueva buscamos las flores más parecidas que ya conocemos y les preguntamos su especie.





TRES ESPECIES DE IRIS

Bloque KNN, 16:56



Iris setosa

pétalo promedio 1.5 × 0.25 cm



Iris versicolor

pétalo promedio 4.3 × 1.3 cm



Iris virginica

pétalo promedio 5.6 × 2.0 cm

El color del marco es el de cada especie en todas las gráficas: azul, verde y naranja.

Fotos (recortadas): Radomil, CC BY-SA 3.0; Danielle Langlois, CC BY-SA 3.0; Frank Mayfield, CC BY-SA 2.0; vía Wikimedia Commons. Ligas en las referencias del bloque.

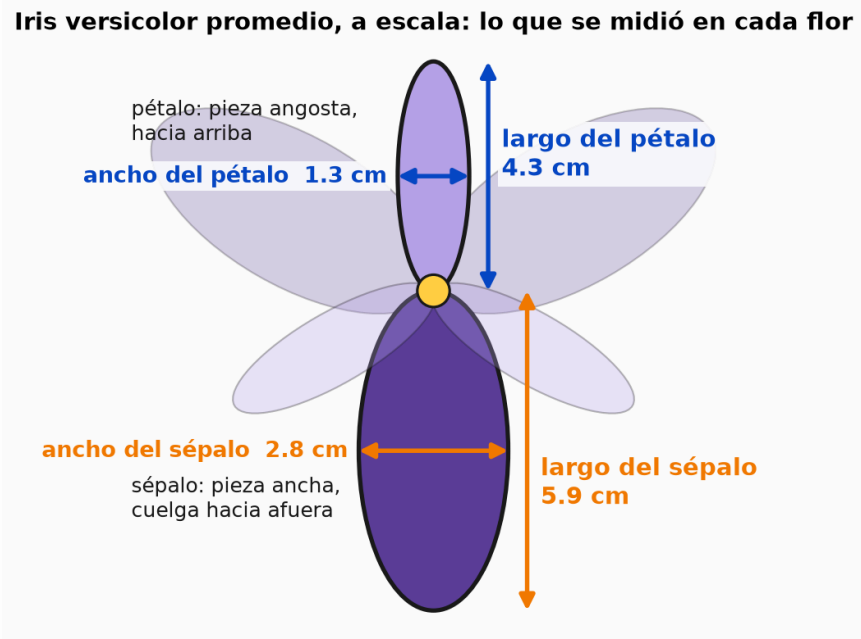
EL PROBLEMA: ¿DE QUÉ ESPECIE ES ESTA FLOR?

Bloque KNN, 16:57

De cada una de las 150 flores sabemos el **largo** y el **ancho del pétalo** (en cm) y su **especie**.

Flor	Largo	Ancho	Especie
1	1.4	0.2	setosa
51	4.7	1.4	versicolor
101	6.0	2.5	virginica
nueva	**4.0**	**1.3**	**?**

Llega una flor sin especie: 4.0 × 1.3 cm. ¿Qué especie es?

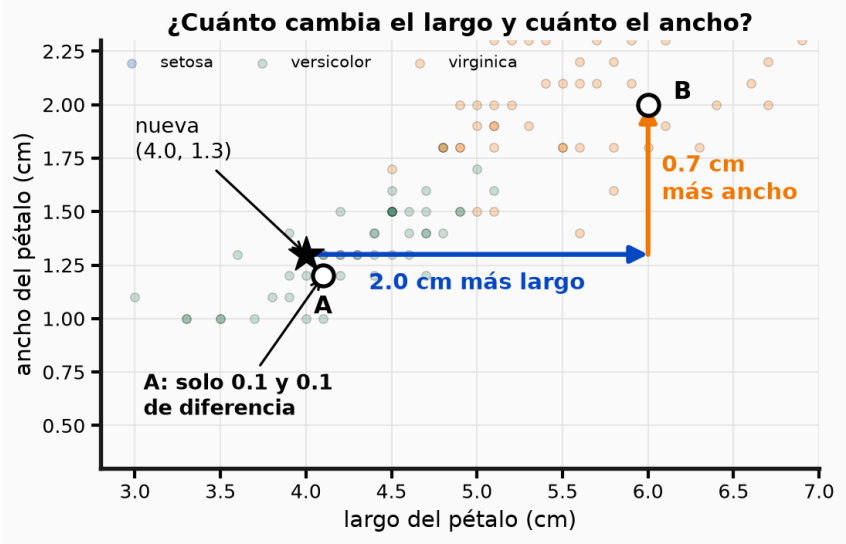


EL PARECIDO

Bloque KNN, 16:58

Flor	Largo	Ancho
nueva	**4.0**	**1.3**
A	4.1	1.2
B	6.0	2.0

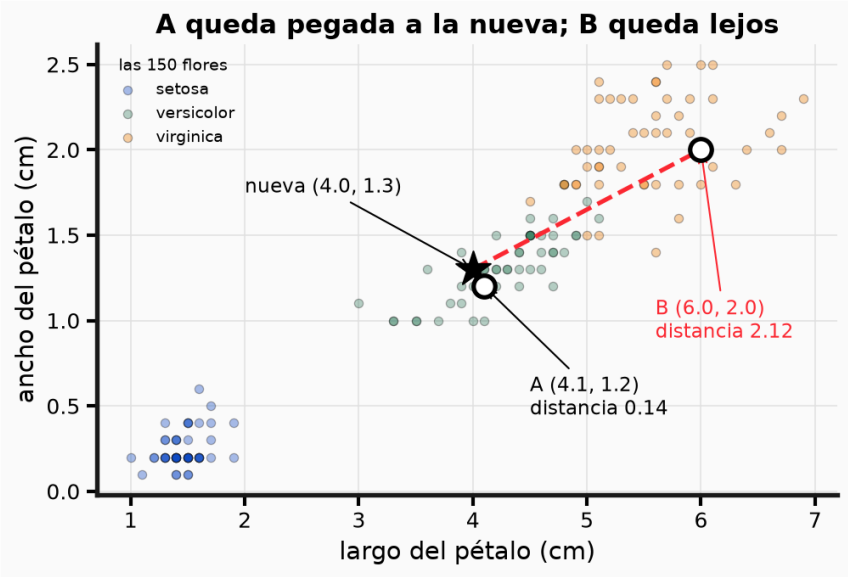
El pétalo de **A** casi no cambia. El de **B** es 2.0 cm más largo y 0.7 cm más ancho.



La computadora no mira la gráfica: necesita un número, la distancia. Cuanto menor, más parecidas.

LA DISTANCIA: LA REGLA DEL METRO SOBRE LA GRÁFICA

Bloque KNN, 17:00



Cada flor es un punto. La distancia es lo que mediría una regla puesta entre los dos puntos:

$$d = \sqrt{(\text{dif. de largo})^2 + (\text{dif. de ancho})^2}$$

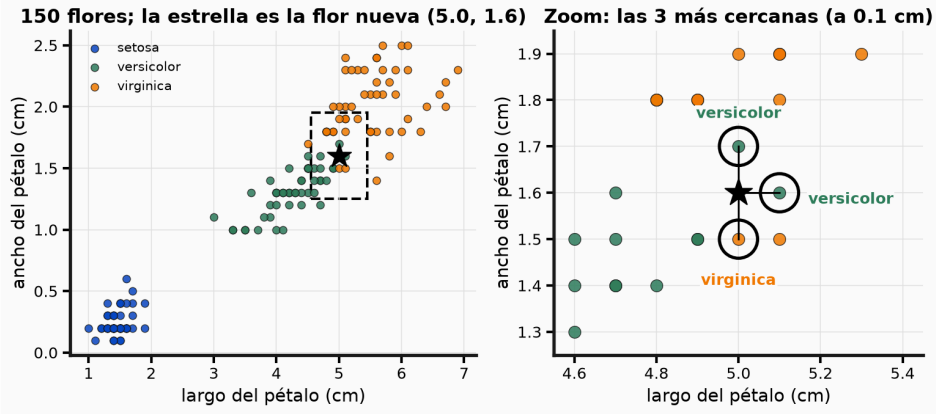
A: $\sqrt{0.1^2 + 0.1^2} = \sqrt{0.02} = 0.14$

B: $\sqrt{2.0^2 + 0.7^2} = \sqrt{4.49} = 2.12$

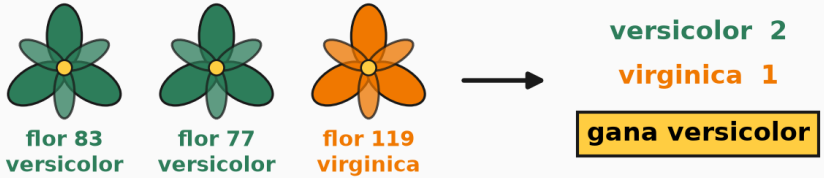
La matemática solo le pone número al parecido: B queda 15 veces más lejos que A.

LA DECISIÓN: CONSULTAR A TRES VECINAS Y VOTAR

Bloque KNN, 17:03



1. **Buscamos** las k = 3 más cercanas.
2. **Votan:** gana la especie con más votos.



MUÉVELO: LAS VECINAS VOTAN

Bloque KNN, 17:04

LAS VECINAS VOTAN

Cada punto es una flor de iris, pintada por su especie. La **estrella** es una flor nueva: arrástrala. Sus **k vecinas** más cercanas votan y gana la especie con más votos.

largo = **5.0** cm

ancho = **1.6** cm

k (cuántas vecinas votan) = **3**

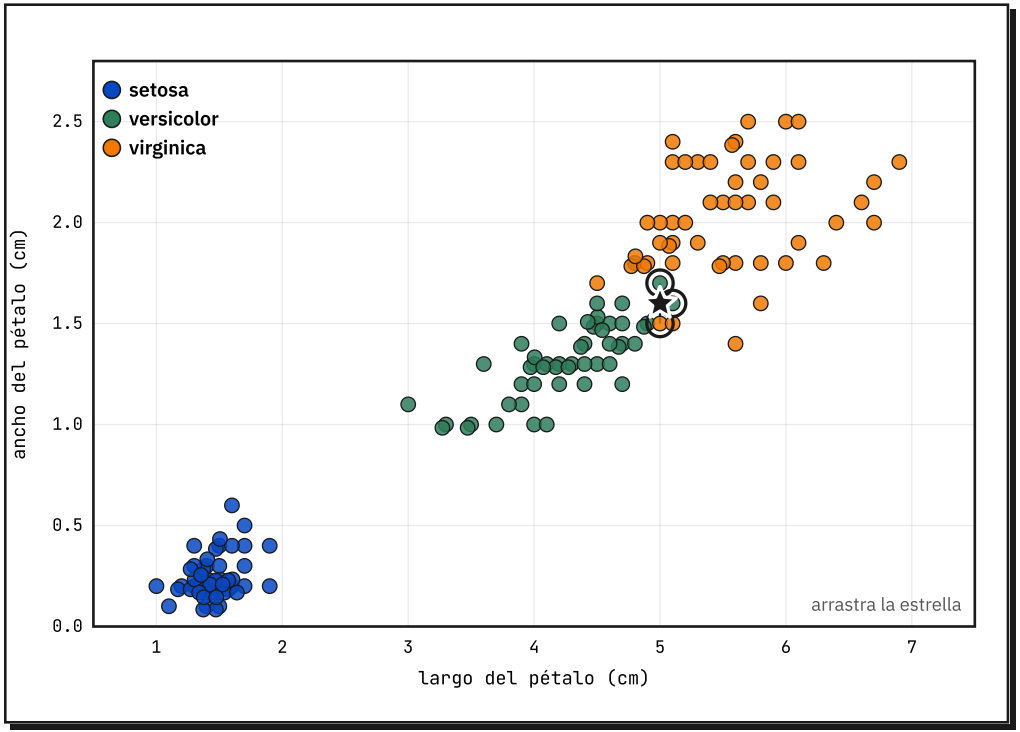
Flor fácil (4.0, 1.3) **Flor difícil (5.0, 1.6)**

☐ **Colorear el fondo por lo que predice**

especie	votos
○ setosa	**0**
○ versicolor	**2** □□
○ virginica	**1** □

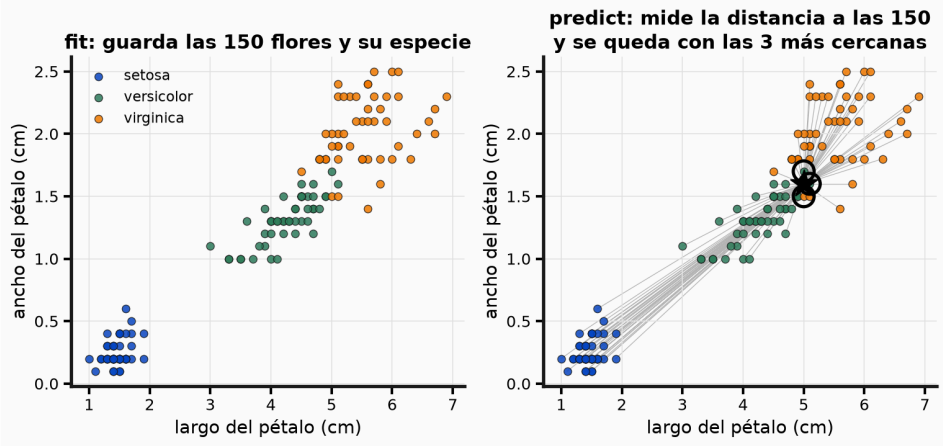
Predice: **VERSICOLOR**

La más lejana que vota está a 0.10 cm.



¿POR QUÉ ES APRENDIZAJE SUPERVISADO?

Bloque KNN, 17:05



Supervisado: aprende de ejemplos que ya traen la respuesta, la especie.

Sin recta ni curva: no hay pesos que ajustar; guarda los ejemplos.

Ajustar es guardar la tabla. Todo el trabajo pasa al predecir.

EN VIVO: TRES LÍNEAS DE SCIKIT-LEARN

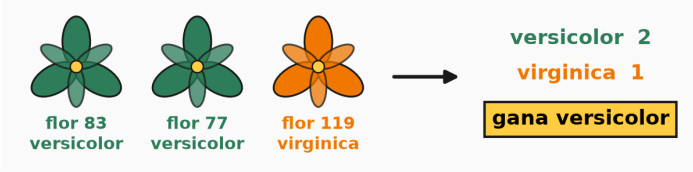
Bloque KNN, 17:06

```
modelo = make_pipeline(StandardScaler(), KNeighborsClassifier(n_neighbors=3)).fit(X, y)

nueva = pd.DataFrame({"largo": [4.0], "ancho": [1.3]})
modelo.predict(nueva)                          # array(['versicolor'])

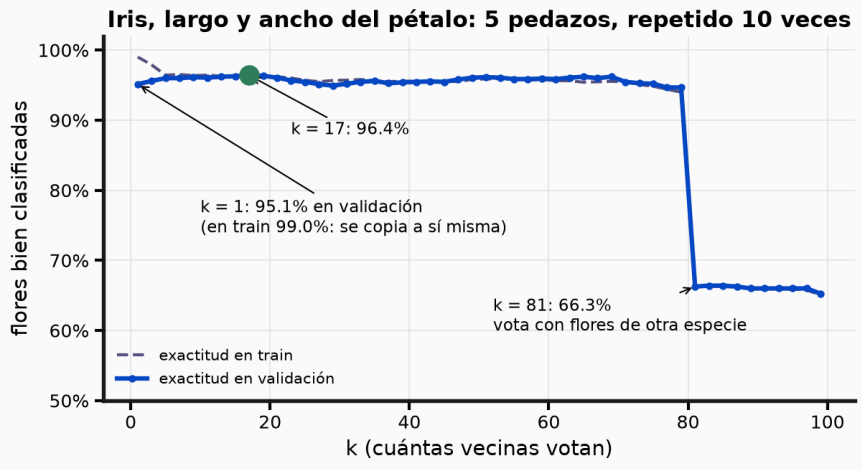
escala, knn = modelo[0], modelo[1]
dist, idx = knn.kneighbors(escala.transform(dificil))   # las 3 vecinas de (5.0, 1.6)
X.iloc[idx[0]]                                 # 83: versicolor, 77: versicolor, 119: virginica
```

`fit` guarda las flores; `predict` busca las 3 vecinas y cuenta los votos; `kneighbors` nos deja ver **quiénes** votaron.



¿CUÁNTAS VECINAS? CÓMO ESCOGER K

Bloque KNN, 17:09



- **k = 1** copia a la vecina más cercana. Si esa flor es rara, se deja engañar. En train acierta 99 % (se encuentra a sí misma); en validación, 95.1 %.
- **k muy grande** vota con flores lejanas. Con k = 81 ya votan flores de otra especie: 66.3 %.
- **Entre esos extremos**, k se escoge con **validación**: aquí k = 17 da 96.4 %.

UNA VOTACIÓN

Bloque KNN, 17:11

¿QUÉ PASA SI…?

Con k = 1, ¿qué pasa si la vecina más cercana de la flor nueva es una flor mal etiquetada?

A. La flor nueva hereda la etiqueta equivocada

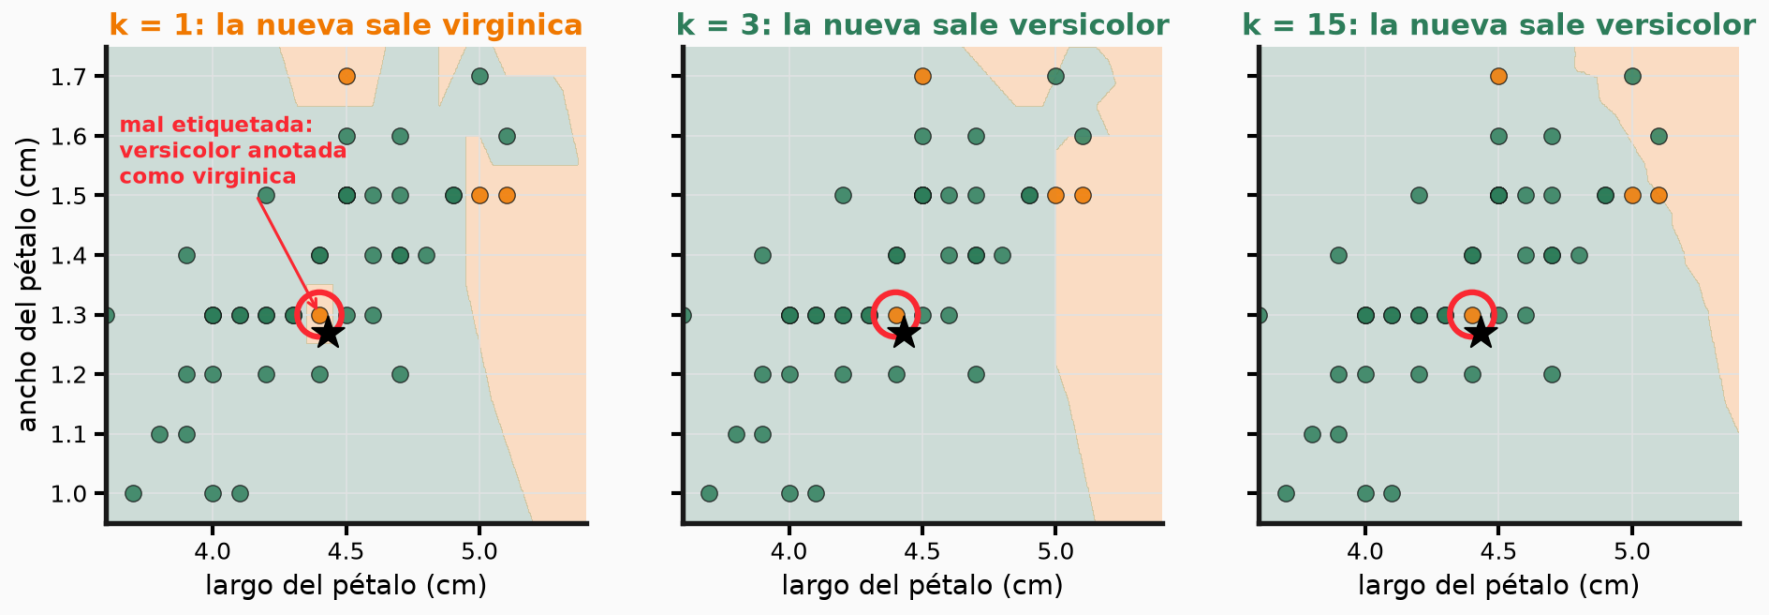
B. El modelo la ignora porque es rara

C. scikit-learn marca un error

D. Da lo mismo: siempre gana la especie correcta

LA RESPUESTA, CON K = 1, 3 Y 15

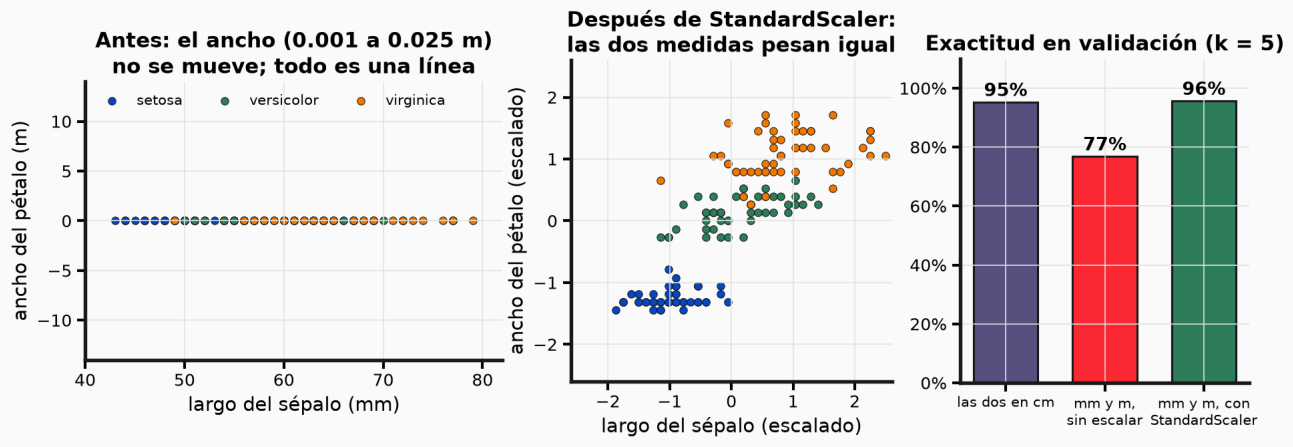
Bloque KNN, 17:11



Con k = 1 hereda el error. Con 3 o más, las otras vecinas lo corrigen.

ANTES DE MEDIR DISTANCIAS, ESCALAR

Bloque KNN, 17:12



Si una medida está en **mm** (43 a 79) y otra en **m** (0.001 a 0.025), la distancia la decide casi sola la de mm. El ancho no cuenta: **77 %**.

`StandardScaler` pone las dos en la misma escala: **96 %**. Se ajusta **solo con train** (la regla de la fuga de S2); por eso va dentro del pipeline.

KNN PARA REGRESIÓN: PROMEDIAR EN LUGAR DE VOTAR

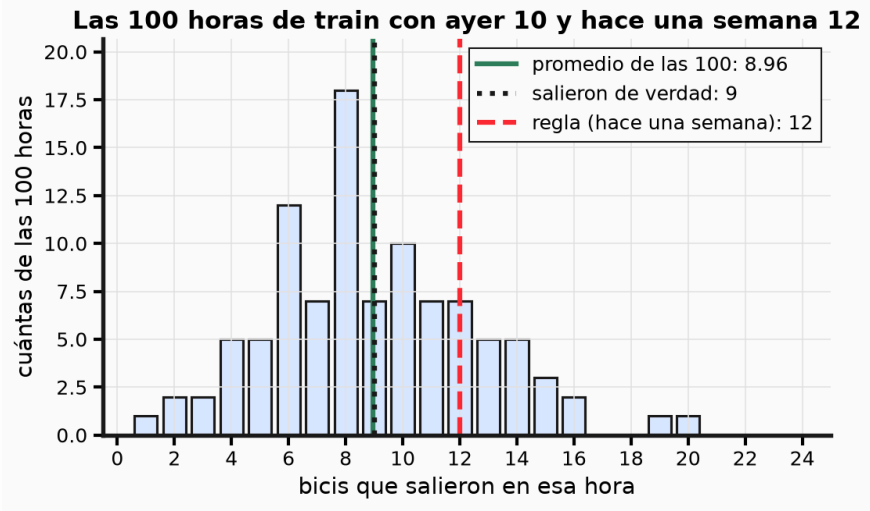
Bloque KNN, 17:14

Para un **número** no se vota: se **promedia**.

Estación 69, miércoles 8 de julio, 8:00

	Salidas
Ayer a esta hora	10
Hace una semana	12
De verdad	**9**

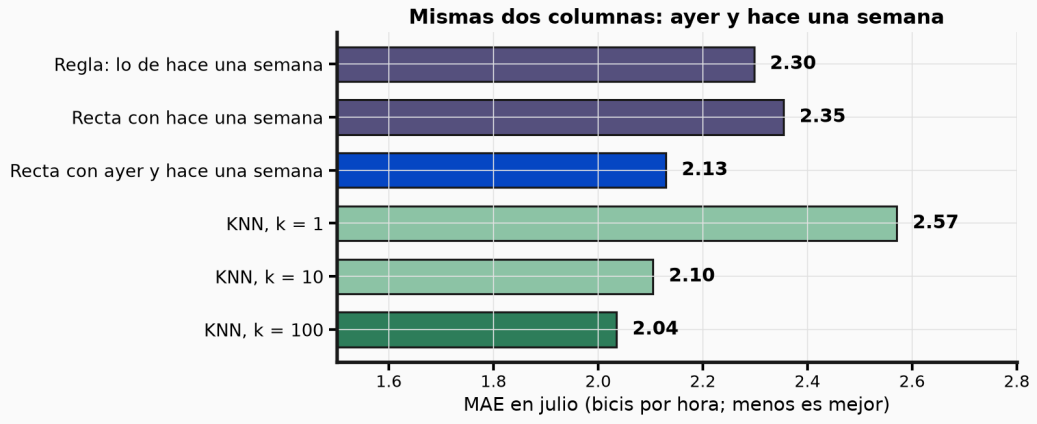
```
knn = KNeighborsRegressor(n_neighbors=100)
knn.fit(train[cols], train.departures)
```



Promedio de las 100: 8.96. La regla decía 12.

¿LE GANA A LA RECTA? MAE EN JULIO

Bloque KNN, 17:16



Con **las mismas dos columnas**, KNN le gana a la recta: 2.04 contra 2.13. No tiene que seguir una línea recta.

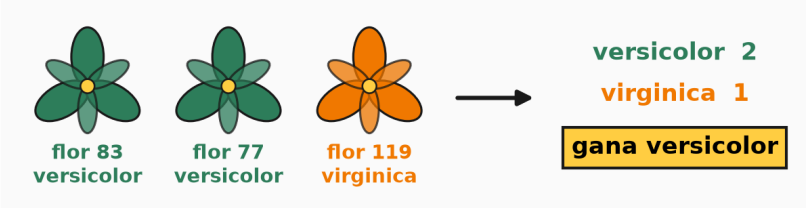
Solo a las 8:00: KNN 2.87, recta 3.05, regla 3.27.

Escogimos k = 100 viendo julio, así que 2.04 es un poco optimista. La cifra final sale de la prueba.

LO BUENO Y LO MALO

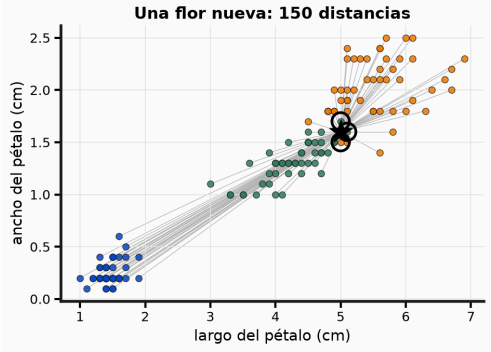
Bloque KNN, 17:17

Lo bueno



- Fácil de explicar: "se parece a estos casos"
- Puedo mostrar quiénes decidieron
- No supone una recta

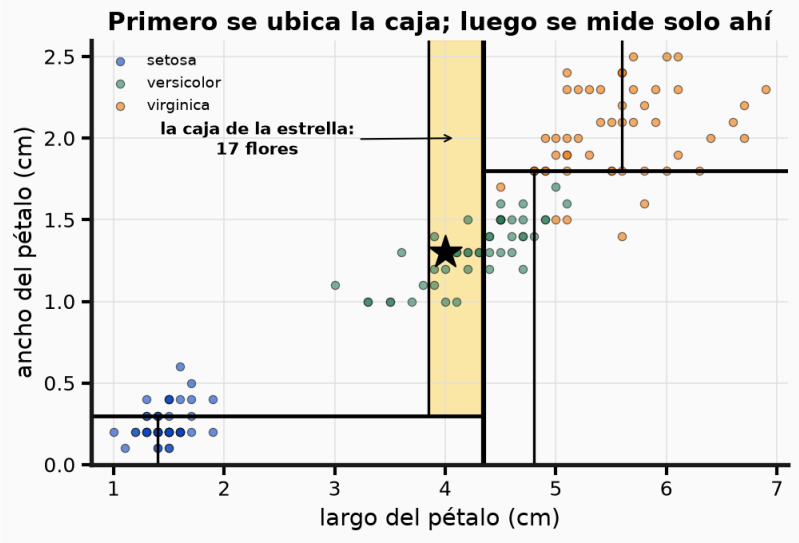
Lo malo



- **Lento:** compara contra todos
- Hay que escalar y escoger columnas
- Con muchas columnas, todo queda lejos

PARA NO MEDIR CONTRA TODAS: EL KD-TREE

Bloque KNN, 17:18



Antes de predecir, se **organizan las flores por regiones**: un corte por el largo, luego por el ancho, y así.

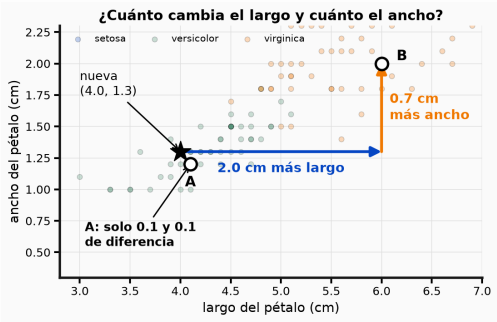
Para una flor nueva, primero se ve **en qué caja cae** y se mide solo contra las de esa caja (y las cajas de junto, si hace falta).

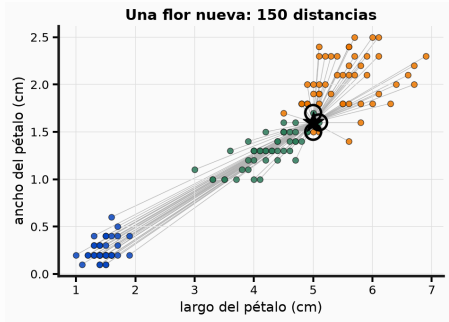
scikit-learn lo usa con `algorithm="kd_tree"`, o solo cuando le conviene con `"auto"`, el valor por defecto.

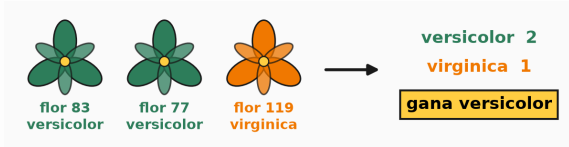
CIERRE DEL BLOQUE KNN

Bloque KNN, 17:19

PASO	QUÉ HACE
1. Parecido	Distancia de regla entre las medidas (escaladas con train)
2. Vecinas	Las k más cercanas; k se escoge con validación
3. Decisión	Clasificación: votan. Regresión: se promedia







Para predecir un caso nuevo, miramos qué les pasó a los casos más parecidos.

REFERENCIAS DEL BLOQUE KNN

Bloque KNN, consulta

Fisher, R. A. (1936). The use of multiple measurements in taxonomic problems. *Annals of Eugenics, 7*(2), 179–188.

James, G., Witten, D., Hastie, T., y Tibshirani, R. (2021). *An introduction to statistical learning: With applications in R* (2a ed.). Springer. Secciones 2.2.3 y 3.5.
https://www.statlearning.com

scikit-learn. (s. f.). *Nearest neighbors*. Consultado el 31 de octubre de 2026.
https://scikit-learn.org/stable/modules/neighbors.html

Starmer, J. (2017, 26 de junio). *StatQuest: K-nearest neighbors, clearly explained* [Video]. YouTube.
https://www.youtube.com/watch?v=HVXime0nQeI

Fotos (Wikimedia Commons; recortadas y reducidas a 800 px):

Radomil. (2005). *Iris setosa* [Fotografía]. CC BY-SA 3.0.
https://commons.wikimedia.org/wiki/File:Kosaciec_szczecinkowaty_Iris_setosa.jpg

Langlois, D. (2005). *Iris versicolor* [Fotografía]. CC BY-SA 3.0.
https://commons.wikimedia.org/wiki/File:Iris_versicolor_3.jpg

Mayfield, F. (2007). *Iris virginica shrevei* [Fotografía]. CC BY-SA 2.0.
https://commons.wikimedia.org/wiki/File:Iris_virginica.jpg

PAUSA DE 5 MIN

Lejos de la pantalla. Agua, estírate, mira por la ventana.

REGRESAMOS EN **05:00**

BLOQUE B | VI.3 y VI.4 | ⏱ 85–140

¿QUÉ ERROR CUESTA MÁS?

Reflexión en FigJam y la primera pregunta de un árbol.

FIGJAM 1 · ¿QUÉ ERROR CUESTA MÁS? (25 MIN)

FIGJAM · REFLEXIÓN

tablero en el chat · breakouts de 3

TIEMPO **20:00**

Cada equipo recibe un **caso** en su marco del tablero:

1. Detección de fraude en tarjetas
2. Tamizaje de diabetes (ENSANUT)
3. Rebalanceo de MiBici
4. Filtro de currículums para una vacante
5. Alerta de deserción escolar

Pónganse de acuerdo y peguen notas:

- 🟥 **Costo de un FN** (¿quién lo paga?)
- 🟨 **Costo de un FP** (¿quién lo paga?)

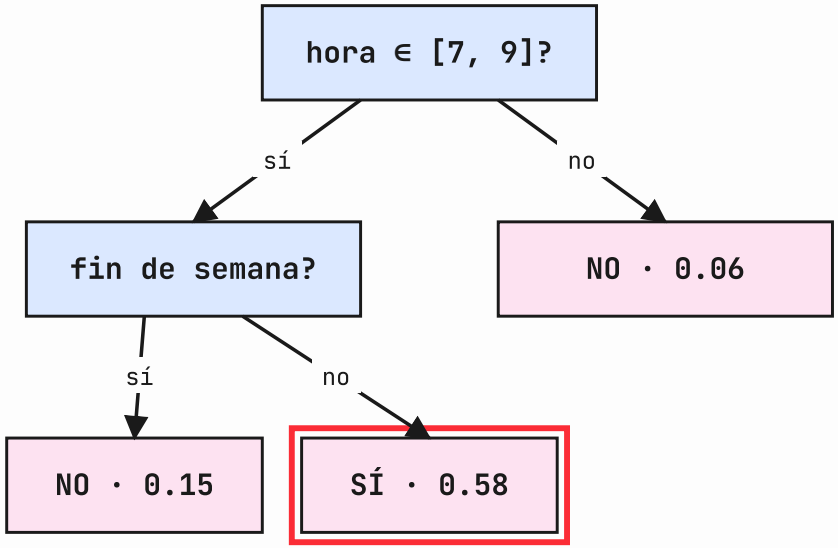
Plenaria (5 min)

Cada equipo lee **una** nota, la que más discutieron.

Pregunta que hace chirriar la ardilla:

> Si el costo lo paga alguien que no está en la sala, ¿quién debería elegir el umbral?

VI.4 · UN ÁRBOL ES UNA SERIE DE PREGUNTAS



¿desbalance fuerte en las próximas 3 h?

Árbol de decisión

RESTRICCIÓN: QUÉ FORMAS PUEDE DIBUJAR

cortes paralelos a los ejes: $x_j \leq t$

PREFERENCIA: CON CUÁL SE QUEDA

árboles cortos; elige el corte con más ganancia de información (greedy)

- Cada hoja predice la **proporción** de positivos (o el promedio, en regresión)
- Se lee como reglas: **es deducción** a partir de lo inducido (VI.1)
- No necesita escalar variables

Ng, MLS C2 S4 «Decision tree model» · R2D3, «A visual introduction to machine learning» (inspiración)

CIERRE DEL BLOQUE B

¿QUÉ PASA SI…?

Si dejas crecer el árbol hasta que cada hoja tenga 1 ejemplo, ¿qué pasa con el error de entrenamiento y el de validación?

A. Ambos bajan

B. Train tiende a 0 y validación sube (varianza)

C. Ambos suben

D. No cambian

PAUSA DE 25 MIN

Lejos de la pantalla. Agua, estírate, mira por la ventana.

REGRESAMOS EN **25:00**

BLOQUE C | VI.4 Árboles de decisión | ⏱ 165–220

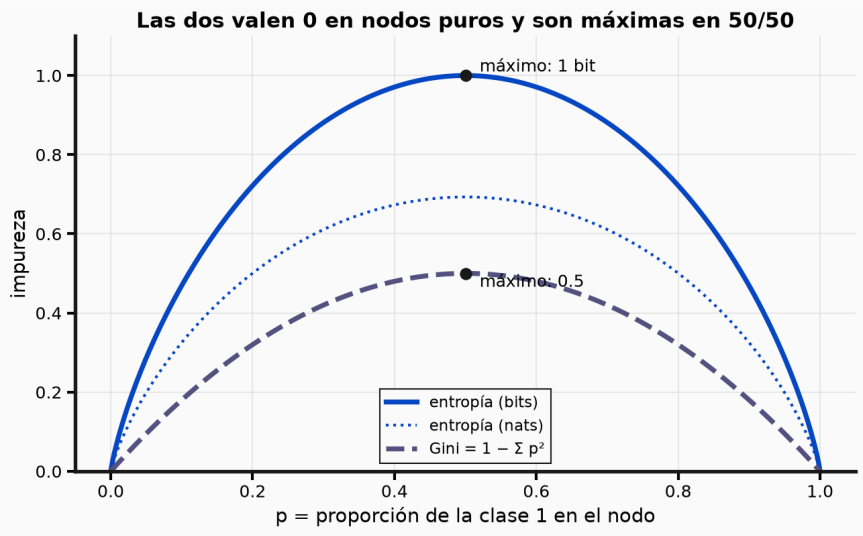
¿QUÉ PREGUNTA HACER PRIMERO?

Entropía (demo 5), sobreajuste y ensambles.

DEMO 5 · MEDIR LA «MEZCLA» DE UN NODO

RECUERDEN, MÓDULO II entropía

$H(p) = -p \log_2 p - (1-p)\log_2(1-p)$: la incertidumbre, en bits, de una moneda con sesgo p.



ganancia de información de un corte

$$IG = H(\text{padre}) - \left[\frac{n_L}{n} H(L) + \frac{n_R}{n} H(R)\right]$$

nodo padre: 5 positivos, 5 negativos, así que $H = 1$

corte A: L = (4+, 0-), R = (1+, 5-)

$$IG_A = 1 - \left[\frac{4}{10} \cdot 0 + \frac{6}{10} \cdot 0.65\right] = _____$$

calcúlalo en el chat

Respuesta: **0.61 bits**. El árbol prueba todos los cortes de todas las variables y se queda con el de mayor IG.

ÁRBOLES QUE MEMORIZAN

- Sin límite, un árbol separa cada ejemplo: **varianza alta**
- Controles: `max_depth`, `min_samples_leaf`, poda
- Un ejemplo distinto puede cambiar **todo** el árbol: inestable

RECUERDEN, MÓDULO VI · S2 sesgo y varianza

J_{train} bajo y J_{cv} alto = varianza. La cura: promediar muchos modelos ruidosos.

ENSAMBLES: MUCHOS ÁRBOLES

Bosque aleatorio (bagging)

1. Remuestrea con reemplazo (*bootstrap*)
2. En cada nodo, considera solo un subconjunto de variables
3. Promedia (o vota)

Baja la varianza. Árboles profundos, en paralelo.

Boosting (XGBoost)

1. Entrena un árbol chico
2. El siguiente se enfoca en lo que el anterior **falló**
3. Suma con una tasa de aprendizaje

Baja el sesgo. Árboles chicos, en secuencia. Recuerden GD (Mód III): es descenso de gradiente en el espacio de funciones.

Ng, MLS C2 S4 «Random forest» · «XGBoost» · CS229 (2018) L9

CONCEPTEST · ¿QUÉ ENSAMBLE?

CONCEPTEST 1. Voto individual (1 min) siguiente ▸

Tu árbol profundo tiene J_train = 0.01 y J_cv = 0.40. ¿Qué ensamble pruebas primero?

- **A.** Boosting con árboles profundos
- **B.** Bosque aleatorio
- **C.** Un solo árbol más profundo
- **D.** Regresión lineal

letra en el chat

¿CUÁNDO USAR ÁRBOLES?

	Árboles y ensambles	Modelos lineales / redes
Datos tabulares (columnas)	**excelentes**	buenos
Imágenes, audio, texto	malos	**excelentes** (Mód VIII–IX)
Escalar variables	no hace falta	necesario
Interpretabilidad	un árbol sí; un ensamble poco	lineal sí
Extrapolar fuera del rango	**no**: la hoja es constante	sí (para bien y para mal)

El último renglón es VI.1 otra vez: el sesgo inductivo del árbol dice «fuera de lo visto, repite el último valor».

PAUSA DE 5 MIN

Lejos de la pantalla. Agua, estírate, mira por la ventana.

REGRESAMOS EN **05:00**

LAB 3 | VI.4 Árboles de decisión | ⏱ 225–295

LAB 3 · ÁRBOLES, BOSQUES Y BOOSTING

Más una caza de fuga de información.

LAB 3 · RUTA

LAB · COLAB notebook L3 TIEMPO 55:00

Nivel	Qué haces
L3	Completa `entropia`, `ganancia_info`, `mejor_corte`
L4	**Caza de errores**: una variable que «ve el futuro»
L5	MiBici: árbol vs bosque vs boosting; curva PR y AP en validación
L6	Mini-reto: ¿qué modelo despliegas y con qué umbral?

Entrega: Moodle, **dom 15 nov 23:59** (tolerancia hasta el mié 18 nov).

Tarea 2 (árboles y SVM): se publica hoy y vence el **dom 15 nov 23:59** (tolerancia hasta el mié 18 nov).

TICKET DE SALIDA (MOODLE, 3 MIN)

1. Con prevalencia del 2 %, ¿por qué la AP es más honesta que la AUC-ROC?
2. ¿Qué ataca un bosque aleatorio: sesgo o varianza?
3. ¿Qué te dejó pensando la actividad de FigJam?

Mañana 9:00: máquinas de soporte vectorial, kernels y el mapa de todos los modelos.

Fuentes: Ng, MLS C2 S3–S4 · CS229 (2018) L9 · Cornell CS4780 (árboles y ensambles).

Material propio CC BY-NC-SA 4.0.