DAMMG | FACULTAD DE CIENCIAS, UNAM | 1ª EMISIÓN

Facultad de Ciencias UNAM

SECRETARÍA DE EDUCACIÓN ABIERTA Y CONTINUA
FACULTAD DE CIENCIAS

DIPLOMADO EN APRENDIZAJE DE MÁQUINA Y MODELOS GENERATIVOS

LA CALLE MÁS ANCHA

Máquinas de soporte vectorial, kernels y el mapa de todo el módulo.

DAMMG Módulo VI: Aprendizaje supervisado | Sesión 4 · VI.5 e integración | sáb 7 nov 2026 · 9:00–14:00

Mtro. Hesus García Cobos

QUIZ DE RECUPERACIÓN (10 MIN)

CONCEPTEST 1. Voto individual (1 min) siguiente ▸

1 · Ganancia de información de un corte que deja los dos hijos con la misma proporción que el padre:

- **A.** 1 bit
- **B.** 0
- **C.** negativa
- **D.** depende de n

letra en el chat

CONCEPTEST 1. Voto individual (1 min) siguiente ▸

2 · Boosting ataca sobre todo…

- **A.** la varianza
- **B.** el sesgo
- **C.** la fuga de información
- **D.** el desbalance

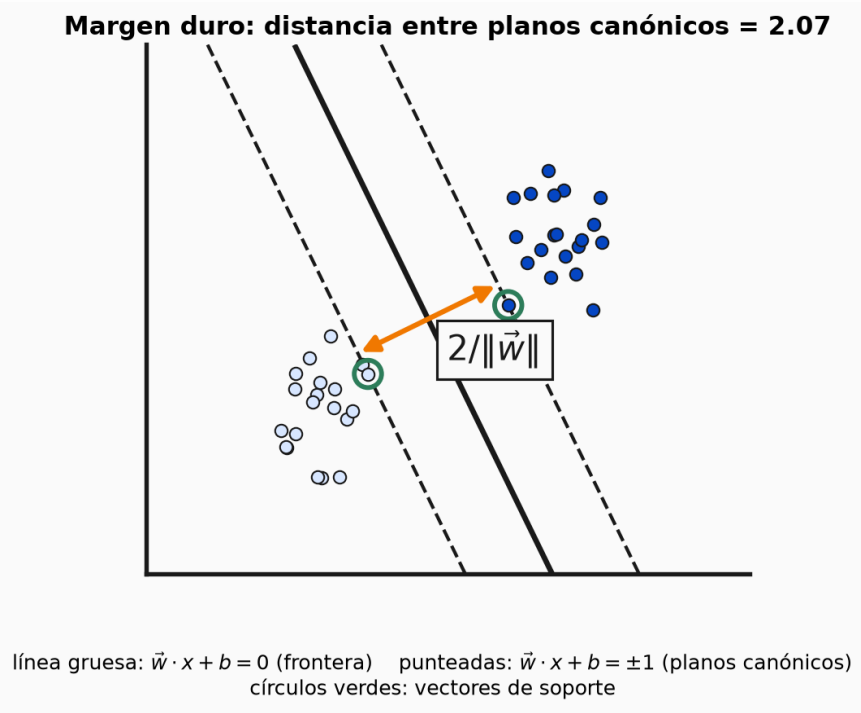
letra en el chat

BLOQUE A | VI.5 Máquinas de soporte vectorial | ⏱ 15–55

MUCHAS RECTAS SEPARAN. ¿CUÁL ES LA MEJOR?

Winston, MIT 6.034 L16 · Ng, CS229 L6.

TRES FRONTERAS PERFECTAS



¿QUÉ PASA SI…?

Las tres rectas separan perfecto el entrenamiento. ¿Cuál generaliza mejor?

A. La que pasa cerca de los puntos rojos

B. La que pasa cerca de los azules

C. La que deja la «calle» más ancha

D. Da igual

SVM

RESTRICCIÓN: QUÉ FORMAS PUEDE DIBUJAR

hiperplano (en el espacio original o en uno transformado por el kernel)

PREFERENCIA: CON CUÁL SE QUEDA

el margen más ancho: la calle más ancha posible

DEMO 6 · ¿POR QUÉ EL ANCHO ES 2/‖W‖?

RECUERDEN, MÓDULO I distancia a un hiperplano

Distancia de x_0 al plano $\vec{w} \cdot x + b = 0$:

$$\frac{|\vec{w} \cdot x_0 + b|}{\|\vec{w}\|}$$

convención canónica: los puntos más cercanos cumplen $\vec{w} \cdot x + b = \pm 1$

distancia entre $\vec{w} \cdot x + b = +1$ y $\vec{w} \cdot x + b = -1$

$$= \frac{|1 - (-1)|}{\|\vec{w}\|} = \frac{2}{\|\vec{w}\|}$$

maximizar el margen = minimizar ?

SUPUESTOS

Datos linealmente separables; etiquetas y $\in \{-1, +1\}$; escala canónica de (w, b).

Si no se cumplen: si las clases se traslapan, no existe ningún w que cumpla todas las restricciones: el margen duro no tiene solución. Siguiente bloque: margen suave.

Vectores de soporte: los puntos sobre los planos ± 1. Si mueves cualquier otro punto (sin cruzar la calle), la solución **no cambia**.

RECUERDEN: LAGRANGE Y EL DUAL (SIN DERIVARLO)

RECUERDEN, MÓDULO III optimización con restricciones

Multiplicadores de Lagrange $\alpha_i \geq 0$, uno por restricción.

Al resolver, la solución tiene la forma

$$\vec{w} = \sum_i \alpha_i \, y^{(i)} x^{(i)}$$

y solo los **vectores de soporte** tienen $\alpha_i > 0$.

El dual solo usa **productos punto** entre ejemplos:

$$\max_{\alpha} \sum_i \alpha_i - \tfrac{1}{2} \sum_{i,j} \alpha_i \alpha_j y^{(i)} y^{(j)} \boxed{x^{(i)} \cdot x^{(j)}}$$

Esa caja es la puerta al **truco del kernel** (bloque B): cambia el producto punto por otra función de similitud.

CS229 (2018) L6–L7 · notas de CS229, SVM y dualidad

CIERRE DEL BLOQUE A

Chat waterfall: en una frase, ¿por qué una calle más ancha debería generalizar mejor? Conéctalo con VI.1.

PAUSA DE 5 MIN

Lejos de la pantalla. Agua, estírate, mira por la ventana.

REGRESAMOS EN **05:00**

BLOQUE B | VI.5 Máquinas de soporte vectorial | ⏱ 60–115

CUANDO LAS CLASES SE MEZCLAN

Margen suave, hinge y kernels (demos 6 y 7).

MARGEN SUAVE: PERMITIR ERRORES CON UN PRECIO

$$\min_{\vec{w},b} \ \frac{1}{2}\|\vec{w}\|^2 + C\sum_i \underbrace{\max\left(0,\ 1 - y^{(i)}(\vec{w}\cdot x^{(i)} + b)\right)}_{\text{hinge}}$$

- Punto fuera de la calle y bien clasificado: hinge = 0
- Punto dentro de la calle: hinge entre 0 y 1
- Punto mal clasificado: hinge > 1

Vectores de soporte en margen suave: los que tienen $0 < \alpha_i < C$ están **sobre** los planos; los que tienen $\alpha_i = C$ pueden quedar **dentro** de la calle o mal clasificados.

RECUERDEN, MÓDULO VI · S2 regularización

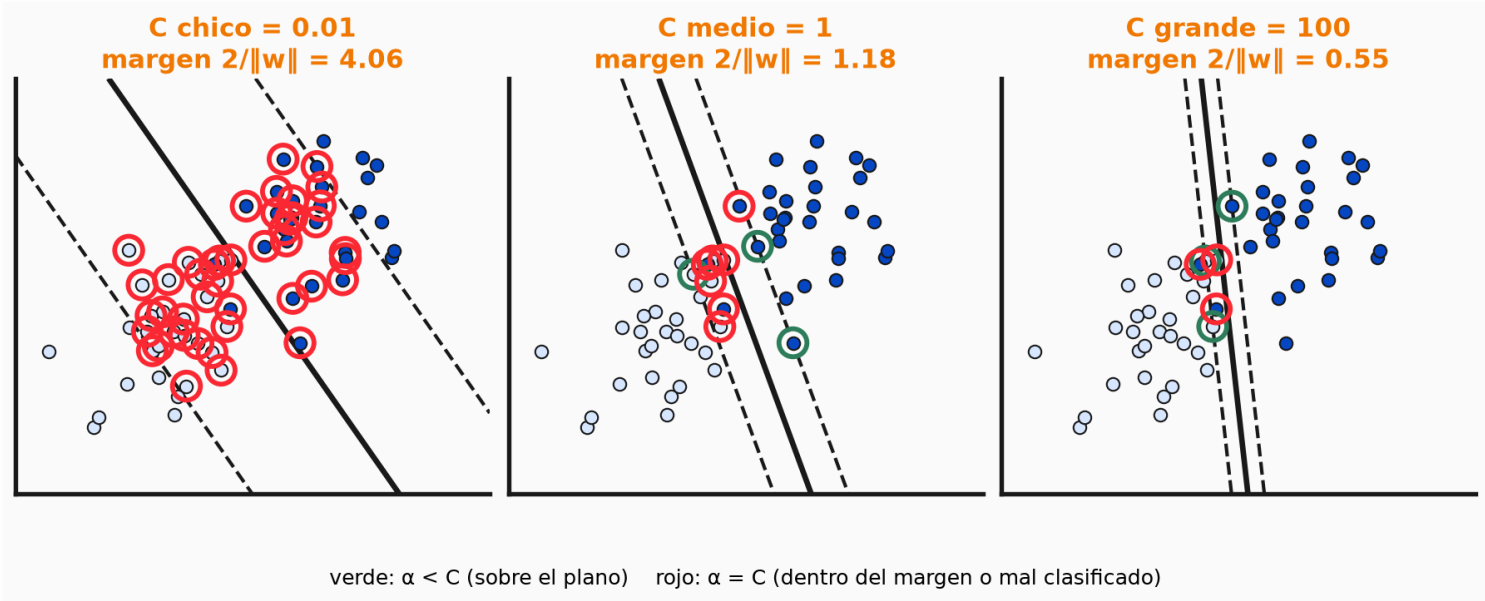
$\frac{1}{2}\|\vec{w}\|^2$ es el término de Ridge. C hace el papel de $1/\lambda$: **C grande = poca regularización**.

¿QUÉ PASA SI…?

¿Qué pasa con el margen si C sube mucho?

A. Se ensancha
B. Se angosta: el modelo castiga cada error (tiende a sobreajustar)
C. No cambia
D. Desaparecen los vectores de soporte

C EN TRES ESTADOS

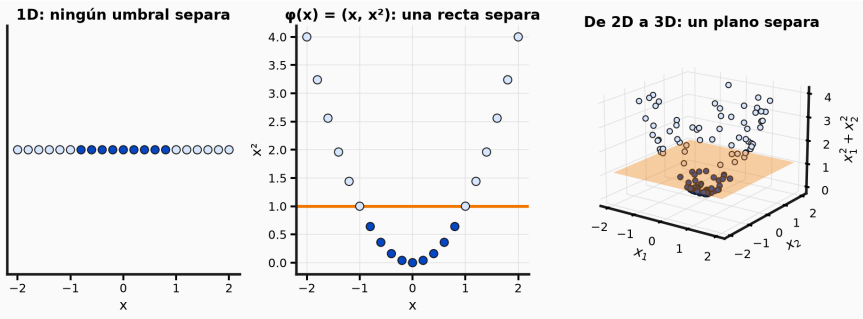


C chico: calle ancha, muchos puntos dentro, más sesgo

C medio: equilibrio; se elige con validación

C grande: calle angosta, casi margen duro, más varianza

DEMO 7 · EL TRUCO DEL KERNEL, A MANO



en 2D, $\varphi(x) = (x_1^2,\ x_2^2,\ \sqrt{2}x_1x_2,\ \sqrt{2}x_1,\ \sqrt{2}x_2,\ 1)$

$x = (1, 2),\ z = (3, -1)$

$$\varphi(x) \cdot \varphi(z) = 9 + 4 - 12 + 6 - 4 + 1 = 4$$

$$(x \cdot z + 1)^2 = (3 - 2 + 1)^2 = ____$$

compruébalo en el chat

El kernel calcula el producto punto en el espacio grande sin construirlo. El RBF $K(x, z) = e^{-\gamma\|x-z\|^2}$ corresponde a un espacio de dimensión infinita.

¿QUÉ PASA SI γ SUBE MUCHO?

¿QUÉ PASA SI…?

Kernel RBF con γ enorme. ¿Cómo se ve la frontera?

A. Una recta

B. Una curva suave

C. Islas alrededor de cada punto de entrenamiento

D. No cambia

- γ chico: cada punto influye lejos, así que la frontera es **suave** (más sesgo)
- γ grande: cada punto influye solo cerca, así que aparecen **islas** (más varianza)
- C y γ se eligen **juntos** con validación cruzada (búsqueda en rejilla, escala log)

RECUERDEN, MÓDULO IV escalamiento

El RBF usa distancias: **sin escalar, una variable en miles domina a las demás**.

SVM EN LA PRÁCTICA (SKLEARN)

Estimador	Pérdida	¿Regulariza b?	Cuándo
`SVC(kernel="rbf")`	hinge	no	hasta ~10^4 ejemplos; fronteras no lineales
`LinearSVC(loss="hinge")`	hinge (por defecto es `squared_hinge`)	sí, vía `intercept_scaling`	muchos ejemplos, frontera lineal
`SGDClassifier(loss="hinge")`	hinge		datos enormes o en flujo

⚠ `SVC` crece entre $O(m^2)$ y $O(m^3)$: con las 254 mil filas de train de MiBici no termina en clase. En el Lab 4 usamos una **muestra estratificada** para el RBF y `LinearSVC` para la tabla completa.

Ng, ML Coursera 2011 «Using an SVM» · documentación de scikit-learn

CIERRE DEL BLOQUE B

CONCEPTEST 1. Voto individual (1 min) siguiente ▸

SVM RBF: train 99 %, validación 71 %. ¿Qué mueves?

A. Subir C y subir γ

B. Bajar C y/o bajar γ

C. Quitar el escalamiento

D. Más iteraciones

letra en el chat

PAUSA DE 25 MIN

Lejos de la pantalla. Agua, estírate, mira por la ventana.

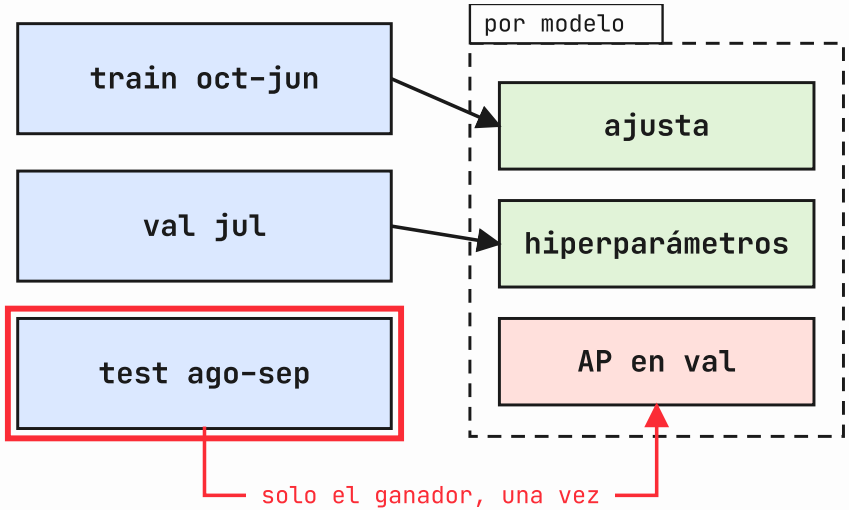
REGRESAMOS EN **25:00**

BLOQUE C | Integración VI.1-VI.5 | ⏱ 140–195

TODOS LOS MODELOS, UN MISMO PROBLEMA

Comparativa honesta y el mapa de sesgos.

LA MISMA PREGUNTA, CINCO APUESTAS



Modelo	Sesgo inductivo
Baseline (lag 168 h)	la semana se repite
Logística	hiperplano en log-momios
Árbol	cortes en los ejes, corto
Bosque / boosting	promedio o suma de árboles
SVM RBF	margen ancho + similitud local

protocolo de comparación

LO QUE SALE EN MIBICI (VALIDACIÓN = JULIO)

Modelo	AP val
Mayoritario	0.145
«La semana se repite»	0.349
SVM RBF (muestra 8 000)	0.429
Logística	0.445
LinearSVC hinge	0.446
Árbol (`max_depth=8`)	0.463
Bosque aleatorio	0.545
Boosting	**0.556**

- Recuerden la prevalencia: **≈ 0.15** es el piso de la AP
- El árbol sin límite: train 1.0, validación 0.23: **varianza**
- Ganador en test (una vez), umbral para 25 % de alertas: AP 0.55, precision 0.41, recall 0.66, **27 % de alertas** (la prevalencia cambió)

Números de la solución del Lab 4; los suyos pueden variar un poco según la muestra.

LEER UNA TABLA DE RESULTADOS

¿QUÉ PASA SI…?

El boosting le gana al bosque por 0.01 de AP en validación. ¿Lo despliegas?

A. Sí, ganó

B. Depende: costo, latencia, interpretabilidad y si 0.01 es ruido

C. No, los árboles nunca

D. Solo si gana en test

- ¿La diferencia es mayor que la variación entre semanas? En el lab, *bootstrap* sobre semanas: +0.011, intervalo 90 % 0.009, 0.013, gana en las 5 semanas: **pequeña pero consistente**
- ¿Quién mantiene el modelo? ¿Hay que explicarlo?
- ¿Qué pasa en eventos raros (conciertos, lluvia)? Los árboles **no extrapolan**
- Volver a VI.1: ¿la apuesta del modelo coincide con el problema?

PAUSA DE 5 MIN

Lejos de la pantalla. Agua, estírate, mira por la ventana.

REGRESAMOS EN **05:00**

LAB 4 | VI.5 + integración | ⏱ 200-275

LAB 4 · SVM Y COMPARATIVA FINAL

LAB 4 · RUTA

LAB · COLAB notebook L4 TIEMPO 45:00

Nivel	Qué haces
L1–L2	Margen y vectores de soporte con datos 2D; slider de C y γ
L3	Completa `hinge`, `kernel_poli2`, `margen`
L5	MiBici: SVM RBF (muestra de 5–10 mil, < 60 s), `LinearSVC` (completo)
L6	Tabla comparativa con todos los modelos del módulo

Entrega: Moodle, **dom 15 nov 23:59** (tolerancia hasta el mié 18 nov).

Los últimos 15 min del lab son el **FigJam 2**: no corras el L6 si no te da tiempo, termínalo en casa.

FIGJAM 2 · EL MAPA DE SESGOS (15 MIN)

FIGJAM · REFLEXIÓN

tablero compartido · todos a la vez

TIEMPO 12:00

En el plano del tablero:

- **Eje x:** ¿qué tanto supone el modelo? (de pocos a muchos supuestos)
- **Eje y:** ¿qué tan bien extrapola fuera de lo visto?

1. Coloca cada modelo del módulo (tarjetas ya hechas)
2. Pega una nota 🟨 con **un problema de tu trabajo** cerca del modelo que usarías
3. Si no estás de acuerdo con la posición de una tarjeta, **muévela y deja una nota explicando**

Para chirriar la ardilla:

> ¿Existe un modelo sin sesgo inductivo? ¿Lo querrías?
>
> Las redes neuronales (Módulo VIII), ¿dónde caen en este mapa?

PUENTE A LO QUE SIGUE

VII · No supervisado

Sin y: el sesgo inductivo es aún más explícito (¿qué es un grupo?).

VIII · Redes neuronales

Una logística = **una neurona**. Apila muchas y entrena con el mismo GD.

X · Generativos

La log-loss y la entropía cruzada regresan como costo para generar datos.

PROYECTO FINAL (EQUIPOS DE 2–3)

Qué

Comparar al menos **tres modelos** del módulo en un problema (MiBici u otro con datos que puedas compartir) y **justificar** cuál despliegas, con qué métrica y con qué umbral.

Entrega

Reporte de **2 páginas** + notebook. Vence **dom 22 nov 23:59**. Tolerancia hasta el **mié 25 nov**.

Rúbrica (resumen)

- Partición honesta y baseline
- Métrica justificada por el costo de los errores
- Lectura de resultados con sesgo, varianza y sesgo inductivo
- Limitaciones y riesgos

Rúbrica completa en Moodle.

TICKET DE SALIDA (MOODLE, 3 MIN)

1. ¿Qué controla C en un SVM y qué pasa si sube mucho?
2. En una frase: ¿qué hace el truco del kernel?
3. ¿Qué te llevas del módulo para tu trabajo?

Fuentes: Ng, CS229 (2018) L6–L7 · ML Coursera 2011 sem. 7 · Winston, MIT 6.034 L16 (CC BY-NC-SA) · Abu-Mostafa, CS156 L14–15. Material propio CC BY-NC-SA 4.0.